

2024 年度研究成果報告書

研究課題	3D アバターの自然な表情変換
------	-----------------

1. 研究背景と目的

研究背景

現在、AR や VR デバイスの普及により、3D 空間での生成 AI モデルの需要が高まっており、リアルな人間を 3D 空間上で再現することで、ゲームや映画などの没入感を増加させることができる。以上のことから生成 AI モデルのタスクの一つである 3D Face Reconstruction に関する研究が盛んに行われている。

人間の顔を 3D 空間で表現しながら、その人固有のアイデンティティや表情、顔の向きなどをパラメトリックに操作できる技術である 3D Morphable Model (3DMM) や、任意の光線上に存在する点とその密度 (存在確率) で 3D 空間を表現する Neural Radiance Fields (NeRF) などの、ニューラルネットワークによる 3D 空間の表現を容易にする技術の発展や、敵対性損失を用いる GAN やノイズを除去していく過程を学習する Diffusion Model などの生成タスクに関する深層学習手法の発展により、頭部の向きや光の当たり方、カメラ視点、アイデンティティを忠実に再現したデジタルヒューマンを 3D 空間で表現することが可能になっている。しかし、アーキテクチャ上の問題や、計算資源の不足により、密な点群での 3D Face Reconstruction が困難であることや、口の中や眼球、髪、アクセサリなどの再現性が不足しているなどの課題がある。また、表情をパラメトリックに変化させることができるが、表情変化によってアイデンティティが失われてしまったり、不自然な表情を生成してしまったり、人間が指示した感情とデジタルヒューマンの表情が一致しないといった課題も存在する。

研究目的

ある人物の 2D 画像を入力することで、その人物特有のアイデンティティと、顔以外の特徴である髪や背景などを保持しながら、顔の向きや表情、光の当たり方を操作する DiffusionRig のモデルアーキテクチャを一部変更することで、より表情豊かで、指定された感情に対して一致度の高い表情を持つデジタルヒューマンを生成できる DiffusionRig-Emo の完成を目指す。この研究により、DiffusionRig の拡張性・実用性を上げるとともに、3D アバターの表情再現性向上によるゲームや映画などへの応用性も示すことができる。

また、DiffusionRig-Emo は DiffusionRig の感情再現性と表情の豊かさを高めることが目的である。その再現性や豊かさを評価する指標として、EmoNet による感情分類精度や、ユーザスタディによる主観的評価などがあるが、AI モデルごとの表情生成性能を評価する指標としてはまだ不十分であると考えている。そこで、他の Face Reconstruction model の生成表情評価にも使用できる定量的かつ直観的な評価指標の開発も目指し、DiffusionRig-Emo と DiffusionRig の性能差を明確にすることを本研究のゴールとする。

2. 既存・関連研究

既存・関連研究として FLAME, NPHM, DECA, EMOCA, DiffusionRig を紹介する.

1. FLAME

FLAME とは, 3D 顔形状を再現するための統計モデルであり, 顔の形状, 表情, 頭部の回転の 3 つのパラメータを制御可能である. 3D スキャンデータを共通のトポロジーに揃えるテンプレートマッチングを行ってから PCA 分析を用いることで統合 3D 点群モデルを構成している. 以上のモデルは 2017 年に発表されたものであるが, 制御性の高さにより様々な 3D Face Reconstruction タスクにおける基盤モデルとして採用されている.




図 1. FLAME モデル[1]

2. NPHM

FLAME と同様に 3D 顔形状を再現するための統計モデルであるが, PCA 分析を用いることで髪や歯などを再現できなかったり, 表面の微細な表現ができなかったりする点などを克服するために 2022 年に提案された. NPHM は 3D 物体の表面を記述する Neural-SDF 手法を用いることで 3D 点群モデルを構成していて, FLAME にはない工夫として顔のアンカーポイントを中心とする局所座標のみを対象とする小さな MLP を複数導入することで表面の微細な表現力が上昇している.




図 2. NPHM のトレーニング過程[2]

また, ある人物の顔に対してアイデンティティを失わない自然な表情変化を実現するため, 顔の形状(アイデンティティ)を表現する潜在空間と表情を表現する潜在空間を分離しておく必要がある. このため, NPHM では同一人物の無表情と表情を変化させたデータセットを用意し, それらの差

すなわち表情変化のみを学習するMLPをトレーニングすることで、それぞれの潜在空間を分離する。さらに、FLAME と比べて多様性は少ないが、より密な 3D 点群頭部スキャンをデータセットとして用いることで、3D Face を表現するための点群が多く、正確なフィッティング精度を持つ出力結果を得られる。

3. FLAME vs NPHM

FLAME と NPHM のメリット・デメリットを比較した表と実際の出力結果の比較を示す。

表 1. FLAME vs NPHM

	FLAME	NPHM
表現力	低い	高い
表現の自由度	頭部のみ	頭部と髪や歯
構成点群数	少ない	多い
必要計算資源	少ない	多い
パラメータ	shape・expression・pose	shape・expression
応用例	多い	少ない




図 3. FLAME と NPHM の出力結果比較[2]

4. DECA

DECA は 1 枚の 2D 顔画像から、顔の特徴をモデリングし、既存の 3D 統合モデル (FLAME) と組み合わせることで精巧な 3D 顔形状を復元することができるモデルである。FLAME を構成するための identity shape・facial expression・pose parameter の 3 つのパラメータと、表面のテクスチャを決める texture parameter, レンダリングに使用する lighting parameter・camera parameter, 以上の 6 つのパラメータを学習する。




図 4. DECA のアーキテクチャ [3]

大まかな顔の形状を学習する coarse stage とより細やかな顔の特徴を学習する detail stage に分けてトレーニングを行うことで、FLAME の表現力を補っている。

5. EMOCA

EMOCA は DECA の拡張版であり、同様のタスクのために開発されたが、生成する 3D Face の表情豊かさに着目したモデルである。DECA の表情に関して、生成した 3D Face と入力画像の感情が一致しないという課題があり、DECA のアーキテクチャの中に感情損失関数を導入することで課題の解決を目指した。

DECA の facial expression ϕ パラメータを coarse stage でのエンコーダから抜き出し、生成した 3D Face をレンダリングした画像と、入力画像を同じ感情認識用ネットワークに入力した結果から感情整合性損失を定義し、それが小さくなる方向に ϕ をトレーニングする。ここで、感情離散ラベルと valence/arousal がアノテーションされた AffectNet-DB に対して ResNet-50 を用いてトレーニングを行ったモデルを感情認識用ネットワークとして使用する。




図 5. EMOCA のアーキテクチャ[4]

6. DECA vs EMOCA

DECA と EMOCA の出力結果の比較を図 6 に示す．激しい表情を扱う際に，EMOCA が入力画像の感情をより忠実に再現していることがわかる．



図 6. DECA vs EMOCA[4]

7. DiffusionRig

DiffusionRig は 2023 年に Adobe から発表されたモデルであり, 20 枚ほどの同一人物のポートレート写真から, 人物特有の顔の特徴を学ぶことができ, 学んだ顔の特徴に含まれるアイデンティティを保持しながら, 顔の表情・ライティング・向きを編集した画像を出力できる.




図 7. DiffusionRig による編集例[5]

学習過程は 2 段階に分けることができ, 大規模 2D 顔画像データセットから一般的な顔情報を学習する stage1 と, 20 枚ほどの同一人物写真を利用して, 一般的な顔情報をターゲット人物に合わせて個人化する stage2 がある. また, 顔の外観を expression・lighting・pose の 3 つのパラメータに従って編集するために, 人物画像を DECA に入力することで得る FLAME のレンダリング結果を拡散モデルの条件として用いる. これにより, 顔のジオメトリが荒いことによる表現力不足や, 髪型やアクセサリなどの顔に直接関係のない外観をモデル化できないという FLAME の課題を, 拡散モデルがもつ高い表現力で補いながら, FLAME が持つ物理特性に従った自然な外観編集を行うことができる.




図 8. DiffusionRig のアーキテクチャ[5]

8. 参考文献

[1]

```
@article{FLAME:SiggraphAsia2017,
  title = {Learning a model of facial shape and expression from {4D} scans},
  author = {Li, Tianye and Bolkart, Timo and Black, Michael. J. and Li, Hao and Romero,
Javier},
  journal = {ACM Transactions on Graphics, (Proc. SIGGRAPH Asia)},
  volume = {36},
  number = {6},
  year = {2017},
  pages = {194:1--194:17},
  url = {https://doi.org/10.1145/3130800.3130813}
}
```

[2]

```
@inproceedings{giebenhain2023nphm,
  author={Simon Giebenhain and Tobias Kirschstein and Markos Georgopoulos and Martin
R{¥"}{u}nz and Lourdes Agapito and Matthias Nie{¥ss}ner},
  title={Learning Neural Parametric Head Models},
  booktitle = {Proc. IEEE Conf. on Computer Vision and Pattern Recognition (CVPR)},
  year = {2023}}
```

[3]

```
@inproceedings{DECA:Siggraph2021,
  title={Learning an Animatable Detailed {3D} Face Model from In-The-Wild Images},
  author={Feng, Yao and Feng, Haiwen and Black, Michael J. and Bolkart, Timo},
  journal = {ACM Transactions on Graphics, (Proc. SIGGRAPH)},
  volume = {40},
  number = {8},
  year = {2021},
  url = {https://doi.org/10.1145/3450626.3459936}
}
```

[4]

```
@inproceedings{EMOCA:CVPR:2021,
  title = {{EMOCA}: {E}motion Driven Monocular Face Capture and Animation},
  author = {Danecek, Radek and Black, Michael J. and Bolkart, Timo},
  booktitle = {Conference on Computer Vision and Pattern Recognition (CVPR)},
  pages = {20311--20322},
  year = {2022}
}
```

[5]

```
@misc{ding2023diffusionriglearningpersonalizedpriors,
  title={DiffusionRig: Learning Personalized Priors for Facial Appearance Editing},
  author={Zheng Ding and Xuaner Zhang and Zhihao Xia and Lars Jebe and Zhuowen Tu
and Xiuming Zhang},
  year={2023},
  eprint={2304.06711},
  archivePrefix={arXiv},
  primaryClass={cs.CV},
  url={https://arxiv.org/abs/2304.06711},
}
```

[6]

```
@misc{wagner2024cagecircumplexaffectguided,
  title={CAGE: Circumplex Affect Guided Expression Inference},
  author={Niklas Wagner and Felix Mätzler and Samed R. Vossberg and Helen Schneider
and Svetlana Pavlitska and J. Marius Zöllner},
  year={2024},
  eprint={2404.14975},
  archivePrefix={arXiv},
  primaryClass={cs.CV},
  url={https://arxiv.org/abs/2404.14975},
}
```

[7]

```
@misc{giebenhain2024mononphmdynamicheadreconstruction,
  title={MonoNPHM: Dynamic Head Reconstruction from Monocular Videos},
  author={Simon Giebenhain and Tobias Kirschstein and Markos Georgopoulos and Martin
Rünz and Lourdes Agapito and Matthias Nießner},
  year={2024},
  eprint={2312.06740},
  archivePrefix={arXiv},
  primaryClass={cs.CV},
  url={https://arxiv.org/abs/2312.06740},
}
```

3. 研究方法と現在の進捗状況

研究方法

本研究では，DiffusionRig をベースとしながら，より感情再現性と表情の豊かさを高めた DiffusionRig-Emo の開発を目指す．具体的には，DiffusionRig のアーキテクチャ中にある DECA を EMOCA に置換したり，表情専用の損失やエンコーダを導入したり，学習データセットを変更したり，NPHM による物理条件を追加することで歯や髪の実現力を上げたりする．また，DiffusionRig と DiffusionRig-Emo の表情に関する性能差を明確にする評価指標の開発も同時に目指す．

進捗状況

現在までに行ったことを記述する．

0. 3DMM や拡散モデルに関する論文調査
1. DiffusionRig をローカル環境で実装

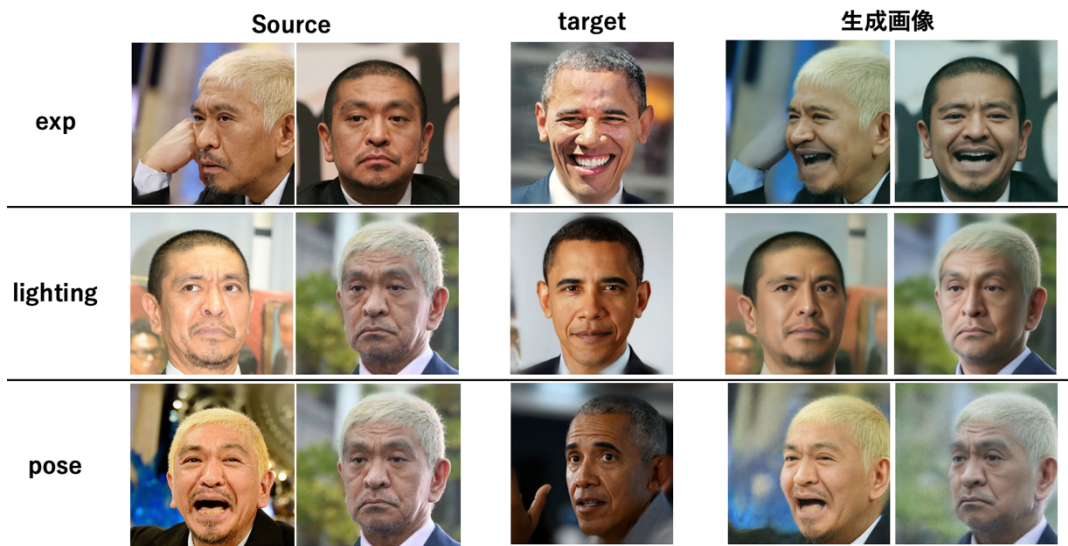


図 9. ローカル環境での DiffusionRig による編集結果

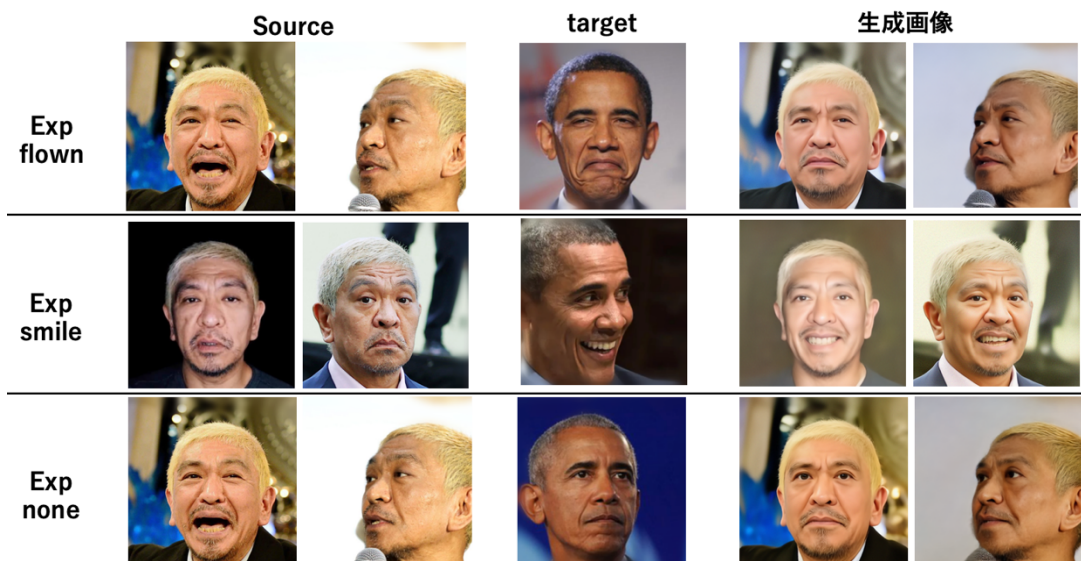


図 10. ローカル環境での DiffusionRig による編集結果(表情)

2. DECA を EMOCA に置換した DiffusionRig-Emo (v1.0) を開発




図 11. DiffusionRig-Emo (v1.0) のアーキテクチャ

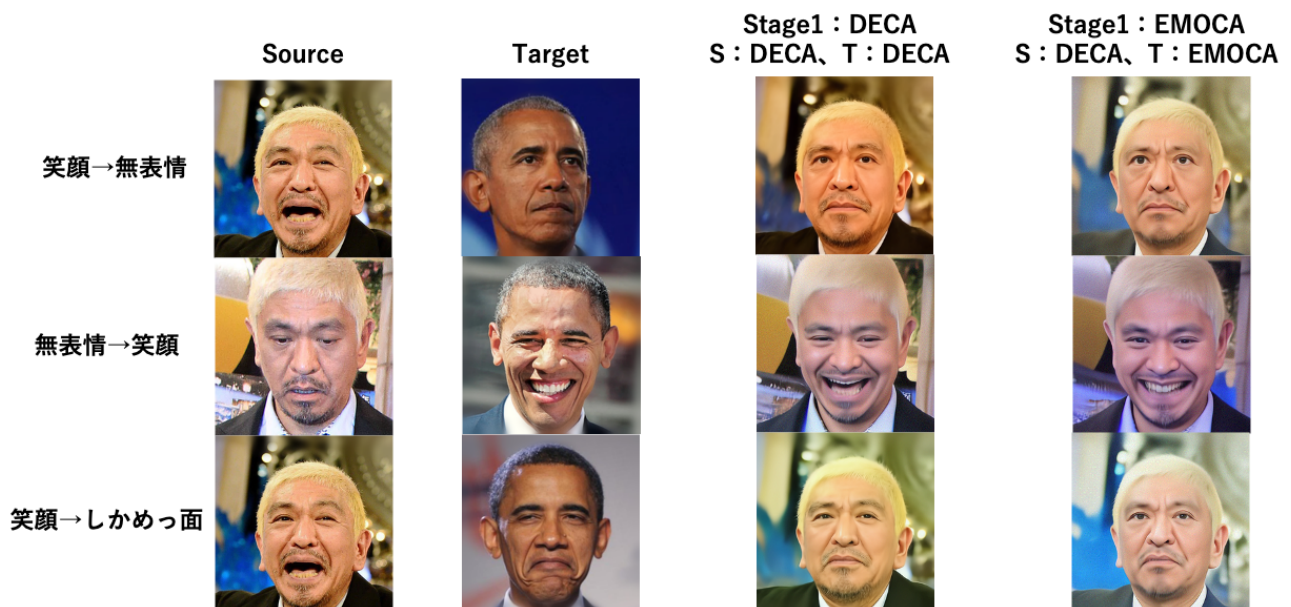


図 12. DiffusionRig と DiffusionRig-Emo (v1.0) の比較

3. EmoNet による DiffusionRig と DiffusionRig-Emo を評価


表 2. 評価対象モデル

データセット	Stage1 stage2	resnet	target expパラ	source expパラ	評価対象 モデル
FFHQ or AffectNet	DECA or EMOCA	18 or 50	DECA or EMOCA	DECA or EMOCA	32種類

● Source 画像と Target 画像間の Valence 比較

AffectNet および従来の FFHQ データセットを訓練データとして用いた場合のモデル性能を評価するため、16 種類の異なるモデルに対して EMOCA による感情推定を行なった。評価指標として、オバマ大統領の表情をソース画像に転送した際の Arousal の差分を算出した。理論的には、ターゲット画像の表情が正確に転送されている場合、Valence 値の差はゼロに収束することが期待される。したがって、表 3 に示す各モデルの Valence 差分が小さいほど、表情転送の精度が高いことを示す指標となる。なお、ここでは性能が上位に位置する Top-5 のモデルのみを示す。

表 3. EmoNet による評価結果 (Valence)



以上の結果から次の考察が得られる。


- AffectNet で訓練した方が Valence の差が小さい。
- 訓練時の物理条件を付与するモデルとして、EMOCA の方が適している。
- 顔以外の特徴を保持する ResNet は 18 と 50 は、訓練時間とのトレードオフで選択すべき。
- 推論時にターゲット人物の特徴を抽出するモデルは EMOCA、ソース人物の特徴を抽出するモデルは DECA を選択すべき

● Source 画像と Target 画像間の Arousal


Arousal による評価でも差分が小さいほど、表情転送の精度が高いことを示す指標となる。

表 4. EmoNet による評価 (Arousal)

AffectNet



FFHQ



以上の結果から次の考察が得られる。

- A) AffectNet で訓練した方が Arousal の差が小さい。
- B) 訓練時の物理条件を付与するモデルとして、EMOCA の方が適している。
- C) 顔以外の特徴を保持する ResNet は、18 の方が高性能である場合が多い。
- D) 推論時にターゲット人物の特徴を抽出するモデルは EMOCA、ソース人物の特徴を抽出するモデルは DECA を選択すべき
- E) 快-不快を示す Valence より、覚醒度を示す arousal の方が良い精度で再現できている


4. MaxViT による DiffusionRig と DiffusionRig-Emo を評価

● Source 画像と Target 画像間の Valence 比較


各モデルの出力画像とターゲット画像を感情推定モデルに入力し、出力された valence 値と arousal 値を比較する実験を、感情推定モデルを EmoNet から CAGE フレームワークに MaxViT を組み合わせたモデルに変更して再度行った。

表 5. MaxViT による評価(valence)

affectnet_valence



FFHQ_valence




Valence 値に関しては、EmoNet を用いた実験と同様の傾向が見られたため、改めて DiffusionRig のアーキテクチャに Emoca を含めることの優位性が明らかになった。


● Source 画像と Target 画像間の Arousal

表 6. MaxViT による評価 (arousal)

affectnet_arousal



FFHQ_arousal



Arousal の比較では、トレーニングの際に使用するモデルとして EMOCA の方が適しているという結論に変わりないが、ターゲット人物の特徴を抽出するモデルとして DECA、ソース人物の特徴を抽出するモデルとして EMOCA を使用した方が、感情の再現性が向上するという結果になり、これは EmoNet を用いた場合の評価と真逆の結果である。現時点ではなぜこのような結果が得られたのか不明である。Valence と arousal に対する再現度は、EmoNet を用いた実験と同様に arousal がより良い精度を示している。

5. アイデンティティ保持性の評価

DiffusionRig による表情編集を経ても、個人のアイデンティティを保っているかどうかを評価する実験を行った。ソース画像と編集画像を FaceNet に入力することで、人物画像を顔に注目した特徴ベクトルに変換し、2 つのベクトルのコサイン類似度を計算した。よって、1 に近いほどアイデンティティが保持できていることを示す。

表 7. 各モデルのコサイン類似度



以上の結果から次の考察が得られる。

- A) AffectNet で訓練した方がアイデンティティの損失が少ない。
- B) アイデンティティの保持を優先する場合、人物の顔特徴を抽出するモデルとして DECA を使用するべきである。
- C) ResNet に関しては他の評価指標と同様に、訓練時間とのトレードオフ関係に留意しながら決定するべきである。

4. 2025 年の研究計画とスケジュール

研究計画

- DiffusionRig=Emo (v1.0) の複数 GPU による分散学習をサポート
- DECA から EMOCA に置換したことによる性能差の提示, 及び感情に関する独自の評価指標の開発
- NPHM によるレンダリング結果を拡散モデルの物理条件に追加 (monoNPHM の実装)
- GitHub 及びアプリ実装により外部公開予定

スケジュール

