

2025年度 修士論文

3D アバターの自然な表情編集に関する研究

指導教員 史 又華, 柳澤 政生 教授

早稲田大学大学院 基幹理工学研究科

電子物理システム学専攻

5124D004

石黒 将太郎

Shotaro Ishiguro

2026年2月

目次

第1章 序論	3
1.1 本論文の研究背景と研究目的	4
1.2 本論文の構成	7
第2章 関連研究	8
2.1 本章の概要	9
2.2 3DMM と FLAME	10
2.3 NPHM	13
2.4 DECA と EMOCA	15
2.5 DiffusionRig	19
2.6 本章のまとめ	23
第3章 DiffusionRig-Emo(v1)	24
3.1 本章の概要	25
3.2 DiffusionRig-Emo(v1) の概要	26
3.3 3D-Face の表情編集に関する評価指標	28
3.4 実験概要	31
3.5 実験結果と評価・考察	33
3.5.1 定性評価	33
3.5.2 表情編集忠実度	33
3.5.3 アイデンティティ保持度	36
3.5.4 DiffusionRig-Emo(v1) に対する結論	37
3.6 本章のまとめ	38

第4章 DiffusionRig-Emo(v2)	39
4.1 本章の概要	40
4.2 DiffusionRig-Emo(v2) の概要	41
4.3 実験概要	43
4.4 実験結果と評価・考察	45
4.4.1 定性評価	45
4.4.2 表情編集忠実度	45
4.4.3 アイデンティティ保持度	47
4.4.4 DiffusionRig-Emo(v2) に対する結論	48
4.5 本章のまとめ	51
第5章 DiffusionRig-Emo のクラウド環境における実証と性能評価	52
5.1 本章の概要	53
5.2 DiffusionRig-Emo アプリと実験概要	54
5.3 実験結果と考察	56
5.4 本章のまとめ	59
第6章 結論	60
謝辞	63
参考文献	64

第1章

序論

1.1 本論文の研究背景と研究目的

近年、人工知能 (AI)、特に機械学習の分野で多くの技術革新が起きたことで、人工知能の技術が応用された製品やサービスがより身近な存在となっている。機械学習とは、機械に大量のデータを複数回読み込ませることで、データに含まれるパターンを見つけたり、データから物事を判断するように学習させることである。また、機械学習を発展させた手法である Deep Learning は、人間や動物の神経細胞 (ニューロン) の仕組みを模した Neural Network をベースとした Deep Neural Network によって実現される。

画像生成は、Deep Learning 技術を画像に応用する研究分野の一つである。本技術は、大量の学習画像データに基づき、利用者の指示に従って新規画像を生成するものである。その活用例としては、画像のスタイル (画風や状況) 変換や、実在しない人物の顔生成等が挙げられる。

この画像生成を実現する主要な技術として、GAN (Generative Adversarial Network)[1] と拡散モデル [2] が存在する。GAN は、二種類のネットワークを競合的に学習させる敵対的損失を用いることにより、高品質な画像を生成可能である。一方、拡散モデルは、学習画像データセットに正規分布ノイズを付与し、そのノイズを段階的に除去する過程 (デノイジング) をネットワークが学習することで、任意のノイズから高品質な画像を生成する。

両アーキテクチャはそれぞれ利点と欠点を有する。GAN は、拡散モデルと比較して画像生成が高速であり、技術的確立が早期であったため実装が容易であるという利点を持つが、GAN 特有の生成器と識別器の競合的学習は不安定になり易く、ハイパーパラメータの調整が困難であるという欠点がある。拡散モデルは、学習プロセスが安定しており、アルゴリズムの特性上モード崩壊 (生成結果の多様性欠如) が発生しにくいという利点を持つが、計算量が大きく生成速度が遅いという欠点がある。以上の特性により、拡散モデルは GAN と比較して多様な画像を生成することが可能である。また、近年では、画像を拡散モデルへ入力する前に VAE (変分オートエンコーダ) [3] のエンコーダを用いて画像の解像度を低減することにより、ノイズ付与・除去の効率化を実現し、計算量を大幅に改善した Latent Diffusion Model (LDM)[4] が開発された。現在の商用画像生成サービスの多くは、

LDM から派生した Stable-Diffusion ベースの AI モデル [5] を採用している。




図 1.1: GAN と拡散モデルの生成画像の比較 [6].

近年, AR (拡張現実) や VR (仮想現実) デバイスの普及に伴い, 3D 空間における生成 AI モデルの需要が高まっている. 3D 空間上で実在感のある人間 (デジタルヒューマン) を再現する技術は, ゲームや映画における没入感の向上や, 非言語的な情報伝達性の強化に寄与する. これらの背景から, 生成 AI モデルの主要タスクの一つとして, 一枚の 2D 画像から 3D 頭部を復元する 3D-Face Reconstruction (3次元顔再構成) に関する研究が活発に行われている.

人間の顔を 3D 空間で表現しつつ, その人固有のアイデンティティ, 表情, 顔の向き等をパラメトリックに操作する技術である 3D Morphable Model (3DMM) や, 任意の光線上に存在する点群の密度 (存在確率) によって 3D 空間を表現する Neural Radiance Fields (NeRF) [7] 等, ニューラルネットワークによる 3D 空間表現技術が進展している. これらの技術と前述の深層学習手法の発展が組み合わさることで, 頭部の向き, 照明条件, カメラ視点, そしてアイデンティティを忠実に再現したデジタルヒューマンの 3D 空間表現が可能となった.

しかし, 既存技術には依然として複数の課題が残存する. アーキテクチャ上の制約や計算資源の不足により, 高密度な点群をそのまま用いた 3D-Face Reconstruction は困難である. また, 口内, 眼球, 髪, 装飾品等の詳細な顔要素の再現性不足も指摘されている. さらに, 表情をパラメトリックに操作する過程で, 個人のアイデンティティが失われる, 不自然な表情が生成される, あるいは利用者が指示した感情とデジタルヒューマンの表情が一致しないといった, 表情再現性と制御性に関する問題も顕著である.

本研究では, 以上の 3D-Face Reconstruction における課題の解決を主目的とし, そのアプローチとして DiffusionRig のアーキテクチャを拡張・改良する手法を提案する. DiffusionRig は, ある人物の 2D 画像を入力とし, その人物固有のアイデ

ンティティと髪や背景等の顔以外の特徴を保持しつつ、顔の向き、表情、照明条件を独立して操作可能なモデルである。本研究ではこのモデルに対し一部変更を加えることで、より表情豊かで、指定された感情との一致度 (以下、表情編集忠実度) が高い表情を持つデジタルヒューマンを生成する「DiffusionRig-Emo」の開発を目指す。この研究を通じて、DiffusionRig の拡張性・実用性を向上させるとともに、3D アバターの表情再現性向上によるエンターテインメント分野への応用可能性を示す。

1.2 本論文の構成

本論文では、拡散モデルと FLAME パラメータを用いることで人物の 3D 一貫性とアイデンティティを保持しながら表情編集を行う既存手法について、ベースラインモデルである DiffusionRig の改良モデルの実行結果、考察及び改良モデルの実用可能性について述べる。本論文は 6 章で構成される。以下に各章の概要を示す。

第 2 章「**関連研究**」では、2D 画像から 3D 頭部の復元を行う既存モデルと、本研究のベースラインについて述べる。

第 3 章「**DiffusionRig-Emo(v1)**」では、本研究の提案モデルの一つである DiffusionRig-Emo(v1) について述べ、本論文における提案モデルの性能評価に用いる評価指標について述べる。さらに、本研究で行った実験とその結果について述べた後、DiffusionRig-Emo(v1) を用いて行った 3D-Face の表情編集に対する評価と考察を述べる。

第 4 章「**DiffusionRig-Emo(v2)**」では、本研究の提案モデルの一つであり、DiffusionRig-Emo(v1) の後継モデルである DiffusionRig-Emo(v2) について述べる。さらに、本研究で行った実験とその結果について述べた後、DiffusionRig-Emo(v2) を用いて行った 3D-Face の表情編集に対する評価と考察を述べる。

第 5 章「**DiffusionRig-Emo の実用化**」では、提案モデルの実用化に向けて DiffusionRig-Emo のアプリ化を行った結果について述べた後、DiffusionRig-Emo の実用化に対する考察を述べる。

第 6 章「**結論**」では、本論文を総括し、今後の課題について述べる。

第2章

関連研究

2.1 本章の概要

本節では、2D 画像の顔から 3D 頭部の予測と再構築に関連する研究と、本研究のベースラインである DiffusionRig について述べる。

2.2 節「3DMM と FLAME」では、3D-Face を扱う際の統計的手法である 3DMM と、その高機能モデルである FLAME について述べる。

2.3 節「NPHM」では、ニューラルネットワークを用いて 3D-Face を表現する手法である NPHM について述べる。

2.4 節「DECA と EMOCA」では、FLAME を利用して 2D 画像から 3D-Face を復元する DECA と、その後継モデルである EMOCA のアーキテクチャと特徴について述べ、それぞれの違いについて説明する。

2.5 節「DiffusionRig」では、本研究のベースラインモデルである DiffusionRig について述べる。

2.6 節「本章のまとめ」では、本章のまとめについて述べる。

2.2 3DMM と FLAME

3DMM (3D Morphable Model)[8] は, 3D 顔モデルを生成するための統計的技術である. 1999 年に提案されたこの手法は, 形状基底とテクスチャ基底の線形結合により顔モデルを表現する. これら二種類の基底は, 予めトポロジー (頂点接続情報) が統一された 3D 顔メッシュのデータセットに対し, 主成分分析 (PCA) [9] を適用することで抽出される.




図 2.1: 3DMM を用いた場合と用いなかった場合の再構成結果 [10].

3DMM は, 事前に定義された形状とテクスチャの基底を用い, PCA によって構築された低次元のパラメータ空間内で顔の形状やテクスチャを表現する. この特性により, 顔の年齢や表情といった属性をパラメトリックに操作することが可能である. また, 高次元の顔データを PCA により圧縮するため, 顔モデルの計算コストを削減可能である. さらに, 生成される顔モデルはトポロジーの一貫性を有するため, 特定の顔領域 (目, 鼻, 口等) の局所的な編集や, 他者との顔特徴の置換, 装飾品や髪型の追加といった操作が容易である.

一方で, 3DMM にはいくつかの制約も存在する. 事前に設定される基底は, 構築に用いたデータセットに強く依存するため, データセットの人種や年齢構成の偏りから影響を受けやすい. また, 基底の線形結合でモデルを表現する構造上, 複雑な顔の変形や非線形な特徴を十分に表現することが困難である. さらに, 顔以

外の個人のアイデンティティを構成する要素 (例: 髪型, 瞳の詳細) は 3DMM のモデル化対象外であるため, これらの要素を繊細に表現することはできない.

3DMM の基本的な枠組みを継承しつつ, その表現力と制御性を大幅に向上させたモデルとして FLAME (Faces Learned with an Articulated Model and Expressions)[11] が提案されている. FLAME は, 従来の 3DMM と比較して大規模な (数万スキャン) データセットから学習されており, 顔の「動き」に関するモデリングに重点を置いている点が最大の特徴である.




図 2.2: FLAME モデルを用いた 3D 頭部の例 [11].

3DMM が主にアイデンティティ (個人の顔形状) の線形モデル化に焦点を当てていたのに対し, FLAME はモデルを以下の三種類の独立したパラメータ空間に明示的に分離している.

1. 形状 (Identity Shape): 3DMM と同様に, 個人の基本的な顔形状を定義するパラメータ.
2. 表情 (Expression): アイデンティティとは独立して, 笑顔や驚きといった表情の変化を制御する線形ブレンドシェイプのパラメータ.
3. 姿勢 (Pose): 頭部全体の回転に加え, 3DMM では考慮されていなかった顎の開閉, 眼球の回転, 首の動きといった「関節 (Articulation)」の動きを制御するパラメータ.

特に, FLAME は姿勢依存の補正 (Pose-dependent correctives) を導入している. これは, 例えば首を傾けたり顎を開いたりする際に生じる, 皮膚の自然で非線形

な変形 (首筋の筋肉の動き等) をリアルに再現するための補正項であり, 3DMM の線形結合のみでは困難だった動的な表現を可能にしている.

また, モデル化の範囲も従来の顔正面を中心とした 3DMM とは異なり, 首, 耳, 後頭部を含む頭部全体をカバーしている. 以上の特性から, FLAME は軽量のパラメトリックモデルでありながら, 会話時の頭部運動や微細な表情変化といった動的なモデリングにおいて, 従来の 3DMM を凌駕する表現力と制御性を備えている. そのため, 近年の 3D Face Reconstruction における基盤モデルとして広く採用されるに至っている.

2.3 NPHM

3DMM や FLAME は、PCA や線形ブレンドシェイプといった線形モデルを基盤としているため、パラメータの制御が容易である一方、その表現力は線形空間の範囲内に制限されるという制約があった。この線形性の制約を超え、より忠実に詳細な頭部モデルを実現するために、近年ではニューラルネットワークの表現力を活用するアプローチが登場している。

その代表例が NPHM (Neural Parametric Head Models)[12] である。NPHM は、従来の固定された基底ベクトル群 (Basis) の代わりに、ニューラルネットワーク (デコーダ) と潜在変数 (Latent Code) を用いて 3D 頭部モデルを表現する。




図 2.3: NPHM のアーキテクチャ[12].

具体的には、図 2.3 に示すように、個人のアイデンティティや表情に対応する低次元の潜在コード (z^{id} や z^{ex}) をパラメータとして持つ。これらのコードがニューラルデコーダ (MLP: 多層パーセプトロン等) に入力されると、デコーダは入力されたコードを解釈し、対応する 3D メッシュの頂点座標、あるいは SDF (符号付き距離関数) のような暗黙的表現を非線形に生成する。

このアーキテクチャにより、NPHM は非線形な顔の変形を効果的にモデル化可能になった。NPHM による出力例を示す図 2.4 では、(横軸) 異なるアイデンティティ (個性) を生成しつつ、(縦軸の) 一貫した表情の変化を適用できていることがわかる。特に、FLAME の線形モデルでは捉えきれなかった、表情変化に伴う微細なシワの形成、個性的な顔貌 (線形空間から外れた形状)、あるいは人種や性別による微妙な形態的差異等をより高い忠実度で再現することが可能となる。




図 2.4: NPHM の出力例 [12].

一方で、NPHMはFLAMEに対して劣る点も存在する。最大の課題は計算コストである。FLAMEが比較的軽量の線形結合(行列演算)でメッシュを生成可能であることに対し、NPHMはメッシュを生成するたびにニューラルネットワークの推論(順伝播計算)を実行する必要がある。そのため、特にリアルタイム性が厳しく要求されるアプリケーションにおいては、FLAMEに比べて計算負荷が高くなるという欠点を持つ。

NPHMは、パラメトリックモデルの持つ「制御性」と、ニューラルネットワークの持つ「高い表現力」を高次元で両立させることを目指した、次世代の頭部モデル技術として位置づけられる。

2.4 DECA と EMOCA

DECA[13] と EMOCA[14] は、いずれも 2D 顔画像から 3D 顔モデルを再構成するモデルであり、再構成過程において 3DMM ベースの統計モデルである FLAME[11] を利用する。EMOCA は DECA の発展モデルであるため、本節では主に DECA のアーキテクチャについて述べる。




図 2.5: DECA の出力例 [13].

DECA (図 2.6) は、FLAME を構成するための六種類のパラメータ (identity shape, expression, pose, texture, lighting, camera) と、表面の凹凸を制御する detail パラメータを推定するエンコーダ群及び 3D 顔モデルを 2D 画像にレンダリ




図 2.6: DECA のアーキテクチャ [13].

ングするネットワークから構成される．また，学習戦略として，大局的な顔形状を学習する coarse stage と，表面の凹凸や皺等の詳細な特徴を学習する detail stage の二段階に分け，それぞれに最適化された損失関数を設定することで，FLAME の基本的な表現力を補完している．




図 2.7: EMOCA の出力例 [14].

EMOCA (図 2.8) は，DECA をベースとしつつ，生成される 3D 顔モデルの「表情の豊かさ」に着目して改良されたモデルである．EMOCA は，DECA の内部で定義されている損失関数に加え，新たに「感情知覚損失 (perceptual emotion loss)」を導入した．この損失は，生成した 3D 顔モデルのレンダリング画像と入力画像を，それぞれ感情認識ネットワークに入力して得られる特徴量の差分として計算




図 2.8: EMOCA のアーキテクチャ[14].

される．学習時は，この損失が最小化される方向（すなわち，入力画像と出力画像の知覚的感情が一致する方向）にパラメータが更新される．ここで用いられる感情認識ネットワークは，感情カテゴリと Valence/Arousal（快-不快/覚醒-鎮静）[15] がアノテーションされた AffectNet-DB [16] を用い，ResNet-50 [17] をバックボーンとして事前学習されたモデルである．

図 2.9 に両モデルの出力結果の比較を示す．この比較から，Valence/Arousal の絶対値が大きい，すなわち激しい表情において，EMOCA が入力画像の感情をより忠実に再現していることが確認可能である．



図 2.9: DECA と EMOCA の比較結果 [14].

DECA は, FLAME パラメータと詳細 (Detail) パラメータを 2D 画像から頑健に推定する二段階の学習戦略を確立した. EMOCA は, この DECA の枠組みを踏襲しつつ, 感情知覚損失という新たなアプローチを導入することで, 特に再構成される顔の表情忠実度を大幅に向上させた発展モデルである. 両者は, FLAME という強力な統計モデルを基盤に, 2D 画像からの 3D-Face Reconstruction タスクの精度を向上させる上で重要な貢献を果たしている.

2.5 DiffusionRig

DiffusionRig[18] は、2023 年に Adobe より発表された 2D 顔編集モデルである。本モデルは、約 20 枚程度の同一人物のポートレート写真から、その人物特有の顔特徴を学習 (個人化) する。学習後、入力画像のアイデンティティを保持したまま、顔の表情 (Expression) ・照明 (Lighting) ・向き (Pose) を編集した画像を生成することが可能である。




図 2.10: DiffusionRig による編集例 [18].

学習プロセスは2段階で構成される。Stage1では、大規模な2D顔画像データセット (FFHQ[19]) を用いて、一般的な顔特徴を学習する。続く Stage2 では、Target 人物の少数の写真 (約 20 枚) を用い、Stage1 で学習した汎用的な顔情報を Target 人物に特化させる (個人化する)。

DiffusionRig の最大の特徴は、顔の外観編集 (表情・照明・向き) の条件付けに、DECA を用いて抽出した FLAME パラメータを利用する点にある。顔の主要3要素 (Expression, Lighting, Pose) をパラメトリックな表現に置換することで、外観編集に適した情報を提供する FLAME のパラメータを拡散モデルの条件として入力する。この設計により、FLAME の課題であった「顔のジオメトリが粗いことによる表現力不足」や「髪型や装飾品等の顔以外の外観をモデル化できない点」を、拡散モデルが持つ高い画像生成能力によって補完する。同時に、DECA が持つ物

理特性 (3D 一貫性) に従った自然な外観編集が可能となっている。




図 2.11: DiffusionRig のアーキテクチャ[18].

DiffusionRig のアーキテクチャを図 2.11 に示す．前述の通り，汎用的な顔特徴を学習する Stage1 と，Target 人物特有の特徴を学習する Stage2 に分離されている点及び拡散モデルへの条件付けに事前学習済みの DECA が用いられている点の確認可能である．また，FLAME ではモデル化されない髪，装飾品，眼鏡，背景等の大局的な外観情報 (グローバル特徴) をエンコードするために，別途「グローバルエンコーダ」が利用される．このエンコーダは Stage1 でのみ学習され，Stage2 (個人化) の際はその重みが固定される．

図 2.12 は，FLAME ベースの手法，他の GAN ベースの手法 (GIF[20], MyStyle[21])，と DiffusionRig (Ours) の編集結果を比較したものである．GIF との比較では，アイデンティティ保持度において DiffusionRig が明確な優位性を示している．MyStyle との比較では，両モデルともアイデンティティ保持は達成できているが，顔の物理特性 (DECA) を条件に持つ DiffusionRig は不自然なアーティファクトが少なく，自然な編集結果を生成している．対照的に，MyStyle は顔の向き的大幅な変更等，大きな変化を伴う編集に追従できていない様子が伺える．

図 2.13 は，DECA (顔の物理特性) とグローバルエンコーダ (髪や背景等の大局的特徴) の役割分担を視覚化したものである．本図は，異なる画像から DECA 由来の物理特性とグローバル特徴を組み合わせて画像を生成した結果を示している (左端の列が DECA のソース，最上段の行がグローバル特徴のソース)．図から明らかのように，出力画像の髪型，サングラス，背景等の DECA がモデル化できない特徴は上段の画像に準じ，顔の向きや表情は左端列の画像に準じている．この結果は，DECA とグローバルエンコーダの役割が明確に分離されており，編集対




図 2.12: DECA と他モデルとの比較結果 [18].

象である Expression, Lighting, Pose は DECA からの条件に基づき制御されていることを強く示唆している。

図 2.14 は、この 2 段階の学習プロセス (Stage1 と Stage2) の効果を視覚的に示したものである。Stage1 のモデル (汎用的な顔特徴のみを学習) では、入力画像 (Input) の人物のアイデンティティを正確に再構成できていない (Stage 1・Sample 1, 2)。一方、Stage2 で少数の個人写真 (約 20 枚) を用いてファインチューニング (個人化) を行ったモデルでは、入力画像のアイデンティティと詳細な特徴を忠実に再現できていることがわかる (Stage 2・Sample 1, 2)。

以上の通り、DiffusionRig は DECA から抽出した FLAME パラメータを拡散モデルへの条件付けに用いる点と、二段階の学習プロセス (特に Stage2 の個人化) を経ることで、高いアイデンティティ保持度と 3D 一貫性を両立した高品質な顔編集を実現した。一方で、その表情編集の性能や多様性は、条件付けに用いる DECA 由来の FLAME パラメータが持つ表情空間の表現力に依存する側面がある。後述する本研究の提案モデルは、この DiffusionRig の優れた枠組みをベースとしながら、表情編集忠実度、表情の多様性及びアイデンティティ保持度をさらに向上さ



図 2.13: DECA とグローバルエンコーダの役割 [18].



図 2.14: DiffusionRig の 2 段階学習 (個人化) の効果 [18].

せることを目的とし，条件付けに用いる FLAME パラメータや学習データセットの改良を試みたモデルである．

2.6 本章のまとめ

本章では、2D 画像からの 3D-Face Reconstruction に関連する主要な既存モデルについて概観した。

まず、3D 顔モデルの基礎的な統計的手法である 3DMM について述べ、PCA に基づく線形基底により顔形状とテクスチャを表現する枠組みを示した。次に、3DMM を発展させ、アイデンティティ、表情及び関節（首、顎）の動きを分離して扱う高機能な頭部モデルである FLAME について解説した。FLAME は、その高い制御性と表現力から、現在の 3D-Face Reconstruction タスクにおける基盤モデルとなっていることを確認した。

次に、FLAME が持つ線形モデルの表現力の限界を超える試みとして、ニューラルネットワーク（デコーダ）を用いて非線形な顔の変形や微細な特徴を高忠実度に捉える次世代モデル NPHM を紹介した。

続けて、これらの 3D 頭部表現モデル（FLAME 等）を実際に 2D 画像から復元するための具体的な手法として、DECA とその発展モデルである EMOCA を取り上げた。DECA が Coarse-to-Detail 戦略により 3D 一貫性を維持した再構成を実現する一方、EMOCA は感情知覚損失を導入することで、特に復元される顔の表情の忠実度を大幅に改善したモデルであることを示した。

最後に、ベースラインモデルとして DiffusionRig を取り上げた。DiffusionRig は、拡散モデルの高い生成能力と、DECA 由来の FLAME パラメータが持つ 3D 顔に対する高い制御性を組み合わせた 2D 顔編集モデルである。特に、2 段階の学習プロセス（汎用学習と個人化）を経ることで、高いアイデンティティ保持度と 3D 一貫性を両立した高品質な編集を実現する、本研究の目的に適した強力なベースラインであることを確認した。

本章で概説したこれらのモデル群は、3D-Face Reconstruction 技術の変遷と根幹を成すものであり、本研究はこれらの知見と課題を基盤として構築される。

第3章

DiffusionRig-Emo(v1)

3.1 本章の概要

本章では、本研究のベースラインモデルである DiffusionRig に改良を加えた DiffusionRig-Emo(v1) の概要と、本研究の提案モデルベースラインモデルの比較に使用した評価指標について述べる。また、DiffusionRig-Emo(v1) とベースラインモデルの比較実験の結果について概説する。

3.2 節「DiffusionRig-Emo(v1) の概要」では、本研究における第一の提案モデル DiffusionRig-Emo(v1) のアーキテクチャについて述べる。

3.3 節「3D-Face の表情編集に関する評価指標」では、DiffusionRig を提案している論文中で述べられている評価指標と、本研究で使用する評価指標について述べる。

3.4 節「実験概要」では、DiffusionRig-Emo(v1) の有効性を検証するために実施した実験の設計と評価方法について述べる。

3.5 節「実験結果と評価・考察」では、同実験によって得られた結果を示し、DiffusionRig-Emo(v1) とベースラインである DiffusionRig の比較から、それぞれのモデルを評価・考察する。最後に DiffusionRig-Emo(v1) に対する結論を述べる。

3.6 節「本章のまとめ」では、本章のまとめについて述べる。

3.2 DiffusionRig-Emo(v1) の概要

本研究における第一の提案モデルである DiffusionRig-Emo (v1) のアーキテクチャを、図 3.1, 3.2 に示す。

DiffusionRig-Emo (v1) は、ベースモデル (DiffusionRig) に対し、二個の主要な変更点を有する。第一の変更点として、アイデンティティや 3D 一貫性を保持するための拡散モデルへの条件付けモデルとして、従来の DECA に加え、EMOCA を選択可能とした (図 3.1 の右上部分)。第二の変更点として、Stage1 の大規模学習と Stage2 の個人化に用いるデータセットとして、従来の顔認識用データセット FFHQ[19] に加え、感情分類用データセット AffectNet[16] を選択可能とした (図 3.1 の左上部分)。

本改良の目的は、学習 (Stage1, Stage2) と推論時に使用する条件付けモデルと学習データセットを選択可能にすることにより、Source 画像のアイデンティティを保持しつつ、Target 画像と出力画像間における表情忠実度を高めることである。




図 3.1: DiffusionRig-Emo(v1) のアーキテクチャ (学習時)。




図 3.2: DiffusionRig-Emo(v1) のアーキテクチャ (推論時) .

3.3 3D-Faceの表情編集に関する評価指標

DiffusionRigの元論文[18]では、その性能を定量的に評価するため、主に二種類の指標が用いられている。第一の指標は「アイデンティティ保持度」である。これは、編集元画像と編集後画像のペアに対し、事前学習済みの顔認識モデル (Dlib-ml) [22] を用いて抽出した特徴量間のコサイン類似度を計算し、人物の同一性がどれだけ保持されているかを測定する評価指標である。第二の指標は「編集の忠実度」である。これは、編集指示として与えた目標の FLAME パラメータ (表情・向き) と、生成された画像から別途 FLAME フィッティングモデルを用いて再推定したパラメータとの間の L2 誤差 (Expr-Err, Pose-Err) として定義する評価指標である。

本研究では、ベースラインモデルである DiffusionRig と後述する提案モデルの性能をより客観的に比較するため、DiffusionRig の元論文で用いられた上記の評価指標を改良した指標を採用する。

「アイデンティティ保持度」の測定に関して、本研究では顔認識モデルを更新する。DiffusionRig の元論文で参照されている Dlib-ml はレガシーモデル (2009 年発表) であるため、本研究では、より後年に提案され、現在広く用いられている高精度な顔認識モデルである FaceNet[23] を採用する。具体的な評価方法として、編集元となる Source 画像と編集後の出力画像から、FaceNet を用いて顔特徴量をそれぞれ抽出し、両者間のコサイン類似度を計算する。この類似度が高いほど、アイデンティティ保持度が高いと評価する。これにより、元論文で実施された実験と比較して人物の同一性の保持をより高精度に評価可能である。

「編集の忠実度」に関しては、本研究は元論文とは異なるアプローチを採用する。元論文で用いられた 3DMM パラメータ空間での L2 誤差の測定は、二種類の潜在的な課題を有する。第一の課題は、生成モデル自身が利用する 3DMM パラメータ (FLAME 等) と、評価に用いる 3DMM パラメータが同一である場合、3DMM 特有のバイアスによって編集の忠実度を過剰に高く評価してしまう点である。第二の課題は、3DMM パラメータの誤差が、必ずしも人間の知覚的な表情の誤差と一致しない可能性がある点である。

そこで本研究は、3DMM パラメータ空間ではなく、画像から知覚される「感情」そのものに着目した評価指標を導入する．具体的には、人間の感情を「快・不快 (Valence)」と「覚醒・鎮静 (Arousal)」の二次元 (それぞれ $-1 \sim 1$) で表現する感情の円環モデル (図 3.3) を用いる．




図 3.3: Lassel の円環モデル [24].

評価プロセスでは、近年の高精度な感情推定モデルである CAGE[25] (2024 年発表) を利用する．表情編集の目標となる Target 画像と，編集後の出力画像それぞれに対し，CAGE を用いて Valence 値と Arousal 値を推定する．そして，両画像間で推定された Valence の差 (L2 誤差) と Arousal の差 (L2 誤差) を計算し，これらの誤差が小さいほど，目標画像の表情が忠実に再現されている，すなわち「表情編集忠実度」が高いと評価する．

以上をまとめると、本研究における定量評価では、「アイデンティティ保持度」の測定には FaceNet による特徴量のコサイン類似度を用い、「表情編集忠実度」の測定には CAGE による Valence と Arousal の推定値の L2 誤差を用いる。これらの指標により、元論文に残存していた評価上の課題を回避し、モデルの性能をより客観的かつ精緻に比較・分析する。

3.4 実験概要

DiffusionRig-Emo(v1) とベースラインモデルである DiffusionRig の性能を比較検証するために実施した実験の概要を述べる.

本実験の目的は、アーキテクチャへの変更、すなわち「拡散モデルへの条件付けモデル (DECA から EMOCA へ)」と「学習データセットの変更 (FFHQ から AffectNet へ)」が、Source 画像と出力画像間のアイデンティティ保持度と、Target 画像と出力画像間の表情編集忠実度に与える影響を定量的に評価することである.

本実験における評価対象モデルは、以下の5項目の組み合わせにより計32通りである. なお、大規模データセットに FFHQ を用い、全ての拡散モデルへの条件付けモデルに DECA を使用した場合が、DiffusionRig の構成に相当する. DiffusionRig の元論文と同様、グローバルエンコーダには ResNet18 と ResNet50 の双方を使用可能とし、本実験でもこの構成を踏襲する.

1. 大規模データセット: FFHQ or affectnet
2. Stage1,2 の条件付けモデル: DECA or EMOCA
3. target 人物の FLAME パラメータ: DECA or EMOCA
4. source 人物の FLAME パラメータ: DECA or EMOCA
5. グローバルエンコーダ: ResNet18 or ResNet50

評価指標として、本研究では 3.3 節で述べた二種類の指標を用いる. 第一に、Target 画像と出力画像間の表情編集忠実度を定量評価するため、両画像を感情推定モデル CAGE に入力して得られる Valence (快-不快) と Arousal (覚醒-鎮静) の差分 (絶対値) を算出する. 本評価では、この差分が小さいほど、表情編集忠実度が高いと定義する. 第二に、Source 画像と出力画像間のアイデンティティ保持度を定量評価するため、両画像を顔認識モデル FaceNet に入力して得られる顔特徴ベクトルのコサイン類似度を算出する. 本評価では、コサイン類似度が 1 に近いほど、アイデンティティ保持度が高いと定義する.

最後に、本実験の実装環境について述べる. 使用したフレームワークは Pytorch であり、これは DiffusionRig と共通である. 主要なハードウェア構成は以下の通

りである.

- OS: Windows 11
- CPU: Ryzen 7 5700X
- GPU: NVIDIA GeForce RTX 4070 Ti Super (VRAM 16GB)

3.5 実験結果と評価・考察

3.5.1 定性評価

DiffusionRig (ベースライン) と DiffusionRig-Emo (v1) の生成結果を比較したものを図 3.4 に示す. 定性的な評価では, DiffusionRig-Emo (v1) はベースラインと比較して表情の変化が大きく, Target 画像との表情編集忠実度も高い傾向が確認された.




図 3.4: DiffusionRig と DiffusionRig-Emo (v1) の比較結果.

3.5.2 表情編集忠実度

本節では, 表情編集忠実度の定量評価結果について述べる. 評価指標として, Target 画像中の人物の表情を Source 画像に転送した際の, 出力画像と Target 画像の Valence (快-不快) 値の差分 (絶対値) を算出した. 理論上, この差分が小さいほど, Target 画像の表情が正確に転送されている, すなわち表情編集忠実度が高いことを示唆する.

Valence 値の差分による評価結果を, 図 3.5 に示す. 本図は, 大規模データセット (AffectNet, FFHQ) ごとに, 性能上位 5 モデルの結果を抽出したものである.

図 3.5 に示す Valence 差分の評価結果から, 学習データセットに関しては AffectNet を用いた場合が, FFHQ を用いた場合と比較して一貫して高い性能 (低差分)




図 3.5: CAGE による評価結果 (base VS v1, Valence).

を示した。また、頭部以外の特徴を保持するグローバルエンコーダに関しては、ResNet18 を用いたモデルが高性能を示す場合が多かった。これは ResNet50 が過剰な表現能力を持つため、グローバルエンコーダが扱うべきでない顔特徴まで学習してしまったことが原因であると考察される。さらに、学習時の FLAME パラメータ推定器として EMOCA、推論時の FLAME パラメータ推定器の組み合わせとしては、Target 人物の特徴抽出に EMOCA を、Source 人物の特徴抽出に DECA を選択した場合に最も性能が高いことが示された。

次に、Arousal (覚醒-鎮静) 値の差分による評価結果を図 3.6 に示す。Valence と同様に、差分が小さいほど表情編集忠実度が高いことを示す。

図 3.6 に示す Arousal 差分の評価結果から、学習データセットと学習時の FLAME パラメータ推定器に関しては、Valence 評価と同様に AffectNet と EMOCA が適し




図 3.6: CAGE による評価結果 (base VS v1, Arousal).

ていることが確認された。一方で、推論時の FLAME パラメータ推定器の組み合わせに関しては、Valence 評価とは反対に Target 側で DECA, Source 側で EMOCA を選択する組み合わせが最適であった。また、頭部以外の特徴を保持するグローバルエンコーダ (ResNet18, ResNet50) の選択は性能への影響が比較的小さいため、訓練時間とのトレードオフ関係を考慮して決定すべきであることが示された。

最後に、Valence 差分と Arousal 差分の各指標における SOTA モデルの数値を比較したところ、Arousal の最小差分は 9.529 であったのに対し、Valence の最小差分は 21.186 であった。Arousal 差分が Valence 差分と比較して一貫して低い値を示した結果は、Lassel の円環モデルにおける感情の 2 次元空間において、比較対象モデルが縦軸の変化 (Arousal) をより捉えやすいことを示唆している。

3.5.3 アイデンティティ保持度

本節では，DiffusionRig-Emo (v1) による表情編集が，Source 画像と出力画像間のアイデンティティ保持度に与える影響を評価した実験結果について述べる．

評価手法として，Source 画像（編集前）と出力画像（編集後）を，顔認識モデル FaceNet に入力し，それぞれ顔特徴ベクトルを抽出した．それらのベクトル同士のコサイン類似度を算出し，これをアイデンティティ保持度の指標とした．この指標は，1に近いほどアイデンティティが保持されていることを示す．評価結果を図 3.7 に示す．




図 3.7: FaceNet による評価結果 (base VS v1, Identity).

図 3.7 に示すアイデンティティ保持度の評価結果から，学習データセットに関しては AffectNet を用いた場合が FFHQ を用いた場合と比較してアイデンティティの損失が少ない（類似度が高い）ことが示された．また，アイデンティティ保持を

優先する場合は、学習時と推論時 (Source 側) の顔特徴抽出モデルとして DECA を用いるべきであることが示された。さらに、顔以外の特徴を保持するグローバルエンコーダの選択に関しては、他の評価指標と同様に訓練時間とのトレードオフ関係を考慮して決定する必要があることが考察される。

3.5.4 DiffusionRig-Emo(v1) に対する結論

以上の実験結果は、他の人種や性別の人物画像を用いた実験においても同様の傾向が確認され、その結果以下の結論を導くことが可能である。

DiffusionRig-Emo (v1) におけるベースモデル (DiffusionRig) からの第一の改良点である「学習データセットの FFHQ から AffectNet への変更」は、個人のアイデンティティ情報の損失を抑制しつつ、Target 画像と出力画像間における表情編集忠実度を高めることに寄与した。

第二の改良点である「FLAME パラメータ推定器の DECA から EMOCA への変更 (選択)」に関しては、EMOCA が DECA の表情多様性を改良したモデルであるため、Target 画像と出力画像間の表情編集忠実度向上に寄与した。一方で、アイデンティティ保持度の低下が見られた。この原因として、Target 画像の表情を Source 画像に転送する際、Target 画像の表情に関する特徴量に含まれてしまったアイデンティティ情報も同時に転送される Identity Leakage (アイデンティティの漏洩) が発生した可能性が考えられる。

以上が DiffusionRig-Emo (v1) の結論である。v1 の研究により、アイデンティティ保持度と表情編集忠実度の間にはトレードオフ関係が存在することが示唆された。したがって、次期モデル DiffusionRig-Emo (v2) では、このトレードオフ関係の解決を主要な研究目的として設定した。

3.6 本章のまとめ

本章では、初めにベースラインモデルである DiffusionRig の表情編集忠実度向上を目的とした改良モデル、DiffusionRig-Emo(v1) について述べた。本モデルでは、主な改良点として「学習データセットの変更 (FFHQ から AffectNet へ)」と「拡散モデルへの条件付けモデルの変更 (DECA から EMOCA へ)」という二種類の選択肢を導入した。

次に、3D-Face の表情編集に関する評価指標について議論した。DiffusionRig の元論文で用いられた指標が持つ潜在的な課題 (レガシー顔認識モデルを用いることによる精度不足と FLAME パラメータ空間での評価バイアス) を考察した。その上で、本研究ではこれらの課題を回避し、より客観的かつ高精度な評価を行うため、二種類の改良指標を採用することを決定した。具体的には、「アイデンティティ保持度」の測定には高精度な顔認識モデルである FaceNet を用い、「表情編集忠実度」の測定には知覚的な感情空間 (Valence/Arousal) を扱う CAGE を用いる。ここで定義した評価指標は、本章と次章で扱う提案モデルの有効性を実証するための実験的基盤である。

実験による性能評価の結果、第一の改良点である AffectNet データセットの使用は、表情編集忠実度の向上とアイデンティティ保持度の改善の両方に寄与する有効なアプローチであることが確認された。一方で、第二の改良点である EMOCA の使用は、表情編集忠実度を向上させる効果があったが、同時にアイデンティティ保持度を低下させることが判明した。

本章の結論として、3.5.4 節で述べた通り、DiffusionRig-Emo(v1) の枠組みにおいては、表情編集忠実度とアイデンティティ保持度との間にトレードオフ関係が存在することが示唆された。このトレードオフ関係の解消が、次章で述べる DiffusionRig-Emo(v2) における主要な研究課題となる。

第4章

DiffusionRig-Emo(v2)

4.1 本章の概要

本章では、本研究のベースラインモデルである DiffusionRig に改良を加えた DiffusionRig-Emo(v2) の概要と、DiffusionRig-Emo(v1) との比較実験の結果について概説する。

4.2 節「**DiffusionRig-Emo(v2) の概要**」では、本研究における第二の提案モデル DiffusionRig-Emo(v2) のアーキテクチャについて述べる。

4.3 節「**実験概要**」では、DiffusionRig-Emo(v2) の有効性を検証するために実施した実験の設計と評価方法について述べる。

4.4 節「**実験結果と評価・考察**」では、同実験によって得られた結果を示し、DiffusionRig-Emo(v2) と DiffusionRig-Emo(v1) の比較から、それぞれのモデルを評価・考察する。最後に DiffusionRig-Emo(v2) に対する結論を述べる。

4.5 節「**本章のまとめ**」では、本章のまとめについて述べる。

4.2 DiffusionRig-Emo(v2) の概要

本研究における第二の提案モデルである DiffusionRig-Emo (v2) のアーキテクチャを、図 4.1, 4.2 に示す。

DiffusionRig-Emo (v2) は、v1 モデルに対し、アーキテクチャ内部に主要な変更点を有する。前提として、v1 モデルの実験結果に基づき、Stage1 の大規模学習に用いるデータセットは、表情編集忠実度・アイデンティティ保持度の両方で優位性が認められた AffectNet[16] に固定した。主要な変更点として、v1 で課題となったアイデンティティと表情のトレードオフ関係を解決するため、FLAME パラメータ推定器 (DECA/EMOCA) 由来の Identity shape と Expression パラメータを、拡散モデルに直接条件付けする経路を新たに追加した。




図 4.1: DiffusionRig-Emo(v2) のアーキテクチャ (学習時) .




図 4.2: DiffusionRig-Emo(v2) のアーキテクチャ (学習時) .

4.3 実験概要

DiffusionRig-Emo(v2) と v1 モデルの性能を比較検証するために実施した実験の概要を述べる.

本実験の目的は, v2 におけるアーキテクチャへの変更, すなわち「FLAME パラメータの拡散モデルへの直接条件付け」が, Source 画像と出力画像間のアイデンティティ保持度と, Target 画像と出力画像間の表情編集忠実度に与える影響 (トレードオフ関係の変化) を定量的に評価することである.

v1 モデルでの実験結果に基づき, 大規模データセットは AffectNet に固定した. したがって, 本実験における評価対象モデルは, DiffusionRig-Emo(v1) と DiffusionRig-Emo(v2) であり, それぞれ以下の 4 項目の組み合わせがあるため, 計 32 通りである.

1. Stage1,2 の条件付けモデル: DECA or EMOCA
2. target 人物の FLAME パラメータ: DECA or EMOCA
3. source 人物の FLAME パラメータ: DECA or EMOCA
4. グローバルエンコーダ: ResNet18 or ResNet50
5. FLAME パラメータの拡散モデルへの直接条件付けの有無

評価指標として, 本研究では 3.3 節で述べた二種類の指標を用いる. 第一に, Target 画像と出力画像間の表情編集忠実度を定量評価するため, 両画像を感情推定モデル CAGE に入力して得られる Valence (快-不快) と Arousal (覚醒-鎮静) の差分 (絶対値) を算出する. 本評価では, この差分が小さいほど, 表情編集忠実度が高いと定義する. 第二に, Source 画像と出力画像間のアイデンティティ保持度を定量評価するため, 両画像を顔認識モデル FaceNet に入力して得られる顔特徴ベクトルのコサイン類似度を算出する. 本評価では, コサイン類似度が 1 に近いほど, アイデンティティ保持度が高いと定義する.

最後に, 本実験の実装環境について述べる. 使用したフレームワークは Pytorch であり, これは DiffusionRig と共通である. 主要なハードウェア構成は以下の通りである.

- OS: Windows 11
- CPU: Ryzen 7 5700X
- GPU: NVIDIA GeForce RTX 4070 Ti Super (VRAM 16GB)

4.4 実験結果と評価・考察

4.4.1 定性評価

DiffusionRig-Emo の v1 モデルと v2 モデルの生成結果を比較したものを図 4.3 に示す.

定性的な評価では, Source 画像と出力画像におけるアイデンティティ保持度と, Target 画像と出力画像における表情編集忠実度について, v1 モデルと v2 モデルで明確な差は認められなかった. しかし, v2 モデルの出力画像では, Source 画像が持つ眉間の皺や毛穴等のディテールを含む詳細なテクスチャの表現度が高い傾向が見られた. 対照的に, v1 モデルの出力画像は平滑化された画風 (アニメ調) になる傾向が見られた.

また, Target 画像が持つ FLAME パラメータでは扱えない特徴量 (例: 口内の歯, 髪の毛の細部) に関する差が確認された. 具体的には, v1 モデルではこれらの特徴量が Target 画像にのみ存在し, Source 画像には存在しない場合においても表現されてしまう出力画像が存在したが, v2 モデルではそのような出力画像はほとんど確認されず, Source 画像本来の特徴を維持している場合が多かった.

以上の相違点は, v2 モデルのアーキテクチャ変更に起因すると考えられる. すなわち, v2 モデル内の拡散モデルが, v1 モデルでは扱えなかった DECA・EMOCA 由来のディテールに関する特徴量を直接扱えるようになった点と, Source 画像に関する DECA・EMOCA 由来の特徴量 (Identity Shape/Expression Latent Code) と FLAME が扱えない特徴量 (Global Latent Code) が明確に分離・条件付けされたことによって, これらの事象が現れたと考察される.

4.4.2 表情編集忠実度

本節では, 表情編集忠実度の定量評価結果について述べる. 評価指標として, Target 画像中の人物の表情を Source 画像に転送した際の, 出力画像と Target 画像の Valence (快-不快) 値の差分 (絶対値) を算出した. 理論上, この差分が小さいほど, Target 画像の表情が正確に転送されている, すなわち表情編集忠実度が高いことを示唆する.




図 4.3: DiffusionRig-Emo の v1 と v2 の比較結果.

Valence 値の差分による評価結果を、図 4.4 に示す. 本図は、v1 モデルと v2 モデルの差、すなわち FLAME パラメータの拡散モデルへの直接条件付けの有無ごとに、性能上位 5 モデルの結果を抽出したものである.

図 4.4 に示す Valence 差分の評価結果から、学習時の FLAME パラメータ推定器として、v1 モデルでは EMOCA が最適であったのに対し、v2 モデルでは DECA が適していることが示された. また、推論時の FLAME パラメータ推定器として、v1 モデルでは Target 側に EMOCA、Source 側に DECA を用いることが適していたことに対し、v2 モデルでは両方に EMOCA を用いることが適していることが示された. さらに、v1 モデルと v2 モデルの SOTA を比較すると、v1 モデルの Valence 最低差分は 21.186 であったのに対し、v2 モデルの Valence 最低差分は 23.483 だったため、V2 モデルは v1 モデルと比較して Valence 再現度が 10.8 % 低下 (悪化) した.

次に、Arousal (覚醒-鎮静) 値の差分による評価結果を図 4.5 に示す. Valence と同様に、差分が小さいほど表情編集忠実度が高いことを示す.

図 4.5 に示す Arousal 差分の評価結果から、Valence 評価で見られた v1 モデルと v2 モデル間での最適な FLAME パラメータ推定器の逆転現象は発生しなかったことが分かる. また、v2 モデルは v1 モデルと同様に、Valence と比較して Arousal の再現度が高い傾向も確認された. しかし、v1 モデルの最高性能モデル (Arousal 差分: 9.529) と比較して、v2 モデルの最高性能モデル (Arousal 差分: 10.313) は、




図 4.4: CAGE による評価結果 (v1 VS v2, Valence).

Arousal 再現度が 8.2 % 低下 (悪化) した。

4.4.3 アイデンティティ保持度

本節では, DiffusionRig-Emo (v2) による表情編集が, Source 画像と出力画像間のアイデンティティ保持度に与える影響を評価した実験結果について述べる。

評価手法として, Source 画像 (編集前) と出力画像 (編集後) を, 顔認識モデル FaceNet に入力し, それぞれ顔特徴ベクトルを抽出した。それらのベクトル同士のコサイン類似度を算出し, これをアイデンティティ保持度の指標とした。この指標は, 1 に近いほどアイデンティティが保持されていることを示す。評価結果を




図 4.5: CAGE による評価結果 (v1 VS v2, Arousal).

図 4.6 に示す.

図 4.6 に示すアイデンティティ保持度の評価結果から, v1 モデルで得られた知見と同様に, 学習時と推論時において DECA を利用した方がアイデンティティの損失は少ない (類似度が高い) ことが示された. また, v1 モデルの最高性能モデル (類似度: 0.9116) と比較して, v2 モデルの最高性能モデル (類似度: 0.9278) は, アイデンティティ保持度が 2.7 %改善した.

4.4.4 DiffusionRig-Emo(v2) に対する結論

以上の実験結果は, 他の人種や性別の人物画像を用いた実験においても同様の傾向が確認され, その結果以下の結論を導くことが可能である.

DiffusionRig-Emo (v2) における v1 モデルからの改良点, すなわち DECA・EMOCA の Identity Shape・Expression パラメータを拡散モデルに直接条件付けす




図 4.6: FaceNet による評価結果 (v1 VS v2, Identity).

る経路の導入により, Target 画像と出力画像間の表情編集忠実度は低下し, Source 画像のアイデンティティ保持度は上昇した.

この結果は, v2 モデルの研究目的であった「アイデンティティ保持度と表情編集忠実度のトレードオフ関係の解決」が達成できなかったことを意味する. しかし, 定性的な評価において, 出力画像における Source 画像のディテール (画風や肌の質感等) の再現度は改善した. したがって, Source 画像の特徴量維持が最優先されるタスク (例: Target 画像の Lighting や Pose のみを転送するタスク) においては, v2 モデルは v1 モデルと比較して有用であると言える.

以上が DiffusionRig-Emo (v2) の結論である. v2 の研究では検証に至らなかったが, Expression Latent Code, Identity Shape Latent Code 及び Global Latent Code が拡散モデルに与える条件付けの強度 (重み) を, Optuna[26] 等のハイパー

パラメータ最適化手法を用いて調整することにより、アイデンティティ保持度と表情編集忠実度のトレードオフ関係が改善される可能性がある。これは将来的な課題としたい。

4.5 本章のまとめ

本章では、v1 モデルで課題となった「表情編集忠実度とアイデンティティ保持度のトレードオフ関係」の解決を目的とした改良モデル、DiffusionRig-Emo(v2) について述べた。本モデルでは、主な改良点として、FLAME パラメータ (Identity Shape/Expression) を拡散モデルへ直接条件付けするための経路を追加した。

v1 モデルと v2 モデルの性能比較実験の結果、この改良によりアイデンティティ保持度を改善させた一方で、表情編集忠実度 (Valence/Arousal) を低下させる結果となった。

本章の結論として、4.4.4 節で述べた通り、v2 モデルの研究目的であったトレードオフ関係の抜本的な解決は達成できなかった。しかし、定性評価においては Source 画像のディテール (肌の質感等) の再現度が向上する副次的な効果も確認された。以上の実験結果から、v2 モデルは Source 画像の特徴量維持が最優先されるタスク (Lighting や Pose の編集) において有用である可能性が示唆された。また、将来的な課題として、各 FLAME パラメータの条件付けの強度を調整することで、更なるトレードオフ関係の改善の余地が残されている。

第5章

DiffusionRig-Emoのクラウド環境に おける実証と性能評価

5.1 本章の概要

本章では，DiffusionRig-Emo の実用化について検討するために作成したアプリの概要と，アプリを使用して行った実験の結果について概説する．

5.2 節「**DiffusionRig-Emo アプリと実験概要**」では，DiffusionRig-Emo のクラウド環境における実用性について検討するために作成したアプリの概要と，アプリを使用して行った性能評価実験について述べる．

5.3 節「**実験結果と考察**」では，同実験によって得られた結果を示し，結果から得られた考察について述べる．

5.4 節「**本章のまとめ**」では，本章のまとめについて述べる．

5.2 DiffusionRig-Emo アプリと実験概要

前章までの提案モデルの構築と評価を経て、本章では DiffusionRig-Emo の社会実装を見据えた実用可能性を検証する。具体的には、クラウドサービス (AWS) 上に DiffusionRig-Emo による表情・頭部の向き・ライティング編集を実行する API を構築し、API エンドポイントへのリクエストを通じてローカル環境から DiffusionRig-Emo を利用可能なアプリケーションを開発した。

API の開発と検証環境として AWS を選定した。選定にあたり、合計 10 種のクラウドコンピューティングサービスと個人・法人向けクラウド GPU サービスの比較検討を行った。その結果、本検証は推論タスクのみを実行するため、必ずしも学習用の超高性能 GPU (NVIDIA H100 等) を必要としない点と、API 化や推論モデルの外部公開の手軽さ及び GPU インスタンスの可用性 (利用のしやすさ) を総合的に考慮し、AWS が最適であると判断した。

図 5.1 に構築した DiffusionRig-Emo アプリのアーキテクチャを示す。システム構成要素として、ローカル PC から AWS 上のサーバー (EC2 インスタンス [27]) やストレージ (S3 バケット [28]) にアクセスするための API Gateway [29] と、ローカル PC 上で API リクエストの送信やワークフローを GUI ベースで実行するための Streamlit [30]、実際に DiffusionRig-Emo を動作させ、性能を評価するための計算リソースである EC2 インスタンス、AWS 上に入力画像や DiffusionRig-Emo のパラメータ群 (.pt ファイル) を保管するためのストレージである S3 バケット、EC2 インスタンス上にローカルで構築した DiffusionRig-Emo に関連するコードを展開・管理するためのツールである GitHub Actions [31] を使用している。また、使用する EC2 インスタンスは g4dn.xlarge (T4 [32] 搭載)、g5.xlarge (A10 [33] 搭載)、g6.xlarge (L4 [34] 搭載)、g6e.xlarge (L40S [35] 搭載) の 4 種類であった。

第5章 DiffusionRig-Emo のクラウド環境における実証と性能評価




図 5.1: DiffusionRig-Emo アプリのアーキテクチャ.

5.3 実験結果と考察

各 EC2 インスタンスにおける推論処理時間とコストを集計した結果を表 5.1 に、GPU ごとの推論処理時間を比較したグラフを図 5.2 に示す。

表 5.1: EC2 インスタンスごとの推論処理時間.

AWSスペック		処理時間(秒)					コスト(円)
EC2インスタンス名	GPU	コスト(円/時)	6枚	15枚	30枚	1000枚	1000枚
g4dn.xlarge	T4	81.53	450	1045	2030	65872	1492
g5.xlarge	A10	155.93	205	440	840	26525	1149
g6.xlarge	L4	124.78	225	500	960	30670	1063
g6e.xlarge	L40S	288.46	160	280	520	15165	1215

※ 1000枚の処理時間は計算値




図 5.2: GPU ごとの処理時間の比較.

実験に使用したサーバー (EC2 インスタンス) に搭載された GPU は全て NVIDIA 製であり、性能順 (昇順) は T4, A10, L4, L40S である。表 5.1 の結果より、L40S が最も高速な処理速度を記録した一方、コスト面では L4 が最も低コストであるという結果が得られた。この結果は、運用においてコストを抑制したい場合は L4 の使用が、生成速度を重視する場合は L40S の使用がそれぞれ適していることを示唆している。

第5章 DiffusionRig-Emo のクラウド環境における実証と性能評価

L40S は四種類の GPU の中で発売年が最も新しく、かつ利用時間単価も最高額であるため、L40S が生成速度において最速である点は予想通りである。しかし、1000 枚生成あたりのコストにおいては L4 が L40S を上回る結果となった。これは、DiffusionRig-Emo で実行される拡散モデルを用いた画像生成タスクと、EMOCA を用いた FLAME パラメータ抽出タスクの負荷に対して、L40S の性能対価格比 (コストパフォーマンス) が L4 ほど最適化されていないことを示している。ただし、よりパラメータ数が多い大規模モデルを利用する場合や、1 回の推論に含まれるタスク数が増加する場合には、L40S の処理能力が活かされ、コストパフォーマンスが逆転する可能性も残されている。



図 5.3: GPU と出力画像の関係.

推論で使用するコードや設定, Python ライブラリ等に変更はないため, DiffusionRig-Emo による出力画像の品質は GPU 性能に依存しない。しかし, 図 5.3 から GPU ごとに生成される画像には少しの差があることがわかる。これは, DiffusionRig-Emo 内で使用している拡散モデルが画像生成を行う際に設定する初期ノイズのランダム性に依るものである。

以上の実験結果に基づき, DiffusionRig-Emo の実用性と推奨される運用環境について以下の知見を得た。

第5章 DiffusionRig-Emo のクラウド環境における実証と性能評価

本システムを実運用する上での最適解は、「コスト効率」と「処理速度 (レイテンシ)」の優先順位によって明確に二分される。

コストパフォーマンスを最優先とする実用シナリオ (例: 夜間のバッチ処理や大規模な画像生成サービス) においては、L4 GPU (g6.xlarge) の採用が最も合理的である。実験結果より、L4 は 1000 枚あたりの処理コストが全モデル中で最小 (1063 円) であり、旧世代の T4 や A10 と比較しても速度・コスト共に大幅に改善されていることから、経済的な観点で最も実用性が高い。

一方で、処理速度を最優先とするシナリオ (例: リアルタイムな対話システムや即時性が求められる Web アプリケーション) においては、L40S GPU (g6e.xlarge) が実用的な選択肢となる。一定枚数当たりのコストは L4 に劣るが、L40S は最も高速な処理 (T4 比で約 4 倍、L4 比でも約 2 倍の速度) を実現しており、ユーザー体験を損なわない程度の高い応答性能を発揮可能である。

なお、本実験では V100 や A100 といった高性能な学習用 GPU は比較対象外としたが、推論用 GPU の中で最高性能である L40S の時点でコストパフォーマンスが悪化傾向にあったことを踏まえると、より高額な学習用 GPU を用いた場合、推論速度は向上してもコストパフォーマンスはさらに低下することが推測される。総じて、DiffusionRig-Emo は用途に応じて AWS インスタンスを適切に選定することで、コスト抑制と高速応答のいずれの要件にも柔軟に対応可能な、高い実用性を有するシステムとして利用可能な AI モデルであると結論付けられる。

5.4 本章のまとめ

本章では、DiffusionRig-Emo の実用化に向けた検証として、AWS クラウド環境上に推論アプリケーションを構築し、異なる GPU インスタンスを用いた性能評価実験を行った。

実験の結果、最新の推論用 GPU である L4 と L40S が高い有用性を示すことが明らかになった。具体的には、L4 はコストパフォーマンスに優れ、大規模なバッチ処理等に適している一方、L40S は処理速度に優れ、リアルタイム性が求められるアプリケーションに適しているという特性が確認された。

これらの検証結果から、DiffusionRig-Emo は、利用目的や制約条件 (コストまたは速度) に応じて適切な計算リソースを選定することで、十分に実用可能なシステムとして利用可能であると結論付けた。本章の知見は、本モデルを社会実装する際のハードウェア選定における重要な指針となるものである。

第6章

結論

本研究では、近年のメタバースやXR領域におけるデジタルヒューマン需要の高まりを背景に、2D画像から個人のアイデンティティを保持しつつ、自然的かつ多様な表情編集を可能にする3Dアバター生成モデルDiffusionRig-Emoの開発と評価を行った。

従来の3D Morphable Model (3DMM) は、計算コストが低く制御性に優れる一方で、髪や装飾品等の顔以外の特徴や、皮膚の質感といった微細なディテールの表現に限界があった。一方で、近年急速に発展した拡散モデルは、高品質な画像生成能力を持つが、3D空間的な一貫性やパラメータによる細かい制御が困難であった。本研究のベースラインであるDiffusionRigは、これらを組み合わせることで課題解決を図ったモデルであるが、表情の豊かさや感情再現性において改善の余地が残されていた。本研究では、このDiffusionRigをベースラインとし、表情編集忠実度とアイデンティティ保持度の向上及びそのトレードオフ関係の解消を目指して、二種類の段階的な改良モデル(v1, v2)を提案した。

第3章で提案した**DiffusionRig-Emo(v1)**では、学習データセットの変更(FFHQからAffectNetへ)と、拡散モデルへの条件付けモデルの変更(DECAからEMOCAへ)というアプローチを検証した。実験の結果、感情ラベル付きデータセットであるAffectNetの導入は、表情編集忠実度とアイデンティティ保持度の双方を向上させる極めて有効な手段であることが明らかになった。一方、感情表現に特化したFLAMEパラメータ推定器であるEMOCAの導入は、表情編集忠実度を向上させる反面、Target画像のアイデンティティ情報が混入することでSource画像のアイデンティティ保持度が低下するという、トレードオフ関係を浮き彫りにした。

第4章で提案した**DiffusionRig-Emo(v2)**では、v1モデルで確認されたトレードオフ関係の解決を目指した。v1モデルのアーキテクチャ内に、FLAMEパラメータ推定器(DECA/EMOCA)が持つIdentity ShapeパラメータとExpressionパラメータを、拡散モデルに対して直接条件付けする経路を追加した。評価の結果、v2モデルはv1モデルと比較してアイデンティティ保持度が向上し、Source画像の肌の質感や皺等のディテール再現性が改善された。一方で、Valence/Arousal差分から測定した表情編集忠実度に関しては、v1モデルと比較して低下する結果となり、目的としていたトレードオフ関係の完全な解消には至らなかった。以上の結果から、DiffusionRigをベースとしたモデルのアーキテクチャにおいて、アイデ

ンティティ情報と表情情報は密接に絡み合っており、単純な条件付けの分離だけでは双方の特徴量空間を別々に扱うことは困難であることが示唆された。一方で、v2モデルはソース人物の特徴を維持する性能において優れていたため、アイデンティティの維持が重要視されるタスクにおいて有用であるという知見が得られた。

第5章では、提案モデルの社会実装を見据え、AWSクラウド環境上でのアプリケーション構築と性能評価を行った。推論用GPU (L4, L40S) を用いた実験により、コスト効率を重視する場合はL4 GPU、リアルタイム性を重視する場合はL40S GPUの利用が最適であるという具体的な指針を示した。これにより、DiffusionRig-Emoは研究室レベルの実験モデルに留まらず、実際のWebサービスやアプリケーションとして展開可能なスケーラビリティと実用性を有していることを実証した。

本研究を通じて得られた知見に基づき、今後の課題と展望として以下の2点が挙げられる。

第一に、条件付け強度の最適化である。v2モデルの実験では、拡散モデルに直接条件付けされたIdentity Shape, Expression, Globalの各特徴量が拡散モデルに与える影響のバランス調整が未実施であった。Optuna等の自動最適化手法を用いて、各条件付けの重みを探索することで、v2モデルで課題となった表情編集忠実度の低下を抑制し、トレードオフ関係が改善される可能性がある。

第二に、評価指標の多角化である。本研究ではCAGEを用いたValence/Arousal差分を表情の評価指標としたが、3Dアバターの評価においては、FLAMEでは扱うことができない口の開閉量や視線の一致度等、より幾何学的な指標も重要となる。また、人間の主観評価(ユーザスタディ)を導入することで、数値には表れない「自然さ」や「不気味の谷」現象の評価を行うことも考えられる。

以上の課題に取り組み、FLAMEの3D-Faceに対する制御性と生成AIの表現力を高度に融合させることで、将来的には誰もが自身のデジタルツインを持ち、仮想空間上で感情豊かなコミュニケーションを行える社会の実現に貢献する。

謝辞

本論文を執筆するにあたり，貴重な御指導，御助言を頂きました，本学電子物理システム学科，史又華教授に深く感謝致します。また，研究テーマや研究の進め方に関して，さまざまな御助言を頂きました，ソニー株式会社，横山正幸様に深く感謝いたします。

本研究に関して，実験のご協力に加え，日々の研究活動等公私に渡り支えていただきました，史研究室の皆様に感謝申し上げます。

参考文献

- [1] A. Creswell, T. White, V. Dumoulin, K. Arulkumaran, B. Sengupta, and A. A. Bharath, “Generative adversarial networks: An overview,” *IEEE Signal Processing Magazine*, vol. 35, no. 1, pp. 53–65, 2018.
- [2] J. Choi, S. Kim, Y. Jeong, Y. Gwon, and S. Yoon, “Ilvr: Conditioning method for denoising diffusion probabilistic models,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 14 347–14 356.
- [3] D. P. Kingma and M. Welling, “Auto-encoding variational bayes,” in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2014.
- [4] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, “High-resolution image synthesis with latent diffusion models,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE Computer Society, 2022, pp. 10 674–10 685.
- [5] Stability.AI, “Stabilityai rest api,” <https://platform.stability.ai/docs/api-reference>, 2025, accessed: 2026-01-09.
- [6] P. Dhariwal and A. Nichol, “Diffusion models beat gans on image synthesis,” in *Proceedings of the International Conference on Neural Information Processing Systems (NeurIPS)*. Curran Associates Inc., 2021, pp. 8780–8794.
- [7] B. Mildenhall, P. P. Srinivasan, M. Tancik, J. T. Barron, R. Ramamoorthi, and R. Ng, “Nerf: representing scenes as neural radiance fields for view

- synthesis,” *Communications of the ACM (CACM)*, vol. 65, no. 1, pp. 99–106, 2021.
- [8] V. Blanz and T. Vetter, “A morphable model for the synthesis of 3d faces,” in *Proceedings of the Annual Conference on Computer Graphics and Interactive Techniques (SIGGRAPH)*. ACM Press/Addison-Wesley Publishing Co., 1999, pp. 187–194.
- [9] K. Pearson, “Liii. on lines and planes of closest fit to systems of points in space,” *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science (Philos. Mag.)*, vol. 2, no. 11, pp. 559–572, 1901.
- [10] L. Bao, X. Lin, Y. Chen, H. Zhang, S. Wang, X. Zhe, D. Kang, H. Huang, X. Jiang, J. Wang, D. Yu, and Z. Zhang, “High-fidelity 3d digital human head creation from rgb-d selfies,” *ACM Transactions on Graphics, (TOG)*, vol. 41, no. 1, pp. 1–21, 2021.
- [11] T. Li, T. Bolkart, M. J. Black, H. Li, and J. Romero, “Learning a model of facial shape and expression from 4d scans,” *ACM Transactions on Graphics, (TOG)*, vol. 36, no. 6, pp. 1–17, 2017.
- [12] S. Giebenhain, T. Kirschstein, M. Georgopoulos, M. Runz, L. Agapito, and M. NieBner, “Learning neural parametric head models,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE Computer Society, 2023, pp. 21 003–21 012.
- [13] Y. Feng, H. Feng, M. J. Black, and T. Bolkart, “Learning an animatable detailed 3D face model from in-the-wild images,” *ACM Transactions on Graphics, (TOG)*, vol. 40, no. 8, pp. 1–13, 2021.
- [14] R. Danecek, M. Black, and T. Bolkart, “Emoca: Emotion driven monocular face capture and animation,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE Computer Society, 2022, pp. 20 279–20 290.

- [15] J. A. Russell, “A circumplex model of affect.” *Journal of Personality and Social Psychology (JPSP)*, vol. 39, no. 6, pp. 1161–1178, 1980.
- [16] A. Mollahosseini, B. Hasani, and M. H. Mahoor, “Affectnet: A database for facial expression, valence, and arousal computing in the wild,” *IEEE Transactions on Affective Computing (TAC)*, vol. 10, no. 1, pp. 18–31, 2019.
- [17] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE Computer Society, 2016, pp. 770–778.
- [18] Z. Ding, X. Zhang, Z. Xia, L. Jebe, Z. Tu, and X. Zhang, “Diffusionrig: Learning personalized priors for facial appearance editing,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023, pp. 12 736–12 746.
- [19] T. Karras, S. Laine, and T. Aila, “A style-based generator architecture for generative adversarial networks,” *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, vol. 43, no. 12, pp. 4217–4228, 2021.
- [20] P. Ghosh, P. S. Gupta, R. Uziel, A. Ranjan, M. J. Black, and T. Bolkart, “Gif: Generative interpretable faces,” in *Proceedings of the International Conference on 3D Vision (3DV)*, 2020, pp. 868–878.
- [21] Y. Nitzan, K. Aberman, Q. He, O. Liba, M. Yarom, Y. Gandelsman, I. Mosseri, Y. Pritch, and D. Cohen-Or, “Mystyle: A personalized generative prior,” *ACM Transactions on Graphics, (TOG)*, vol. 41, no. 6, pp. 1–10, 2022.
- [22] D. E. King, “Dlib-ml: A machine learning toolkit,” *Journal of Machine Learning Research (JMLR)*, vol. 10, pp. 1755–1758, 2009.
- [23] F. Schroff, D. Kalenichenko, and J. Philbin, “Facenet: A unified embedding for face recognition and clustering,” in *Proceedings of the IEEE/CVF*

- Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE Computer Society, 2015, pp. 815–823.
- [24] E. Shoichi and S. Yoichiro, “情動評価のためのラッセルの円環モデルに基づく感情重心推定手法の提案,” *日本感性工学会論文誌*, vol. 18, no. 3, pp. 187–193, 2019.
- [25] N. Wagner, F. Mätzler, S. R. Vossberg, H. Schneider, S. Pavlitska, and J. M. Zöllner, “Cage: Circumplex affect guided expression inference,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024, pp. 4683–4692.
- [26] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, “Optuna: A next-generation hyperparameter optimization framework,” in *Proceedings of the International Conference on Knowledge Discovery and Data Mining (SIGKDD)*, 2019, pp. 2623–2631.
- [27] Amazon Web Services, Inc., *Amazon EC2 Instance Types*. Amazon Web Services, Inc., 2026, accessed: 2026-01-09.
- [28] Amazon Web Services, Inc., *What is Amazon S3?* Amazon Web Services, Inc., 2026, accessed: 2026-01-09.
- [29] Amazon Web Services, Inc., *What is Amazon API Gateway?* Amazon Web Services, Inc., 2026, accessed: 2026-01-09.
- [30] Streamlit Inc., *Main concepts*. Snowflake Inc., 2026, accessed: 2026-01-09.
- [31] GitHub, Inc., *Understanding GitHub Actions*. GitHub, Inc., 2026, accessed: 2026-01-09.
- [32] NVIDIA Corporation, *NVIDIA T4 Tensor Core GPU Data Sheet*. NVIDIA Corporation, 2026, accessed: 2026-01-09.
- [33] NVIDIA Corporation, *NVIDIA A10 Tensor Core GPU Data Sheet*. NVIDIA Corporation, 2026, ch. 1, accessed: 2026-01-09.

- [34] NVIDIA Corporation, *NVIDIA L4 Tensor Core GPU Data Sheet*. NVIDIA Corporation, 2026, ch. 1, accessed: 2026-01-09.
- [35] NVIDIA Corporation, *NVIDIA L40S GPU Specifications*. NVIDIA Corporation, 2026, ch. 1, accessed: 2026-01-09.

2025 年度 修士論文

3D アバターの自然な表情編集に関する研究

指導教員 史 又華，柳澤 政生 教授

早稲田大学大学院 基幹理工学研究科
電子物理システム学専攻

5124D004

石黒 将太郎

Shotaro Ishiguro

二〇二五年度 修士論文

3Dアバターの自然な表情編集

石黒将太郎

二〇二五年度 修士論文

3Dアバターの自然な表情編集

石黒将太郎

二〇二五年度 修士論文

3Dアバターの自然な表情編集

石黒将太郎

二〇二五年度 修士論文

3Dアバターの自然な表情編集

石黒将太郎

二〇二五年度 修士論文

3Dアバターの自然な表情編集

石黒将太郎

二〇二五年度 修士論文

3Dアバターの自然な表情編集

石黒将太郎

二〇二五年度 修士論文

3Dアバターの自然な表情編集

石黒将太郎

二〇二五年度 修士論文

3Dアバターの自然な表情編集

石黒将太郎