

3Dアバターの自然な 表情編集に関する研究

氏名 : 石黒将太郎

学籍番号 : 5124D004-7

専攻名 : 電子物理システム学専攻

研究室名 : 情報システム・史研究室

指導教員 : 史 又華 教授

: 柳澤 政生 教授

1. 研究背景・研究目的

2. 先行研究

- FLAMEパラメータ
- DECA & EMOCA
- DiffusionRig

3. 提案モデル: DiffusionRig-Emo(v1)

- DiffusionRig-Emo(v1)の概要
- DiffusionRig-Emo(v1)の研究成果

4. 提案モデル: DiffusionRig-Emo(v2)

- DiffusionRig-Emo(v2)の概要
- DiffusionRig-Emo(v2)の研究成果

5. DiffusionRigのクラウド環境における性能評価

- アプリ化の概要
- DiffusionRigアプリの実験結果

6. 結論

1. 研究背景・研究目的

2. 先行研究

- FLAMEパラメータ
- DECA & EMOCA
- DiffusionRig

3. 提案モデル: DiffusionRig-Emo(v1)

- DiffusionRig-Emo(v1)の概要
- DiffusionRig-Emo(v1)の研究成果

4. 提案モデル: DiffusionRig-Emo(v2)

- DiffusionRig-Emo(v2)の概要
- DiffusionRig-Emo(v2)の研究成果

5. DiffusionRigのクラウド環境における性能評価

- アプリ化の概要
- DiffusionRigアプリの実験結果

6. 結論

研究背景と研究目的

研究背景

1. 3D生成AIの需要拡大と現状

- 近年のAR（拡張現実）やVR（仮想現実）デバイスの普及に伴い、3D一貫性を保ったリアルなデジタルヒューマンに関する需要が増加している
- 実在人物の2D画像からCV上に3D頭部を復元する「3D-Face Reconstruction」技術が進展している

2. 既存技術における課題

- 既存手法では、高密度な点群の扱いが難しく、口内・眼球・髪等の詳細な再現性が不足している
- 表情を操作する過程で、「**個人のアイデンティティ（本人らしさ）が失われる」「不自然な表情になる」「指示した感情と生成結果が一致しない**」といった課題が残されている

研究目的

1. ベースラインモデルの改良と提案

- 入力画像に含まれるアイデンティティを保持しつつ、表情やポーズ等が編集可能である**DiffusionRig**をベースラインモデルとし、そのアーキテクチャを改良する
- 本研究では、より表情豊かで、指定された感情との一致度（表情編集忠実度）が高いデジタルヒューマンを生成する**DiffusionRig-Emo**の開発を目指す

2. 目指す成果と応用

- 3D-Face Reconstructionタスクにおけるアイデンティティの保持と、高い表情編集忠実度の両立を可能にする
- 3Dアバターの表情再現性を向上させることで、ゲームや映画等のエンターテインメント分野への応用可能性を示す
- 提案モデルの駆動を目的としたアプリを開発し、実運用の実現可能性を示す

1. 研究背景・研究目的

2. 先行研究

- FLAMEパラメータ
- DECA & EMOCA
- DiffusionRig

3. 提案モデル: DiffusionRig-Emo(v1)

- DiffusionRig-Emo(v1)の概要
- DiffusionRig-Emo(v1)の研究成果

4. 提案モデル: DiffusionRig-Emo(v2)

- DiffusionRig-Emo(v2)の概要
- DiffusionRig-Emo(v2)の研究成果

5. DiffusionRigのクラウド環境における性能評価

- アプリ化の概要
- DiffusionRigアプリの実験結果

6. 結論

FLAMEパラメータとは？

3D頭部の表現手法である3DMMを元にしたモデルであり、shape・pose・expressionパラメータを操作することで、アイデンティティ・頭部の動き・表情をコントロールできる

- それぞれのパラメータは独立しているため、1つのパラメータを変化させても、他のパラメータへの影響は少ない
- 本研究のベースラインモデルであるDiffusionRigの基盤モデルとして採用されている




図2.2. FLAMEモデルを用いた3D頭部の例[11].

DECAとは？

2D顔画像から3D顔モデルを再構成するモデルであり、内部でFLAMEを用いることで、計算コストを抑えながら3D一貫性と自然な表情・見た目を持つ3D-Faceを生成できる

- 一枚の2D顔画像から3D顔画像を再現可能であり、FLAMEパラメータの一部を入れ替えることで表情転送も可能である




図2.5. DECAの出力例[13].




図2.6. DECAのアーキテクチャ[13].

EMOCAとは？ DECAとの違いは？

DECAの改良版であり、表情の再現度に着目した評価指標を導入することで、表情多様性を向上させた

- EMOCAはDECAと同様のアーキテクチャを持つが、新たに感情認識モデルの特徴量に基づいた損失関数が導入されている
- 激しい表情を持つ画像が入力された場合の3D-Faceの表情の追従性が向上している



図2.9. DECAとEMOCAの比較結果[14]（一部抜粋）。




図2.8. EMOCAのアーキテクチャ[14].

本研究のベースラインモデルであるDiffusionRigとは？

Source画像中の人物のアイデンティティや3D一貫性を維持したまま、Target画像中の人物のPose・Lighting・ExpressionをSource画像に移植した画像を出力する拡散モデル




図2.10. DiffusionRigによる編集例[18].

DiffusionRigを改良することで、Source画像のアイデンティティを維持しながら、Target画像中で指定された表情と一致度が高い表情を持つデジタルヒューマンを生成する“DiffusionRig-Emo”の開発を目指す

DiffusionRigのアーキテクチャの特徴は？

2D画像から3D顔モデルを生成するDECAから抽出したPhysical Buffersと、頭部以外の部分の特徴量を保持するGlobal Latent Codeを、画像生成を行う拡散モデルに条件付けしている

- DECA由来のPhysical Buffersにより、出力画像中の人物が3D一貫性を維持したり、Source人物のアイデンティティを保持できる
- Global Latent CodeはDECAが扱わない領域（背景・髪・歯等）の特徴量を拡散モデルに伝える
- Source人物の表情のみを変化させたい場合は、ExpressionパラメータのみをTarget人物のものと入れ替える
- 学習には2段階あり、Stage1ではFFHQを用いた学習により人物の基本的な特徴を学習し、Stage2では同一人物の個人アルバムを用いた学習によりアイデンティティを学習する




図2.11. DiffusionRigのアーキテクチャ[18].

1. 研究背景・研究目的

2. 先行研究

- FLAMEパラメータ
- DECA & EMOCA
- DiffusionRig

3. 提案モデル: DiffusionRig-Emo(v1)

- DiffusionRig-Emo(v1)の概要
- DiffusionRig-Emo(v1)の研究成果

4. 提案モデル: DiffusionRig-Emo(v2)

- DiffusionRig-Emo(v2)の概要
- DiffusionRig-Emo(v2)の研究成果

5. DiffusionRigのクラウド環境における性能評価

- アプリ化の概要
- DiffusionRigアプリの実験結果

6. 結論

DiffusionRig-Emo(v1)のベースラインモデルに対する変更点とは？

1. Stage1データセットをFFHQからAffectNetに変更

2. 人物の特徴を抽出するモデルをDECAからEMOCAに変更

1. 表情に関する質の高い特徴を学習するためには？

- FFHQは高品質な顔画像の生成と顔認識を目的としているが、AffectNetは顔の表情認識を目的としている
- FFHQの画像枚数は7万枚であることにに対し、AffectNetの画像枚数は約26万枚

2. Source・Target人物から高品質なFLAMEパラメータを抽出することにより、出力画像の精度が上がるのではないか？

- EMOCAはDECAの表情多様性欠如を解決するために開発された
- EMOCAはDECAで使用する損失関数に、感情に関する損失関数を加えたモデル




図3.1. DiffusionRig-Emo(v1)のアーキテクチャ（学習時）。




図3.2. DiffusionRig-Emo(v1)のアーキテクチャ（推論時）。

DiffusionRig-Emo(v1)の評価方法とは？

合計32種類のモデルを評価・比較することで、データセットとしてFFHQとAffectNetのどちらが優れているかと、人物からの特徴抽出モデルとしてDECAとEMOCAのどちらが適しているかが判明する

データセット	Stage1 stage2	Global Latent Code	Target expパラ	Source expパラ	評価対象 モデル
FFHQ or AffectNet	DECA or EMOCA	Resnet 18 or Resnet50	DECA or EMOCA	DECA or EMOCA	32種類




図3.1. DiffusionRig-Emo(v1)のアーキテクチャ（学習時）。




図3.2. DiffusionRig-Emo(v1)のアーキテクチャ（推論時）。

3D-Faceのアイデンティティ保持度と表情編集忠実度をどのように定量評価すべきか？

FaceNetから抽出した顔特徴量のコサイン類似度と、CAGEから抽出したValence値とArousal値の差分をモデルごとに比較することで定量評価する

• アイデンティティ保持度

1. Source画像と出力画像を顔認識モデルFaceNet[23]に入力し、それぞれの顔特徴量ベクトルを抽出する
2. モデルごとに両ベクトルのコサイン類似度を算出・比較し、その平均値が1に近似するほど、Source画像のアイデンティティが失われていない、すなわちアイデンティティ保持度が高いと判定する

• 表情編集忠実度

1. Target画像と出力画像を感情推定モデルCAGE[25]に入力し、それぞれのV/A値を推定後、両画像間のV/A値の差分を算出する
2. モデルごとにV/A値の差分を比較し、その差分が小さいほどTarget画像の表情が知覚的に正しく再現されている、すなわち表情編集忠実度が高いと判定する




図3.3. Lasselの円環モデル[24].

[23] F. Schroff, D. Kalenichenko, and J. Philbin, "Facenet: A unified embedding for face recognition and clustering," in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2015, pp. 815–823.

[24] E. Shoichi and S. Yoichiro, "情動評価のためのラッセルの円環モデルに基づく感情重心推定手法の提案," 日本感性工学会論文誌, vol. 18, no. 3, pp. 187–193, 2019.

[25] N. Wagner, F. M"atzler, S. R. Vossberg, H. Schneider, S. Pavlitska, and J. M. Z"ollner, "Cage: Circumplex affect guided expression inference," in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2024, pp. 4683–4692.

DiffusionRig-Emo(v1)とベースラインモデルの生成画像を定性比較した結果

学習過程・推論過程で使用する人物特徴抽出モデルを変更すると、生成画像の表情に明確な差が見られ、DiffusionRig-Emo(v1)はベースラインと比較して、表情編集忠実度が高い傾向が確認された




図 3.4. DiffusionRigとDiffusionRig-Emo(v1)の比較結果.

DiffusionRig-Emo(v1)とベースラインモデルの生成画像とTarget画像のValence差を比較

AffectNetによりValence一致度が上昇した。また、学習時と推論時のTarget人物・Source人物の特徴抽出モデルの一部にEMOCAを選択することでValenceの一致度が上昇した

評価実験概要

- Target人物の表情を転送した場合の、Target画像とSource画像のValence差を計算
- Target人物の表情をうまく転送できている、すなわち表情の覚醒度が一致すればValenceは同値になるはず
- AffectNetと従来のFFHQを用いた場合、それぞれ16種類のモデルの中から性能上位5モデルを表示

評価結果

- AffectNetで訓練した方がValenceの差が小さい
- 学習時のFLAMEパラメータ推定器としてEMOCAが最適である
- 頭部以外の特徴を保持するエンコーダとしてResNet18を選択するべきである
- 推論時のFLAMEパラメータ推定器として、Target人物の特徴抽出にEMOCA、Source人物の特徴抽出にDECAが最適である




図 3.5. CAGE による評価結果 (baseVSv1, Valence).

DiffusionRig-Emo(v1)とベースラインモデルの生成画像とTarget画像のArousal差を比較

AffectNetによりArousal一致度が上昇した。また、学習時と推論時のTarget人物・Source人物の特徴抽出モデルの一部にEMOCAを選択することでArousal一致度が上昇した

評価実験概要

- Target人物の表情を転送した場合の、Target画像とSource画像のArousal差を計算
- Target人物の表情をうまく転送できている、すなわち表情の感情価が一致すればArousalは同値になるはず
- AffectNetと従来のFFHQを用いた場合、それぞれ16種類のモデルの中から性能上位5モデルを表示

評価結果

- AffectNetで訓練した方がArousalの差が小さい
- 学習時のFLAMEパラメータ推定器としてEMOCAが最適である
- 頭部以外の特徴を保持するResNetの選択は性能への影響が小さい
- 推論時のFLAMEパラメータ推定器として、Target人物の特徴抽出にDECA、Source人物の特徴抽出にEMOCAが最適である




図 3.6. CAGE による評価結果 (baseVSv1, Arousal).

DiffusionRig-Emo(v1)とベースラインモデルの生成画像とSource画像のアイデンティティ保持度を比較

AffectNetによりアイデンティティ保持度が上昇したが、DECAからEMOCAへの変更によりアイデンティティ損失が大きくなった

評価実験概要

- Source画像と出力画像をFaceNetに入力することで、人物顔画像を特徴ベクトルに変換し、モデルごとの特徴ベクトルのコサイン類似度の平均値を比較
- アイデンティティの損失が小さければコサイン類似度は1に近似するはず
- AffectNetと従来のFFHQを用いた場合、それぞれ16種類のモデルの中から性能上位5モデルを表示

評価結果

- AffectNetで学習することでアイデンティティ保持度が上昇する
- 頭部以外の特徴を保持するResNetの選択は性能への影響が小さい
- アイデンティティ損失の小ささを優先する場合、FLAMEパラメータ推定器としてDECAを選択するべき




図 3.7. FaceNetによる評価結果 (baseVSv1, Identity).

DiffusionRig-Emo(v1)の評価結果は？

FFHQからAffectNetへの変更は、アイデンティティ保持度と表情再現度の上昇に寄与した。DECAからEMOCAへの変更は、大幅な表情再現度向上に寄与したが、反対にアイデンティティ保持度の低下を招いたため、両者にはトレードオフ関係があることが明らかになった

現状

学習データセットのFFHQからAffectNetへの変更

- 個人のアイデンティティ情報の損失を抑制しつつ、Target画像と生成画像間における表情再現度を高めることに寄与したことを確認した

DECAからEMOCAへの変更

- EMOCAがDECAの表情多様性を改良したモデルであるため、Target画像と生成画像間の表情再現度向上に寄与したことを確認した
- その一方で、アイデンティティ保持度の低下を確認した。原因として、Target画像の表情をSource画像に転送する際、Target画像の表情に関する特徴量に含まれてしまっているアイデンティティ情報も同時に転送されるIdentity Leakage（アイデンティティの漏洩）が発生した可能性が考えられる

v2開発に向けた課題

- v1の研究成果は、アイデンティティ保持度と表情再現度の間には**トレードオフ関係**が存在することを示唆している
- 次期モデルDiffusionRig-Emo(v2)では、このトレードオフ関係の解決を主要な研究目的として設定した

1. 研究背景・研究目的

2. 先行研究

- FLAMEパラメータ
- DECA & EMOCA
- DiffusionRig

3. 提案モデル: DiffusionRig-Emo(v1)

- DiffusionRig-Emo(v1)の概要
- DiffusionRig-Emo(v1)の研究成果

4. 提案モデル: DiffusionRig-Emo(v2)

- DiffusionRig-Emo(v2)の概要
- DiffusionRig-Emo(v2)の研究成果

5. DiffusionRigのクラウド環境における性能評価

- アプリ化の概要
- DiffusionRigアプリの実験結果

6. 結論

DiffusionRig-Emo(v2)の改良点は？

DECA or EMOCA由来の特徴量を効率良く拡散モデルに伝達するため、FLAMEパラメータ（Identity・Expression Latent Code）を拡散モデルに直接条件付けする経路を追加した

v1は、FLAMEパラメータ推定器から抽出した頭部特徴を画像化した上で拡散モデルに条件付けしているが、このプロセスでは、FLAMEパラメータからPhysical Buffers画像を生成するタイミングで、特徴量の欠落が発生しているのではないかな？

- FLAMEパラメータを拡散モデルへ直接条件付けすることで、拡散モデルに対しDECA or EMOCA由来の特徴を強く反映させる
- Identity shape・Expression・Global Latent Codeそれぞれ別の条件付け経路を設けることにより、拡散モデルが”背景と顔の領域区分”と”人物のアイデンティティと表情”をより明確に区分できるようになる




図4.1. DiffusionRig-Emo(v2)のアーキテクチャ（学習時）。




図4.2. DiffusionRig-Emo(v2)のアーキテクチャ（推論時）。

DiffusionRig-Emo(v2)の評価方法とは？

合計32種類のモデルを評価・比較することで、DiffusionRig-Emoのv1とv2のどちらが優れているかが判明する

FLAME 直接条件付け	Stage1 stage2	Global Latent Code	Target expパラ	Source expパラ	評価対象 モデル
あり(v2) or なし(v1)	DECA or EMOCA	Resnet 18 or Resnet50	DECA or EMOCA	DECA or EMOCA	32種類




図4.1. DiffusionRig-Emo(v2)のアーキテクチャ（学習時）。




図4.2. DiffusionRig-Emo(v2)のアーキテクチャ（推論時）。

DiffusionRig-Emo(v1)とDiffusionRig-Emo(v2)の生成画像を定性比較した結果

拡散モデルにFLAMEパラメータを直接条件付けすることで生成画像に明確な差が見られ、しわや毛穴等のディテールの表現力向上が確認された




図4.3. DiffusionRig-Emo(v1)とDiffusionRig-Emo(v2)の比較結果.

DiffusionRig-Emo(v1)とDiffusionRig-Emo(v2)の生成画像とTarget画像のValence差を比較

DiffusionRig-Emo(v2)はDiffusionRig-Emo(v1)と比較して、Valence再現度が10.8%悪化した

評価実験概要

- Target人物の表情を転送した場合の、Target画像とSource画像のValence差を計算
- Target人物の表情をうまく転送できている、すなわち表情の覚醒度が一致すればValenceは同値になるはず
- DiffusionRig-Emo(v1)とそれにFLAMEパラメータ直接条件付け経路を加えたDiffusionRig-Emo(v2)、それぞれ16種類のモデルの中から性能上位5モデルを表示

評価結果

- 学習時のFLAMEパラメータ推定器として、v1ではEMOCAが最適であったのに対し、v2ではDECAが最適となった
- 推論時のFLAMEパラメータ推定器として、v1ではTarget側にEMOCA、Source側にDECAが最適であったのに対し、v2では両方にEMOCAを用いるのが最適となった
- v2はv1と比較して、出力画像におけるValence再現度が10.8%悪化した




図4.4. CAGE による評価結果 (v1VSv2, Valence).

DiffusionRig-Emo(v1)とDiffusionRig-Emo(v2)の生成画像とTarget画像のArousal差を比較

DiffusionRig-Emo(v2)はDiffusionRig-Emo(v1)と比較して、Arousal再現度が8.2%悪化した

評価実験概要

- Target人物の表情を転送した場合の、Target画像とSource画像のArousal差を計算
- Target人物の表情をうまく転送できている、すなわち表情の感情価が一致すればArousalは同値になるはず
- DiffusionRig-Emo(v1)とそれにFLAMEパラメータ直接条件付け経路を加えたDiffusionRig-Emo(v2)、それぞれ16種類のモデルの中から性能上位5モデルを表示

評価結果

- 学習時と推論時どちらの場合においても、最適なFLAMEパラメータ推定器の選択に変更はない
- v2はv1と比較して、出力画像におけるArousal再現度が8.2%悪化した




図4.5. CAGE による評価結果 (v1VSv2, Arousal).

DiffusionRig-Emo(v1)とDiffusionRig-Emo(v2)の生成画像とTarget画像のIdentity保持度を比較

DiffusionRig-Emo(v2)はDiffusionRig-Emo(v1)と比較して、Identity保持度が2.7%改善した

評価実験概要

- Source画像と出力画像をFaceNetに入力することで、人物顔画像を特徴ベクトルに変換し、モデルごとの特徴ベクトルのコサイン類似度の平均値を比較
- アイデンティティの損失が小さければコサイン類似度は1に近似するはず
- DiffusionRig-Emo(v1)とそれにFLAMEパラメータ直接条件付け経路を加えたDiffusionRig-Emo(v2)、それぞれ16種類のモデルの中から性能上位5モデルを表示

評価結果

- 学習時と推論時どちらの場合においても、最適なFLAMEパラメータ推定器の選択に変更はない
- アイデンティティ損失の小ささを優先する場合、FLAMEパラメータ推定器としてDECAを選択するべき
- v2はv1と比較して、出力画像におけるIdentity保持度が2.7%改善した




図4.6. FaceNet による評価結果 (v1VSv2, Identity).

DiffusionRig-Emo(v2)の評価結果は？

FLAMEパラメータを拡散モデルに直接条件付けするアーキテクチャの導入では、アイデンティティ保持度と表情編集再現度のトレードオフ関係を解決できなかった

現状

- FLAMEのIdentity Shape・Expressionパラメータを拡散モデルに直接条件付けするアーキテクチャの導入により、Target画像と出力画像間の表情再現度は低下し、Source画像のアイデンティティ保持度は上昇したことから、v2の開発目的であったトレードオフ関係を解決することは達成できなかった
- しかし、定性的な評価において、出力画像におけるSource画像のアイデンティティ以外の特徴（画風や肌の質感等のディテール）の再現度は向上したため、Source画像の特徴量維持が最優先されるタスク（例：Target画像のLightingやPoseのみを移植するタスク）においては、v2はv1と比較して有用である

今後の課題

- Expression Latent Code、Identity Shape Latent Code、およびGlobal Latent Codeが拡散モデルに与える条件付けの強度（重み）をOptuna等で調整することで、アイデンティティ保持度と表情再現度のトレードオフ関係が改善される可能性がある
- 自分の実験環境（RTX4070ti Super）では、DiffusionRig-Emo(v2)の推論に時間がかかるため（1画像5秒程度）、拡散モデルの学習と3つのハイパーパラメーター調整の両立は時間の都合上不可能であった。したがって、これは将来的な課題としたい

1. 研究背景・研究目的

2. 先行研究

- FLAMEパラメータ
- DECA & EMOCA
- DiffusionRig

3. 提案モデル: DiffusionRig-Emo(v1)

- DiffusionRig-Emo(v1)の概要
- DiffusionRig-Emo(v1)の研究成果

4. 提案モデル: DiffusionRig-Emo(v2)

- DiffusionRig-Emo(v2)の概要
- DiffusionRig-Emo(v2)の研究成果

5. DiffusionRigのクラウド環境における性能評価

- アプリ化の概要
- DiffusionRigアプリの実験結果

6. 結論

DiffusionRig-Emoの実用性についてどのように検討するのか？

DiffusionRig-Emoの推論を行うAPIをAWS上に構築し、複数のGPUを用いた推論を行うことで、GPUごとのコストパフォーマンスや、DiffusionRig-Emoはどのようなサービスに適するのかについて考察する

- AWS上に、DiffusionRig-Emoによる推論を行うAPIを構築し、APIエンドポイントへのリクエストを通じてDiffusionRig-Emoをどの環境からでも利用可能なアプリケーションを開発する
- AWS上のストレージ（S3バケット）にアップロードされた画像は、DiffusionRig-Emoコンテナをデプロイしたサーバー（EC2インスタンス）で処理されるが、複数のEC2インスタンスを選択することで、GPUスペックを変化させた時の推論速度とコストのトレードオフ関係について調査する
- NVIDIA製のT4・L4・A10・L40Sについて調査した




図5.1. DiffusionRig-Emoアプリのアーキテクチャ。

GPUごとの推論時間とコストの関係性は？ DiffusionRig-Emoのユースケースは？

推論用GPUを用いることで1円・1秒/枚の生成画像を出力できる。また、コストを優先する場合と推論速度を優先する場合で使用するべきGPUが異なる

- ・ ウォームスタート前提で、1枚の推論に1秒・1円かかる
- ・ L40Sを使用することで最高生成速度を達成できるが、L4を用いた場合と比較してコストが14%増加する
- ・ 学習用GPU（V100以上）は使用できなかったが、高性能推論GPU（L40S）時点でコストは上昇傾向だったため、学習用GPUを使用することでコストパフォーマンスが上昇することは考えにくい

表5.1. インスタンスごとの推論処理時間.

AWSスペック		処理時間(秒)					コスト(円)
EC2インスタンス名	GPU	コスト(円/時)	6枚	15枚	30枚	1000枚	1000枚
g4dn.xlarge	T4	81.53	450	1045	2030	65872	1492
g5.xlarge	A10	155.93	205	440	840	26525	1149
g6.xlarge	L4	124.78	225	500	960	30670	1063
g6e.xlarge	L40S	288.46	160	280	520	15165	1215

※ 1000枚の処理時間は計算値




図5.2. GPUごとの処理時間の比較.

1. 研究背景・研究目的

2. 先行研究

- FLAMEパラメータ
- DECA & EMOCA
- DiffusionRig

3. 提案モデル: DiffusionRig-Emo(v1)

- DiffusionRig-Emo(v1)の概要
- DiffusionRig-Emo(v1)の研究成果

4. 提案モデル: DiffusionRig-Emo(v2)

- DiffusionRig-Emo(v2)の概要
- DiffusionRig-Emo(v2)の研究成果

5. DiffusionRigのクラウド環境における性能評価

- アプリ化の概要
- DiffusionRigアプリの実験結果

6. 結論

本研究の結論

DiffusionRig-Emo(v1)モデル（学習データ・モデルの変更）の成果

- 学習データをAffectNetに変更したことで、表情編集忠実度とアイデンティティ保持度の双方が向上した
- 条件付けにEMOCAを導入すると表情編集忠実度が向上するが、アイデンティティ保持度は低下するというトレードオフ関係が示唆された

DiffusionRig-Emo(v2)モデル（パラメータ直接条件付け）の成果

- FLAMEパラメータを拡散モデルへ直接条件付けすることで、アイデンティティ保持度とディテール（肌の質感等）の再現性が向上した
- 一方で、表情編集忠実度はv1と比べて低下し、トレードオフ関係の完全な解消には至らなかった
- 「本人らしさの維持」が最優先されるタスクにおいてはv2が有用であることを確認した

実用化の検証

- DiffusionRig推論用アプリケーションを構築し、内部で動作させるGPUを変更することで実用性を検証した
- GPU選定の指針として、コスト重視ならL4、速度重視ならL40Sが最適であると結論付けた

今後の課題

- **条件付け強度の最適化:** Optuna等を用い、Identity/Expression等の各特徴量が拡散モデルに与える影響バランスを自動調整する
- **評価指標の多角化:** 幾何学的な指標（口の開閉量や視線推定）や、ユーザスタディによる主観評価の導入することでより良い評価指標ベースラインを作成する

Appendix

GPUと生成画像の品質の関係

生成画像の品質はGPU性能に依存せず、拡散モデルの初期ノイズのランダム性によって生成画像に細かい違いが生まれる



図5.3. GPUと生成画像の関係.

>

Deploy

 推論実行トリガー

 接続設定

推論API エンドポイント URL

https://iu6oaxao69.execute-api.ap-northeast-1.amazonaws.com

S3バケット名

diffusionrig-demo-tokyo

完了監視設定

S3チェック間隔 (秒)

15

監視上限時間 (分)

15

ECS推論タスクを実行 (Start Task)

 パス設定

Source ディレクトリ (S3パス)

s3://diffusionrig-demo-tokyo/source02/

Target ファイル (S3パス)

s3://diffusionrig-demo-tokyo/target/obama05.p

Output ディレクトリ (S3パス)

s3://diffusionrig-demo-tokyo/outputs/my-first-r

⚠ 注意: Outputディレクトリに生成された画像は、画面表示後に自動的にS3から削除されます。

aws

検索

[オプション+5]

アジアカシフィック (東京)

アカウント ID: 2207-4929-7321

ishow_pantarhei

Elastic Container Registry

Lambda

S3

Billing and Cost Manage...

CloudWatch

IAM

EC2

Elastic Container Service

API Gateway

VPC

Amazon Elastic Container Service

クラスター

my-ecs-cluster

タスク

my-ecs-cluster

ASG

最終更新日: 2025年11月22日 00:18 (UTC+9:00)

アクション

起動

クラスターの概要

ARN

arn:aws:ecs:ap-northeast-1:20749297321:cluster/my-ecs-cluster

ステータス

アクティブ

CloudWatch モニタリング

デフォルト

登録済みコンテナインスタンス

1

サービス

タスク

ドレイン中

アクティブ

保留中

実行中

サービス

タスク

インフラストラクチャ

更新しました

メトリクス

スケジュールされたタスク

設定

イベント

タスク (3)

最終更新日: 2025年11月22日 00:18 (UTC+9:00)

タグの管理

停止

新しいタスクの実行

プロパティまたは値でタスクをフィルタ

希望するステータスをフィルタリング

あらゆる希望するステータス

起動タイプをフィルタリング

あらゆる起動タイプ

タスク

29a60863cd7d40f79bdbbd1e8bf52e3f

停止済み | Essential container in task exited

停止済み

diffus

61a8ce894a8c4a1f9ba15aa9560ad816

停止済み | Essential container in task exited

停止済み

diffus

d6101ebc0006467295ff6f5590a7d690

停止済み | Essential container in task exited

停止済み

diffus