

第9回定期ミーティング

2024/11/12

早稲田大学 基幹理工学研究科
電子物理システム学専攻 史研究室
石黒将太郎・野口颯汰

1. 論文紹介 part1

- A) DECA
- B) EMOCA

2. 実装状況

- A) NeRFモデル
- B) DECA
- C) EMOCA
- D) DiffusionRig

3. 今後の方針(石黒)

4. 論文紹介 part2

- A) DiffusionAutoencoders

5. 今後の方針(野口)

1. 論文紹介 part1

- A) DECA
- B) EMOCA

2. 実装状況

- A) NeRFモデル
- B) DECA
- C) EMOCA
- D) DiffusionRig

3. 今後の方針(石黒)


4. 論文紹介 part2

- A) DiffusionAutoencoders

5. 今後の方針(野口)

Learning an Animatable Detailed 3D Face Model from In-The-Wild Images

YAO FENG, HAIWEN FENG, MICHAEL J. BLACK, TIMO BOLKART



このモデルができること

- ✓ 一枚の顔画像から、顔の特徴をモデリングし、既存の3Dモデル(FLAME)と組み合わせることで精巧な3D顔形状を復元
- ✓ 高速で推論が可能：120fps (w/Nvidia Quadro RTX 5000を使用)

本手法の特徴

- ✓ 入力画像は単一画像
- ✓ 個人の特徴を有する顔モデルを復元
- ✓ 学習時に3D教師データが不要であり、2D画像のみを利用

FLAMEの仕組み

六つのパラメーターによって3D顔モデルが構成される

identity shape β

facial expression ψ

pose parameter θ

3D顔モデルの形状を決定


texture parameter α

表面のテクスチャ(albedo)を決定


lighting parameter $\mathbf{l}$

camera parameter c

レンダリングに使用



DECAモデルの概要




学習の仕組み


3段階の学習で3つのネットワークを最適化

1. Pre-training stage
2. Coarse stage
3. Detail stage

Pre-training stage / Coarse stage



Detail stage



損失関数(Pre-training stage)

$$\text{Total Loss} : L_{\text{pretrain}} = L_{\text{lmk}} + L_{\text{eye}} + L_{\text{reg}} (+ L_{\text{lip}})$$

L_{lmk} : ランドマーク座標誤差の最小化



L_{eye} : 目の部分のランドマーク座標の差分を一致させる

L_{reg} : shape, expression パラメータに感じてL2正則化

損失関数(Coarse stage)

$$\text{Total Loss} : L_{Coarse} = L_{lmk} + L_{eye} + L_{pho} + L_{id} + L_{sc} + L_{reg}$$

L_{pho} : 再構成損失…レンダリング後の画像とGT画像のL1距離を最小化

L_{id} : 顔認識ネットワークを用いて顔の特徴量のコサイン距離を最小化

L_{sc} : 同一人物の複数枚の画像からshapeパラメータのみを交換し、
 $L_{lmk} + L_{eye} + L_{pho} + L_{id} + L_{reg}$ を計算

L_{reg} : shape, expression, textureパラメータに感じてL2正則化

損失関数(Detail stage)

$$\text{Total Loss} : L_{Coarse} = L_{phoD} + L_{mrf} + L_{sym} + L_{dc} + L_{regD}$$

L_{phoD} : 再構成損失…UV空間における顔領域のL1距離を最小化

L_{mrf} : ID-MRFというinpaintingタスクで最初に用いられた損失
VGG19によって抽出された特徴感パッチの差分が小さくなるようにする
(物体の質感を近くする効果)

L_{sym} : 見えていない部分へのロバスト性向上効果
見えてない部分は左右対称とみなす

L_{dc} : L_{sc} (Coarse Stage)と同じアイデア
個人特有の変数を同一人物間で使いまわしても同じになるという考え方

データセット

- ✓ VGGFace2 : 95枚の画像を学習に使用(高解像度& 低解像度)
- ✓ BUPT-BalancedFace : 多国籍画像 55万枚の画像を学習に利用
- ✓ VoxCeleb2 : 動画 + 音声のデータセット 50万枚の画像フレームを学習に利用

→顔領域のマスクを取得し、FANによる顔のLandmark座標を取得

学習の詳細

1. Pre-training stage
バッチサイズ64 / 2epochs VGGFace2 & BUPT-BalancedFace
2. Coarse stage
バッチサイズ32 / 1.5epochs VGGFace2 & BUPT-BalancedFace
3. Detail stage
バッチサイズ6 / ?epochs VGGFace2 & VoxCeleb2

定量評価

①Now benchmark

100人の顔画像(2054枚)+3Dスキャンデータ

Method	Median (mm)	Mean (mm)	Std (mm)
3DMM-CNN [Tran et al. 2017]	1.84	2.33	2.05
PRNet [Feng et al. 2018b]	1.50	1.98	1.88
Deng et al.19 [2019]	1.23	1.54	1.29
RingNet [Sanyal et al. 2019]	1.21	1.54	1.31
3DDFA-V2 [Guo et al. 2020]	1.23	1.57	1.39
MGCNet [Shang et al. 2020]	1.31	1.87	2.63
DECA (ours)	1.09	1.38	1.18

②Feng et al. benchmark

135人の顔画像(2000枚)+3Dスキャンデータ
低解像度と高解像度に分かれている


Method	Median (mm)		Mean (mm)		Std (mm)	
	LQ	HQ	LQ	HQ	LQ	HQ
3DMM-CNN [Tran et al. 2017]	1.88	1.85	2.32	2.29	1.89	1.88
Extreme3D [Tran et al. 2018]	2.40	2.37	3.49	3.58	6.15	6.75
PRNet [Feng et al. 2018b]	1.79	1.59	2.38	2.06	2.19	1.79
RingNet [Sanyal et al. 2019]	1.63	1.59	2.08	2.02	1.79	1.69
3DDFA-V2 [Guo et al. 2020]	1.62	1.49	2.10	1.91	1.87	1.64
DECA (ours)	1.48	1.45	1.91	1.89	1.66	1.68

定性評価

①Coarse Reconstruction



②Detail Reconstruction



論文紹介

EMOCA: Emotion Driven Monocular Face Capture and Animation

目的

- 入力画像からより表情豊かな3D顔モデルの生成を可能に
- 生成する3D顔形状が入力画像の感情と一致しない問題を、表情に関する損失感数を導入することで解決



図. 入力画像に対して再構成された疎・密な3D顔形状[1]

論文紹介

EMOCA: Emotion Driven Monocular Face Capture and Animation

全体アーキテクチャ

- DECAの表情パラ ψ のみ別の表情エンコーダで訓練し、感情認識用ネットワークからの特徴量で損失計算




図. EMOCAのアーキテクチャ[1]

論文紹介

EMOCA: Emotion Driven Monocular Face Capture and Animation

損失関数

- Coarse stageでのみ変更

$$L_{coarse} = \lambda_{emo} L_{emo} + \lambda_{pho} L_{pho} + \lambda_{eye} L_{eye} + \lambda_{mc} L_{mc} + \lambda_{lc} L_{lc} + \lambda_{\psi} L_{\psi}$$

Emotion consistency loss

- 感情整合性損失は、入力画像の感情特徴 $\epsilon_I = A(I)$ とレンダリング画像の感情特徴 $\epsilon_{Re} = A(I_{Re})$ の間の差を計算

$$L_{emo} = ||\epsilon_I - \epsilon_{Re}||_2$$

Emotion Recognition Network

- 感情離散ラベルやvalence/arousal予測するResNet-50ネットワーク
- 7つの感情離散ラベルとvalosal/arousalがアノテーションされたAffectNet-DBで訓練





図. EMOCAのアーキテクチャ中の損失計算部分[1]

論文紹介

EMOCA: Emotion Driven Monocular Face Capture and Animation

定量評価

- Emotion Recognitionによる定量評価
 - 顔モデルを復元する際に用いる3DMMパラメータを入力とする感情予測NNを学習
 - 感情予測が高精度
- ⇒感情に関して詳細な特徴を表現できる3DMMパラを入力画像から抽出できてる



Model	V-PCC ↑	V-CCC ↑	V-RMSE ↓	V-SAGR ↑	A-PCC ↑	A-CCC ↑	A-RMSE ↓	A-SAGR ↑	E-ACC ↑
EmoNet [88]	0.75	0.73	0.32	0.80	0.68	0.65	0.29	0.78	0.68
Deep3DFace [20]	0.75	0.73	0.33	0.80	0.66	0.65	0.31	0.78	0.65
ExpNet [15]	0.45	0.42	0.43	0.73	0.39	0.36	0.38	0.64	0.46
MGCNet [78]	0.71	0.69	0.35	0.80	0.59	0.58	0.34	0.77	0.60
3DDFA_V2 [36]	0.63	0.62	0.39	0.75	0.53	0.50	0.34	0.73	0.52
DECA [28]	0.70	0.69	0.36	0.76	0.59	0.58	0.33	0.74	0.59
DECA w/ details [28]	0.70	0.69	0.37	0.77	0.59	0.57	0.33	0.77	0.58
EMOCA (Ours)	0.78	0.77	0.31	0.81	0.69	0.68	0.30	0.81	0.68
EMOCA w/ details (Ours)	0.77	0.76	0.31	0.81	0.70	0.69	0.29	0.83	0.69

図. 各生成モデル・感情認識ネットワークによる予測精度の比較[1]

論文紹介

EMOCA: Emotion Driven Monocular Face Capture and Animation

定性評価

- Coarse stageとdetail stageでの3D顔形状をその他生成モデルと比較



図. detail形状での比較 vs DECA[1]

図. Coarse形状での比較[1]

論文紹介

EMOCA: Emotion Driven Monocular Face Capture and Animation

Ablation Study

- 学習データの変更(FFHQ⇒Affect Net)による効果より、Emotion Consistency Lossによる効果大きい

EMOCA DS w/o EMO : DECAにExpression Encoderをつけただけ

EMOCA w/o EMO : AffectNetで学習したが、Emotion Consistency Lossなし

EMOCA DS : FFHQで学習

Model	V-PCC ↑	V-CCC ↑	V-RMSE ↓	V-SAGR ↑		A-PCC ↑	A-CCC ↑	A-RMSE ↓	A-SAGR ↑	E-ACC ↑
DECA [28]	0.70	0.69	0.36	0.76		0.59	0.58	0.33	0.74	0.59
EMOCA DS w/o Emo	0.70	0.69	0.37	0.78		0.61	0.58	0.32	0.79	0.60
EMOCA w/o Emo	0.68	0.66	0.36	0.74		0.59	0.58	0.32	0.77	0.59
EMOCA DS	0.77	0.76	0.31	0.82		0.69	0.67	0.29	0.79	0.68
EMOCA	0.78	0.77	0.31	0.81		0.69	0.68	0.30	0.81	0.68

図. Ablation Study結果[1]

1. 論文紹介 part1

- A) DECA
- B) EMOCA

2. 実装状況

- A) NeRFモデル
- B) DECA
- C) EMOCA
- D) DiffusionRig

3. 今後の方針(石黒)

4. 論文紹介 part2

- A) DiffusionAutoencoders

5. 今後の方針(野口)

研究進捗

FENeRFの失敗

- 公式のFENeRFのFFHQを用いたトレーニング：約200日
- 計算効率の高いNeRF(Instant NGP)と、より疎な学習率を設定したトレーニング：約1.5か月

原因

- 論文中に実行環境、実行時間の記載なし
- 一つの3Dオブジェクトに対し、複数回のNeRFのボリュームレンダリング
 - ビューの一貫性向上
 - 計算回数が多い、計算負荷が高い→メモリを多く消費するため、パッチ数も増やせない
- FENeRFをGANからDiffusionに変えたDiffusioNeRFも実装断念

今後




- PCAにより低負荷、かつ3DFaceに最適化された3DMM主体の手法に回帰
- DiffusionRig(実装済み)の改良に注力
 - 1枚の画像から生成したFLAME(3DMM)を条件付けしたDiffusionで画像生成
 - FFHQを用いたトレーニング：約1週間
 - 推論：30分+15秒

EMOCAによる出力結果



Input






Geometry(coarse)



Geometry(detail)



Albedo map






研究進捗

EMOCAによる出力結果


Input





Geometry(coarse)



Geometry(detail)
EMOCA



Geometry(detail)
DECA



Wild image(detail)



研究進捗

DiffusionRigの編集結果

Source

target

生成画像

exp



lighting



pose



研究進捗

DiffusionRigの編集結果(感情変化)

Source

target

生成画像

Exp
flown



Exp
smile



Exp
none



1. 論文紹介 part1

- A) DECA
- B) EMOCA

2. 実装状況

- A) NeRFモデル
- B) DECA
- C) EMOCA
- D) DiffusionRig

3. 今後の方針(石黒)

4. 論文紹介 part2

- A) DiffusionAutoencoders

5. 今後の方針(野口)

研究方針

やりたいこと

1. DECAをEMOCAへ
2. 表情専用のエンコーダ追加




図. DiffusionRigのアーキテクチャ

研究方針

課題

1. DECAをEMOCAへ

- DECA周りのコードが複雑
- DECAとEMOCAの出力は同じであるが、レンダリング方法が少し異なる

2. 表情専用のエンコーダ追加

- 入力画像と生成画像の感情特徴量抽出ネットワークが必要
- 感情カテゴリやarousal・valenceをラベル付けしたデータセットが必要




図. EMOCAのアーキテクチャ

1. 論文紹介 part1

- A) DECA
- B) EMOCA

2. 実装状況

- A) NeRFモデル
- B) DECA
- C) EMOCA
- D) DiffusionRig

3. 今後の方針(石黒)


4. 論文紹介 part2

- A) DiffusionAutoencoders

5. 今後の方針(野口)

Diffusion Autoencoders: Toward a Meaningful and Decodable Representation

Konpat Preechakul Nattanat Chatthee Suttisak Wizadwongsa Supasorn Suwajanakorn VISTEC, Thailand



目的


自然画像に対するmanipulationやinterpolationなどの画像編集で高品質な結果を出力する

取り組んだ問題と背景

従来の拡散モデルの条件付け(テキスト)などだと思いうように画像編集を行うことができない問題が発生
→入力画像の再構成を正確にしつつ、一部の部分だけ正確に変更できるようにする

髪型や表情の変更など

概要



- ✓ 画像を物体の大まかな情報を持つ z_{sem} と詳細部分の情報を持つ x_T に分離して表現
- ✓ z_{sem} で条件付け、 x_T を潜在変数とした生成を拡散モデルを用いて行う
- ▶ 画像の重要箇所のみ編集が可能に

使用する拡散モデルの選択

Step1：空間的に細かな編集が目的

- GAN：潜在変数の次元が1次元
- 拡散モデル：潜在変数の次元が2次元

→GANは空間的情報を捉えづらいので**拡散モデル**を選択

Step2：正確な再構成が目的

- DDPM：ノイズを除去して画像を生成する「確率的な」拡散モデル
- DDIM：DDPMのステップ数を減らす、「決定論的な」拡散モデル

→DDPMは確率的なので正確な構成に不向きなので**DDIM**を選択

一部分のみの画像編集



(c) DDIM interpolation.

DDIMでinterpolationを行なっても顔自体の自然な合成は不可能
→周辺のパixel値に大きく影響されてしまうから

画像を物体の**大まかな情報**を持つ Z_{sem} と**詳細部分の情報**を持つ X_T に分離して表現することで解決を目指す

画像編集方法


interpolation

二つの入力画像から得られる (Z_{sem}, X_T) の組み合わせを用いて超球面上の内挿で計算

attribute変換

ラベル付きデータセットと学習済み生成モデルを用いてattribute境界を取得
境界を用いてattribute変換の移動方向を求める
これを用いて線形変換される

詳細設計



【Semantic encoder】

設計に制限はなし

今回使用されているのはDDIMの前半部分(U-Net)

【Stochastic encoder】

DDIMのデノイズの逆プロセスとして実装

$$x_{t+1} = \sqrt{\alpha_{t+1}} f_{\theta}(x_t, t, z_{sem}) + \sqrt{1 - \alpha_{t+1}} \epsilon_{\theta}(x_t, t, z_{sem})$$

学習方法

$$\text{損失関数: } L_{\text{simple}} = \sum_{t=1}^T \mathbb{E}_{\mathbf{x}_0, \epsilon_t} \left[\|\epsilon_{\theta}(\mathbf{x}_t, t, \mathbf{z}_{\text{sem}}) - \epsilon_t\|_2^2 \right]$$

この損失関数では、 θ, ϕ が学習される(θ : DDIMのパラメーター、 ϕ : Semantic encoderのパラメーター)

Z_{sem} は、右式でU-Netに入力される: $\text{AdaGN}(\mathbf{h}, t, \mathbf{z}_{\text{sem}}) = \mathbf{z}_s(\mathbf{t}_s \text{GroupNorm}(\mathbf{h}) + \mathbf{t}_b)$

定性評価

 X_T を変えて評価

Input

Reconstruction
 (z_{sem}, x_T) Varying stochastic subcode (z_{sem}, x_T^i)

定性評価



Real image → Wavy hair



Real image → Smiling



Younger

Real image

Older



Real image


Real image

定性評価

Z_{sem} で X_0 を予測する実験(timestep=10：左から9,8,7,5,2,0)



(a) DDIM predicting x_0 .



(b) Our diffusion autoencoder predicting x_0 .

DDIMよりも高速な推論が可能

1. 論文紹介 part1

- A) DECA
- B) EMOCA

2. 実装状況

- A) NeRFモデル
- B) DECA
- C) EMOCA
- D) DiffusionRig


3. 今後の方針(石黒)

4. 論文紹介 part2

- A) DiffusionAutoencoders

5. 今後の方針(野口)

Step1 : 表情編集に特化したDDIMを訓練



表情特化DiffusionAutoencoders

Step2 : 変換前後で β 変化しないように訓練

