

第15回定期ミーティング

2025/03/24

早稲田大学 基幹理工学研究科
電子物理システム学専攻 史研究室
石黒将太郎・野口颯汰


1.研究テーマ

2.先行研究

- 前回の補足
- 先行研究

3.今後の研究計画

表情変換顔生成モデル(Diffsion)と2Dto3D顔形状を生成するモデルを組み合わせることで、3Dの表情変換を軽量化かつ自然に行う



- 1 性能の良い**分類機**に変更
- 2 2D**アイデンティティ損失**を追加
- 3 3D**アイデンティティ損失**を追加

図. DECA[1]とDiffusionAutoencoders[2]を元にした提案モデル

[1] YAO FENG et al. Learning an Animatable Detailed 3D Face Model from In-The-Wild Images

[2] Konpat Preechakul et al. Diffusion Autoencoders: Toward a Meaningful and Decodable Representation

1.研究テーマ

2.先行研究

- 前回の補足
- 先行研究

3.今後の研究計画

DreamBoothは拡散モデルのファインチューニングにおける欠点を解決

DreamBooth (Ruiz et al., 2023) の概念

従来の研究：入力画像に対する少数の画像を用いたファインチューニング

欠点：

- 入力画像に対する過学習
- 既存の知識が失われる可能性（人の顔とは？などの一般的な概念）


DreamBooth：

- 事前学習済みの拡散モデルを利用して、対象の概念に関連する画像セットを生成
- この画像をトレーニング中に使用し、モデルの合成能力を維持する

方法：拡散モデルの損失関数 + 事前知識保持目的関数の組み合わせによるファインチューニング

事前知識保持関数：
$$\mathcal{L}_{PR} = \mathbb{E}_{z_{pr}, c_{pr}, \epsilon', t'} [\epsilon_{pr} - \epsilon_{\theta}(z_{pr, t'}, t', c_{pr}) \|_2^2]$$

1. デノイジングネットワークのみの学習(コスト面のため)
2. LoRAという追加する新しいレイヤーのみ学習し、事前学習済みの重みは変更しない



画像生成の流れ

1. 入力画像を**Semantic encoder**と**Stochastic encoder**に入力
2. **Semantic encoder**で意味的情報 z_{sem} を抽出
3. **Stochastic encoder**で画像の詳細情報 x_T を抽出
4. **線形分類器**から属性の方向を示す重みベクトルを取得
5. 抽出された z_{sem} に対して、重みベクトルを加算
6. 操作後の z_{sem} と x_T を**Decoder**に入力し、属性変更した画像を生成

Manipulationにおける訓練

1. Diffusion Autoencoderの訓練

$$L_{\text{simple}} = \sum_{t=1}^T \mathbb{E}_{x_0, \epsilon_t} \left[\|\epsilon_\theta(x_t, t, z_{sem}) - \epsilon_t\|_2^2 \right]$$

2. 線形分類器の訓練

入力された z_{sem} に対して、以下の重みベクトルを推定

$$z_{sem_new} = w^T z_{sem} + b$$

今回発見した新しい改善余地：

線形分類器の改善、AffectNetを用いたDiffusionAutoencoderの訓練

DiffusionAutoencodersの分類機：

単純な線形分類器を使用

【理由】 提案する潜在空間の**品質**と**適用可能性**を示すため

□ 線形分類器の訓練

入力された z_{sem} に対して、以下の重みベクトルを推定

$$z_{sem_new} = w^T z_{sem} + b$$




図. 線形分類器の課題 [3]

問題点

非線形性の限界

- 複雑な属性は線形の境界で分離できない
- 単純な線形超平面では、データの本質的な構造を捉えきれない

操作結果の制御性低下

- 属性の変更が他の特徴にも影響を与え、望ましくない変化を引き起こすことがある
- 精度が低いと、目的の属性だけでなく、顔の他の部分や背景も変化してしまう


Denoising Diffusion Autoencoders are Unified Self-supervised Learners

Weilai Xiang^{1,2} Hongyu Yang^{1,3*} Di Huang² Yunhong Wang^{1,2}

¹State Key Laboratory of Virtual Reality Technology and Systems, Beihang University, Beijing, China

²School of Computer Science and Engineering, Beihang University, Beijing, China

³Institute of Artificial Intelligence, Beihang University, Beijing, China



• 拡散モデルが生成と識別両方のタスクが実行可能であることを検証

取り組んだ問題：

コンピュータビジョンにおける、自然言語処理（NLP）のBERTやGPTのような、生成能力と識別能力を両立する統一的な自己教師あり学習アプローチの提案

その背景：

1. 自己教師あり学習の重要性の高まり
2. コンピュータビジョンにおける統一的な生成-識別モデルの課題
3. 拡散モデルの登場
4. 拡散モデルとオートエンコーダーの関連性

▶ 生成的事前学習（generative pre-training）を通じて、拡散モデルが分類に適した識別的表現（discriminative representations）を獲得できるかを検討

▶ 拡散事前学習が、生成と識別の両方の学習のための一般的なアプローチとして確立されることを目指す

• 代表的な拡散モデルで検証

今回の検証を行う代表的な三つの拡散モデル

1. オリジナルのDDPM Unet
2. EDMで訓練されたDDPM++
3. 潜在空間ViTを用いたDiT

【それぞれの特徴】

•DDPM（およびDDPM++）

- UNetを使用し、タイムステップ埋め込みを用いて、 $\epsilon_{\theta}(x_t, t)$ または $D_{\theta}(x_t, t)$ をパラメータ化する。

•DiT（Diffusion Transformer）

- 潜在空間の**Vision Transformer（ViT）**を使用。
- タイムステップ埋め込みと**ラベル埋め込み**を用いて、条件付き生成用の $\epsilon_{\theta}(x_t, y, t)$ 学習。
- 同時に、無条件モデル $\epsilon_{\theta}(x_t, \emptyset, t)$ も学習し、「分類器なしガイダンス（classifier-free guidance）」によるサンプリングを可能にする。
- **クラス条件付き** ImageNet 生成で**最先端（state-of-the-art）**の結果を達成。

• 拡散モデルにおける識別的表現の抽出と活用に向けた検討

DDAEから意味のある識別的表現を抽出することは容易ではない

DDIMのような決定論的推論手法を用いれば、一意に識別可能なエンコーディングを導出することは可能
しかし、その情報は分類タスクには十分にコンパクトではないため、直接的な応用は難しい

追加のエンコーダ（auxiliary encoders）を導入して識別的な表現を学習する手法もある

属性操作・分類（classification）

ただし、これらの手法は追加の学習が必要であり、拡散モデルの枠組みを変更することになる。

今回は事前学習済みのDDAEの中間層の線形分離可能な表現を直接利用する方法を提案

DDPM-segに基づき、層ごとの特徴の質とノイズスケールをグリッドサーチ（grid search）で検証

• 拡散モデルの識別学習器としての評価

事前学習済みの拡散モデルを画像分類タスクにおける識別学習器として評価するための2つの主要な手法

1. 線形プローブ



手法:

1. 拡散モデルの**特定の間層**における特徴を抽出
2. 抽出された特徴に対し、**単純な線形分類器**（例：ロジスティック回帰）を**ラベル付きデータ**を用いて学習。**拡散モデルの重みは学習中固定**
3. 学習された線形分類器の**分類精度**を測定し、中間層の表現の質を評価

結果:

最適な特徴は、ネットワークのアップサンプリングの中間層に存在
比較的少ないノイズで摂動させた画像から抽出された特徴が、高い分類精度を示す

層の深さとノイズのスケールは、特徴の質に複合的な影響を与える



• 拡散モデルの識別学習器としての評価

事前学習済みの拡散モデルを画像分類タスクにおける識別学習器として評価するための2つの主要な手法

2. ファインチューニング

手法:

1. 線形プローブで見つかった**最適な表現層で拡散モデルを切り詰め**、画像エンコーダとして利用
2. **ノイズなしの画像**をエンコーダに入力し、抽出された特徴を分類層（通常は線形層）に接続
3. **ラベル付きデータ**を用いて、**切り詰められたエンコーダ全体（または最後の数層と分類層）の重みを更新**します。




図. 拡散モデルを自己教師あり識別学習モデルとして評価するフロー


• ラベルなしでの層選択モニタリング

拡散モデルが識別タスクに対して高品質な表現を学習する一方で、適切なネットワーク構成（特に特徴を抽出する層）の探索にラベル付きデータが必要となる可能性がある

→ 訓練中にラベルなしで最適な層を判断できる指標があれば、層探索の効率化につながる

提案手法：特徴分布の分析（アライメントと均一性）

- アライメント損失：異なるノイズサンプルで生成した同一画像の特徴ベクトル間の距離を評価
- 均一性損失：データ分布全体における、異なる画像の特徴ベクトルの分布の一様性を測定



• 多段階ノイズ除去が拡散モデルの表現学習に与える影響

ノイズレベルの数 (T) と ノイズスケールの範囲 ($\beta_{1...T}$) の2つの要素に着目

前提

- DDPMのデフォルト $T=1000$ を 512, 256, 64 に削減して実験
- ノイズスケジュールは、 $[\beta_{min}, \beta_{max}]$ ($\beta_{min} = 10^{-4}$, $\beta_{max} = 0.02$) の範囲で線形配置

結果

1. 最大のノイズレベル数 ($T=1000$) と最も広いノイズスケール範囲を持つ拡散モデルが、画像生成と認識の両方で最高の性能を達成
2. ノイズレベルを減らすか、ノイズ範囲を狭めると、生成性能と識別性能の両方が低下
3. 訓練の進行を追跡すると、より優れた生成モデルはより優れた表現を学習する傾向
4. 認識は生成よりも早く過学習する傾向

結論


二つの要素の設計が、拡散モデル を強力な識別学習器とする重要な要因である

• 生成的事前学習による認識能力の向上


より高度な生成的事前学習が、認識タスクの性能向上にどのように貢献するのか

基本的なDDPM UNet（35.7Mパラメータ）と、EDMによって訓練されたDDPM++を比較検討

EDM は DDPM よりも生成性能と識別性能の両方で優れている



(a) DDAEs in DDPM and EDM trained on CIFAR-10.



(b) DDAEs in DDPM and EDM trained on Tiny-ImageNet.

結論：生成的事前学習の改善は、認識モデルの性能向上に大きく貢献する

- 生成的事前学習が、強力な識別表現を獲得するための有効なアプローチである

表.拡散モデルベースの表現学習手法との比較

Method	Evaluation	Generation FID	Acc. %
<i>on CIFAR-10</i>			
WideResNet-28-10 [63]	Supervised	N/A	96.3
DRL/VDRL [1, 37]	Non-linear	~3.0	<80.0
HybViT [61]	Supervised	26.4	95.9
SBGC [67]	Supervised	*	95.0
DDAE (EDM)	Linear	2.0	95.9
DDAE (EDM)	Fine-tune	N/A	97.2
<i>on Tiny-ImageNet</i>			
WideResNet-28-10 [63]	Supervised	N/A	69.3
HybViT [61]	Supervised	74.8	56.7
DDAE (EDM)	Linear	19.5	50.0
DDAE (EDM)	Fine-tune	N/A	69.4

既存の教師あり・教師なしの拡散モデルベースの手法よりも優れた生成性能と認識精度

特にCIFAR-10では、最先端のハイブリッドモデルと同等以上の性能

結論:

- ✓ 拡散モデルの事前学習は、生成と認識の両面で優れた能力を持つ統一的なモデルを開発するために有効
- ✓ 今後の研究では、認識タスクに最適化されたバックボーン的设计、学習効率の向上、そして他の自己教師あり学習パラダイムとの統合などが重要な課題である

手法	計算コスト・学習負荷	精度向上の可能性	システム適用性・統合の容易さ	技術的課題・注意点
SVM（非線形カーネル）	- カーネル行列計算により大規模データの場合は学習コストが高い - 予測はサポートベクター数に依存	- 適切なカーネル選択とハイパーパラメータ調整で高い分類性能が期待できる - 線形分離できないパターンも捉え可能	エンコード済みの潜在ベクトルを入力する独立モジュールとして容易に統合可能	- 判定境界が局所的な勾配になるため、単純なベクトル加算での属性操作が困難 - 属性変更のための最適化的手法（反復更新など）が必要
ランダムフォレスト	- 並列化可能で学習は比較的高速 - 多数の決定木を構築するため、データ量や木の数によってはモデルサイズ・予測計算が増大	多数の木による多数決でノイズに強く、非線形な特徴相関を捉えやすい	エンコード後の潜在ベクトルを直接入力でき、既存パイプラインへの後付けが容易	非微分可能なため、勾配情報を直接利用できず属性操作に工夫が必要 - 複数属性を扱う場合は個別モデルの管理やヒューリスティックな調整が必要
深層学習ベースの分類器（MLP/CNN/Transformer）	- MLPは小規模なら高速 - CNN/Transformerは計算資源（GPU等）が必要	- 十分なデータがあれば線形分類器を大幅に上回る精度が得られる - MLPの場合、勾配伝播により属性操作の方向性を直接活用できる	- MLPは潜在コードに直接接続でき統合が容易 - CNN/Transformerは画像→分類器のパイプラインとなるため実装はやや複雑	データが少ない場合の過学習リスク
半教師あり・自己教師あり手法	- 追加の学習ステージが必要となるため、全体のトレーニングコストは上昇 - 推論時は採用する分類器次第	- 限られたラベルデータでも未ラベルデータを活用でき、精度向上が期待できる - 自己教師ありにより潜在表現そのものの分離性が改善される可能性がある	最終的な分類器はシンプルに保てるが、事前学習フェーズや擬似ラベル付与などの工程が追加されるため、パイプライン全体は複雑化する可能性がある	- 誤った擬似ラベルによるバイアスリスクの管理が必要 - 自己教師ありタスクの設計次第で、有用な特徴が学習できないリスク - 実装と学習手順が複雑になり、チューニングコストの増加が懸念される


1.研究テーマ

2.先行研究

- DDIMの損失関数
- DiffusionAutoencoderの損失関数
- 他のDiffusionモデルのアイデンティティ損失追加方法

3.今後の研究計画

今回発表した改善点を随時実装



1.商用利用可能モデルについての調査

- monoNPHM

2. 2024年度レポート

Appendix. NPHM

MonoNPHM: Dynamic Head Reconstruction from Monocular Videos

Simon Giebenhain, Tobias Kirschstein, Markos Georgopoulos, Martin Runz ,
Lourdes Agapito, Matthias Nießner
Technical University of Munich, Synthesia, University College London




図1：NPHMの出力結果

取り組んだ問題と背景

- ✓ 単眼RGB画像から3D頭部ジオメトリを構成したいが、複雑な顔の形や光などの影響を十分に考慮するために、顔の構造、表情、外観に関する仮定をモデル化したPrior情報を導入する必要あり
- ✓ 3DMMは最も一般的なPrior情報であるが、テンプレートメッシュの精度に依存するため、表現力に限界がある

このモデルの特徴

- ✓ ジオメトリ、表情を共同でモデル化し、Hyper-Dimensionsを追加することで動的能力(表情の変化や光の当たり方)を向上
- ✓ 学習途中にポーズ空間と標準空間を生成することで、学習の効率化と、表情やポーズをより独立的に扱える

標準空間 (Canonical Space)


Canonical Geometry Representation

- 頭部の形状は、標準空間において z_{geo} を用いて NN-SDF として表現
- 柔軟なトポロジーによって髪を含む完全な頭部を表現可能

Canonical Appearance Representation

- 外観は z_{app} を用いてテクスチャフィールドを条件づけることでモデル化
- 外観潜在空間とジオメトリ潜在空間が完全に独立してしまうと、外観由来の勾配変化にジオメトリが追従できなくなってしまう

⇒ F_{geo} 最終層由来の特徴 $h_{geo}(x_c)$ を F_{app} に条件づけ



Posed Space & Canonical Space

変形ネットワーク D_{exp}


- z_{exp} と z_{geo} によって条件付けされる
- ポーズ空間中の点(x_p)を標準空間中の点(x_c)に変換

$$\mathcal{D}_{exp} : \mathbb{R}^{3+d_{exp}+d_{geo}} \rightarrow \mathbb{R}^3, x_p \mapsto x_c$$

Hyper-Dimensionsの導入

- 空間的3次元による制約から抜け出すため、出力に高次元成分を付与
- 論文中では ω によって5次元に拡張
- ネットワーク全体の動的能力が向上

$$\mathcal{D}_{exp}(x_p; \mathbf{z}_{exp}, \mathbf{z}_{geo}) = (x_c, \omega) \in \mathbb{R}^{3+h},$$



トレーニング

入力データ


- RGBフレーム
- シルエット
- 2D顔ランドマーク

モデルパラメータ

- z_{geo} : 時間不変
- z_{app} : 時間不変
- z_{exp}^t : フレームごとに変化
- $\{R_t, t_t\}$: 頭部ポーズ
- Φ_{sh} : 証明パラメータ (SH関数)

損失関数

$$\operatorname{argmin}_{\phi, \zeta, \Pi} \sum_{t=1}^T \mathcal{L}_{\text{RGB}}^t + \lambda_{\text{sil}} \mathcal{L}_{\text{sil}}^t + \lambda_{\text{lm}} \mathcal{L}_{\text{lm}}^t + \lambda_{\text{reg}} \mathcal{L}_{\text{reg}}^t$$



定量指標

L1-Chamfer距離：

- 再構築のメッシュと測定済み深度マップの単方向での誤差


法線コサイン距離：

- 再構築メッシュ法線と測定済みジオメトリのメッシュ法線の類似性


recall：

点群のあるべき位置から、設定したしきい値内にいる再構成点群の割合

Method	L_1 -Chamfer ↓	N. C. ↑	Recall@2.5mm ↑
DECA [20]	0.0034	0.917	0.644
MICATracker [98]	0.0030	0.932	0.654
NHA [30]	0.0055	0.872	0.490
IMavatar [93]	0.0054	0.888	0.625
HeadNeRF [33]	0.0049	0.883	0.504
Ours	0.0024	0.940	0.785



Expression Transfer



monoNPHMリポジトリ上のライセンス文

```
1 MIT License
2
3 This License only concerns the code provided in this repository, but not the associated data or pretrained models.
4 It DOES NOT concern the NPHM dataset, which is distributed with a separate, much stricter license.
5
6 Copyright (c) 2024 Simon Giebenhain, Tobias Kirschstein, Markos Georgopoulos, Martin Rünz, Lourdes Agapio and Matthias Nießner
7
8 Permission is hereby granted, free of charge, to any person obtaining a copy
9 of this software and associated documentation files (the "Software"), to deal
10 in the Software without restriction, including without limitation the rights
11 to use, copy, modify, merge, publish, distribute, sublicense, and/or sell
12 copies of the Software, and to permit persons to whom the Software is
13 furnished to do so, subject to the following conditions:
14
15 The above copyright notice and this permission notice shall be included in all
16 copies or substantial portions of the Software.
17
18 THE SOFTWARE IS PROVIDED "AS IS", WITHOUT WARRANTY OF ANY KIND, EXPRESS OR
19 IMPLIED, INCLUDING BUT NOT LIMITED TO THE WARRANTIES OF MERCHANTABILITY,
20 FITNESS FOR A PARTICULAR PURPOSE AND NONINFRINGEMENT. IN NO EVENT SHALL THE
21 AUTHORS OR COPYRIGHT HOLDERS BE LIABLE FOR ANY CLAIM, DAMAGES OR OTHER
22 LIABILITY, WHETHER IN AN ACTION OF CONTRACT, TORT OR OTHERWISE, ARISING FROM,
23 OUT OF OR IN CONNECTION WITH THE SOFTWARE OR THE USE OR OTHER DEALINGS IN THE
24 SOFTWARE.
```

- DECAはソフトウェア全体が商用利用不可だが、monoNPHMはリポジトリ内のコードは商用利用可能
- 訓練に必要な独自の3Dデータセットはダメ (FaceScape・Faceverseも商用利用不可)
- <https://www.3dscanstore.com/hd-head-scans/hd-head-models> ⇐このようなサイトで買う？

- [ここに格納](#)

Shotarolshiguro / 2024_ResearchReport

🔍

🔒

+

🕒

🔗

📧

<> Code

🕒 Issues

🔗 Pull requests

🕒 Actions

📁 Projects

📖 Wiki

🛡 Security

📈 Insights

...

2024_ResearchReport

Private

👁 Unwatch 1

🍴 Fork 0

☆ Star 0

main

🔗

📄

Go to file

+

<> Code

Shotarolshiguro

回復

5bfff70 · 4 days ago

🕒

📁 発表資料	14回資料のEmonetに関する間違い...	last week
📁 石黒	回復	4 days ago
📁 野口	回復	4 days ago
📄 .gitignore	Update .gitignore	2 weeks ago
📄 2024Report_石黒.pdf	石黒レポート 最終版	4 days ago
📄 README.md	Update README.md	2 weeks ago

📖 README

✎

☰

2024_ResearchReport

2024年度の研究成果をまとめたリポジトリです。

早稲田大学大学院 基幹理工学研究科 電子物理システム学専攻 史研究室
石黒将太郎・野口颯汰

About

⚙

2024年度の研究成果をまとめたリポジトリです。

📖 Readme

👤 Activity

☆ 0 stars

👁 1 watching

🍴 0 forks

Releases

No releases published

[Create a new release](#)

Packages

No packages published

[Publish your first package](#)

Languages

Python 97.4%

Jupyter Notebook 1.7%

Other 0.9%

Learning Neural Parametric Head Models

Simon Giebenhain, Tobias Kirschstein, Markos Georgopoulos, Martin Runz ,
Lourdes Agapito, Matthias Nießner
Technical University of Munich, Synthesia, University College London




図1：NPHMのモデルアーキテクチャ

取り組んだ問題と背景

- ✓ 3D Faceを表現するためのパラメトリック空間として主流であるのは、DECAにも使用されているFLAMEであり、複数の3D Faceデータセットをテンプレートフィッティング後に、PCA分析をベースとした手法で組み立てられる
- ✓ PCAベースの手法は、入力データに対する剛性に優れるという特徴を持つが、局所的な表面の微細な表現に弱いことや、固定されたテンプレートメッシュを基にするため髪形や歯の生成ができない

このモデルの特徴

- ✓ ニューラルパラメトリックヘッドモデル(NPHM)は、顔のキーポイントを中心とする局所座標が対象とする小さなMLPを複数導入することにより、局所的な表面の表現が得意
- ✓ SDFによってcanonical spaceでの頭部ジオメトリを表現してから、ポーズ空間で形状変化を学ぶため、アイデンティティと表情を表現する潜在空間の分離度が高い
- ✓ 255人を対象とした平均3.5Mサイズの頭部スキャンを5200以上用意し、これらをもとにトレーニングすることでトレーニング時の正確なフィッティング誤差を得る

3Dデータセット

Num. Subjects	255 (188m/67f)
Total num. Scans	5200
Num. Vertices/Scan	$\approx 1.5\text{M}$




表2：NPHMの3Dデータセットについて

モデルアーキテクチャ




図2：NPHMのトレーニング過程

損失関数

$$\mathcal{L}_{\text{id}} = \sum_{j \in J} \mathcal{L}_{\text{IGR}} + \lambda_a \|\hat{\mathbf{a}}_j - \mathbf{a}_j\|_2^2 + \lambda_{\text{sy}} \mathcal{L}_{\text{sy}} + \lambda_{\text{reg}}^{\text{id}} \|\mathbf{Z}_j^{\text{id}}\|_2^2,$$

$$\mathcal{L}_{\text{ex}} = \sum_{\substack{i, j \in J, L \\ x \in X_{j, l}}} \|\mathcal{F}_{\text{ex}}(x, \mathbf{z}_{j, l}^{\text{ex}}, \hat{\mathbf{z}}_j^{\text{id}}) - \delta(x)_{j, l}\|_2^2 + \lambda_{\text{reg}}^{\text{ex}} \|\mathbf{z}_{j, l}^{\text{ex}}\|_2^2$$


表2：NPHMの3Dデータセットについて



定量評価(identity)

Method	L_1 -Chamfer ↓	N. C. ↑	F-Score@1.5 ↑
BFM [32]	1.341e−2	0.936	0.319
FLAME [21]	0.640e−2	0.931	0.530
Global PCA [2]	0.563e−2	0.954	0.571
Local PCA [2]	0.416e−2	0.960	0.756
ImFace [48]	0.404e−2	0.954	0.832
ImFace* [48]	0.312e−2	0.971	0.883
NPM [27]	0.200e−2	0.975	0.947
Ours	0.182e−2	0.978	0.954

* trained on our data

定性評価(identity)





定量評価(expression)

Method	L_1 -Chamfer ↓	N. C. ↑	F-Score@1.5 ↑
BFM [32]	1.271e−2	0.937	0.508
FLAME [21]	0.679e−2	0.924	0.351
Global PCA [2]	0.515e−2	0.956	0.606
Local PCA [2]	0.535e−2	0.950	0.641
ImFace [48]	0.369e−2	0.959	0.824
ImFace* [48]	0.321e−2	0.971	0.879
NPM [27]	0.299e−2	0.962	0.891
Ours	0.272e−2	0.969	0.913

* trained on our data

定性評価(expression)

