


第16回定期ミーティング

2025/04/25

早稲田大学 基幹理工学研究科
電子物理システム学専攻 史研究室
石黒将太郎・野口颯汰



画像生成の流れ

1. 入力画像を**Semantic encoder**と**Stochastic encoder**に入力
2. **Semantic encoder**で意味的情報 z_{sem} を抽出
3. **Stochastic encoder**で画像の詳細情報 x_T を抽出
4. **線形分類器**から属性の方向を示す重みベクトルを取得
5. 抽出された z_{sem} に対して、重みベクトルを加算
6. 操作後の z_{sem} と x_T を**Decoder**に入力し、属性変更した画像を生成

Manipulationにおける訓練

1. Diffusion Autoencoderの訓練

$$L_{\text{simple}} = \sum_{t=1}^T \mathbb{E}_{x_0, \epsilon_t} \left[\|\epsilon_{\theta}(x_t, t, z_{sem}) - \epsilon_t\|_2^2 \right]$$

2. 線形分類器の訓練

入力された z_{sem} に対して、以下の重みベクトルを推定

$$z_{sem_new} = w^T z_{sem} + b$$

今回発見した新しい改善余地：

線形分類器の改善、AffectNetを用いたDiffusionAutoencoderの訓練

非線形分類機：

メリット：潜在空間の非線形境界を捉えて属性操作精度を向上できる。

参考論文：Diffusion Models Beat GANs on Image Synthesis

Attention条件付け：

メリット：属性に関連する特徴へ重み付けして、狙った属性の生成制御精度を高める。


参考論文：High-Resolution Image Synthesis with Latent Diffusion Models

分類機なし条件付け：

メリット：明示的な分類器を不要にしつつ、多様で滑らかな属性変化を直接生成プロセスに組み込める。

参考論文：CLASSIFIER-FREE DIFFUSION GUIDANCE

今回発表した改善点を随時実装



Diffusion Models Beat GANs on Image Synthesis



• 拡散モデルはGANを超える画像品質を実現する

背景：

- **GANの限界**：GANはlikelihood-basedモデルと比較して**多様性を捉える能力が低い**
GANは**学習が不安定**であり、モデルが崩壊する恐れあり
- **Likelihood-basedモデルの可能性と課題**：
多様性を捉えやすく、学習も比較的容易である一方で、
サンプリング速度とサンプル品質が問題
- **Diffusionモデルの現状**：
分布の網羅性、安定した学習目標、容易なスケールといった特徴はあるが、
モデルアーキテクチャが徹底的に研究・洗練されていない（GANと比較して）

Diffusionモデルにおいて、**モデルアーキテクチャを改善し、さらに多様性と忠実度のトレードオフを制御する手法**を開発

AdaGANを導入することで、クラス情報を埋め込むこと& FID(忠実度)を向上できる

AdaGANとは、**タイムステップとクラスの埋め込み**を、**グループ正規化**の後に各残差ブロックに組み込むもの

$$\text{AdaGN}(h, y) = y_s \text{ GroupNorm}(h) + y_b$$

h : 最初の畳み込み後の残差ブロックの中間活性化

$y = [y_s, y_b]$: タイムステップとクラスの埋め込みの線形射影から得られる

y_s と y_b : それぞれスケールとバイアスを表す

表. AdaGANのアブレーション結果

Operation	FID
AdaGN	13.06
Addition + GroupNorm	15.08

AdaGANを導入することで**FID**を向上

• 条件付けは分類機を用いて行う

方法概要：

- ノイズ付き画像 x_t を入力とし、分類器 $p_\phi(y|x_t)$ を訓練
- 目的のクラス y に対して、分類確率の勾配 $\nabla_{x_t} \log p_\phi(y|x_t)$ を計算
- 勾配を利用して、**拡散サンプリング**を特定クラス方向にガイドする

方法

1. Classifier guided diffusion sampling (分類器による誘導を用いた拡散サンプリング)
2. Classifier guided DDIM sampling (分類器による誘導を用いたDDIMサンプリング)

分類機の勾配を利用して、条件付けを行うがDDIMには適応不可

- 入力**
- ・ **クラスラベル y** : 生成したい画像のクラス
 - ・ **勾配スケール s** : 分類器からの勾配の大きさを調整するためのハイパーパラメータ
 - ・ **拡散モデル**: 逆拡散過程における各ステップでの**平均 μ** と**分散 Σ** を予測するモデル
 - ・ **分類器**: ノイズ付与した画像が与えられたときに、クラス y に属する確率を予測するモデル
- 初期化** : 純粋なガウスノイズ x_T を標準正規分布 $N(0, I)$ からサンプリング
- 反復処理** : 現在のノイズレベルの画像 x_t に基づいて、拡散モデルから予測された**平均 μ** と**分散 Σ** を取得
 x_t における、分類器 p_ϕ によるクラス y の**対数確率の勾配**を計算
(勾配は、 x_t をクラス y に近づける方向を示す)
次のステップの画像 x_{t-1} を、以下の正規分布からサンプリング
- ・ **平均**: $\mu + s * \Sigma * \nabla_{x_t} \log p_\phi(y|x_t) \rightarrow$ **分類器による誘導**
 - ・ **分散**: 拡散モデルが予測した分散 Σ をそのまま使用
- 出力** : クラスラベル y に条件付けした最終的に得られる画像 x_0

この条件付けアルゴリズムは**DDIM** に**適応できない**

分類機の勾配を利用して、条件付けを行うがDDIMには適応不可

入力 : クラストラベル y : 生成したい画像のクラス
勾配スケール s : 分類器からの勾配の大きさを調整するためのハイパーパラメータ
拡散モデル: 逆拡散過程における各ステップでの平均 μ と分散 Σ を予測するモデル
分類器: ノイズ付与した画像が与えられたときに、クラス y に属する確率を予測するモデル

初期化 : 純粋なガウスノイズ x_T を標準正規分布 $N(0, I)$ からサンプリング

反復処理: 修正されたノイズ予測値 $\hat{\epsilon}$ を計算

$$\begin{aligned}\hat{\epsilon} &\leftarrow \epsilon_{\theta}(x_t) - \sqrt{1 - \bar{\alpha}_t} \nabla_{x_t} \log p_{\phi}(y|x_t) \\ x_{t-1} &\leftarrow \sqrt{\bar{\alpha}_{t-1}} \left(\frac{x_t - \sqrt{1 - \bar{\alpha}_t} \hat{\epsilon}}{\sqrt{\bar{\alpha}_t}} \right) + \sqrt{1 - \bar{\alpha}_{t-1}} \hat{\epsilon}\end{aligned}$$

出力 : クラストラベル y に条件付けした最終的に得られる画像 x_0

▶ DDIMの決定的サンプリングプロセスの中核であるノイズ予測を、分類器の勾配を用いて直接的に修正するというアプローチを取っているためこの条件付けアルゴリズムはDDIMに**適応できる**

スケール係数を1以上にすることで、画像の制御が可能になるかつ、忠実度は向上



左側の画像（分類器スケール 1.0）では、目的のクラスに合致する画像は生成されない

右側の画像（分類器スケール 10.0）では、よりクラスに一貫した画像が生成できる

図. 分類機の誘導による結果





図. 分類器の勾配のスケールを変化させた際のサンプル品質の変化


勾配スケールが1.0を超えて大きくなるにつれて、**Recall**（多様性の指標）は滑らかに低下する一方、**Precision**と**IS**（忠実性の指標）は向上

今回発表した改善点を随時実装



1. 実装状況

2. 研究計画





やったことリスト

- V/A出力モデル(EmoNet, MaxViT)をローカルで実装
- MaxViTを用いたV/A評価

やることリスト

- 複数の指標を使用した評価
 - V/Aの出力
 - アイデンティティの保持（野口）
- 感情認識用モデルの調査
- 編集を行う人物や表情に対して得意・不得意があるかを調査

データセット	Stage1 stage2	resnet	target expパラ	source expパラ	評価対象 モデル
FFHQ or AffectNet	DECA or EMOCA	18 or 50	DECA or EMOCA	DECA or EMOCA	32種類




Source画像とTarget画像間のArousal(MaxViT)

評価実験概要

- オバマ大統領をターゲット人物として使用
- 訓練データセットとしてAffectNetと従来のFFHQを用いた場合、それぞれ16種類のモデルを比較
- オバマ大統領の表情を転送した場合の、ターゲット画像とソース画像のArousalの差を計算
- ターゲット画像の表情をうまく転送できていれば、Arousalは同値になるはず

考察

- AffectNetで訓練した方がArousalの差が小さい
- 訓練モデルとしてEMOCAを使用すべき
- 推論時にTarget画像から特徴抽出するモデルとしてDECAを使ったほうが高性能(なぜ?)
- グローバルエンコーダとしてResNet18を使用すべき




Source画像とTarget画像間のValence(MaxViT)

評価実験概要

- オバマ大統領をターゲット人物として使用
- 訓練データセットとしてAffectNetと従来のFFHQを用いた場合、それぞれ16種類のモデルを比較
- オバマ大統領の表情を転送した場合の、ターゲット画像とソース画像のValenceの差を計算
- ターゲット画像の表情をうまく転送できていれば、Valenceは同値になるはず

考察

- AffectNetで訓練した方がValenceの差が小さい
 - 訓練モデルとしてEMOCAを使用すべき
 - グローバルエンコーダとしてResNet18を使用すべき
 - ターゲット人物の特徴抽出モデルとしてEMOCAを使用すべき
- 👉 Arousalでの考察と真逆




Source画像とTarget画像間のArousal(MaxViT)

評価実験概要

- 橋本環奈をターゲット人物として使用
- 訓練データセットとしてAffectNetと従来のFFHQを用いた場合、それぞれ16種類のモデルを比較
- オバマ大統領の表情を転送した場合の、ターゲット画像とソース画像のArousalの差を計算
- ターゲット画像の表情をうまく転送できていれば、Arousalは同値になるはず

考察

- 訓練モデルとしてEMOCAを使用すべき
- 推論時にTarget画像から特徴抽出するモデルとしてDECAを使ったほうが高性能(なぜ?)
- グローバルエンコーダとしてResNet18を使用すべき



Source画像とTarget画像間のValence(MaxViT)


評価実験概要

- 橋本環奈をターゲット人物として使用
- 訓練データセットとしてAffectNetと従来のFFHQを用いた場合、それぞれ16種類のモデルを比較
- オバマ大統領の表情を転送した場合の、ターゲット画像とソース画像のValenceの差を計算
- ターゲット画像の表情をうまく転送できていれば、Valenceは同値になるはず

考察

- 訓練モデルとしてEMOCAを使用すべき
- グローバルエンコーダとしてResNet18を使用すべき
- ターゲット人物の特徴抽出モデルとしてEMOCAを使用すべき

Valence: EMOCA, Arousal: DECA






評価実験概要

- オバマ大統領の表情を転送する前のソース画像と、転送後の出力画像を用意
- 2つの画像から顔認識モデルFaceNetによる特徴ベクトルを生成
- 特徴ベクトルのコサイン類似度をモデルごとに比較
- 1に近づくほどアイデンティティ損失が少ない

考察

- AffectNetで訓練したほうが損失が少ないが、他の評価指標と比べて差は少ない
- 無表情を転送した場合、DECAによる条件付けがされたモデルのほうが損失が少ない
- 学習モデルの選択がアイデンティティ損失に与える影響が大きい





評価実験概要

- 橋本環奈の表情を転送する前のソース画像と、転送後の出力画像を用意
- 2つの画像から顔認識モデルFaceNetによる特徴ベクトルを生成
- 特徴ベクトルのコサイン類似度をモデルごとに比較
- 1に近づくほどアイデンティティ損失が少ない
- AffectNetのみで実験

考察

- 無表情を転送した場合、DECAによる条件付けがされたモデルのほうが損失が少ない
- 学習モデルの選択がアイデンティティ損失に与える影響が大きい
- 無表情を転送した場合のアイデンティティ損失は少ない






考察

- 無表情を転送した場合と比べ、感情アリの表情を転送した場合はアイデンティティの損失が大きい
- 訓練時とターゲット画像の条件付けモデルにEMOCAを用いたほうが、アイデンティティの損失が少ない

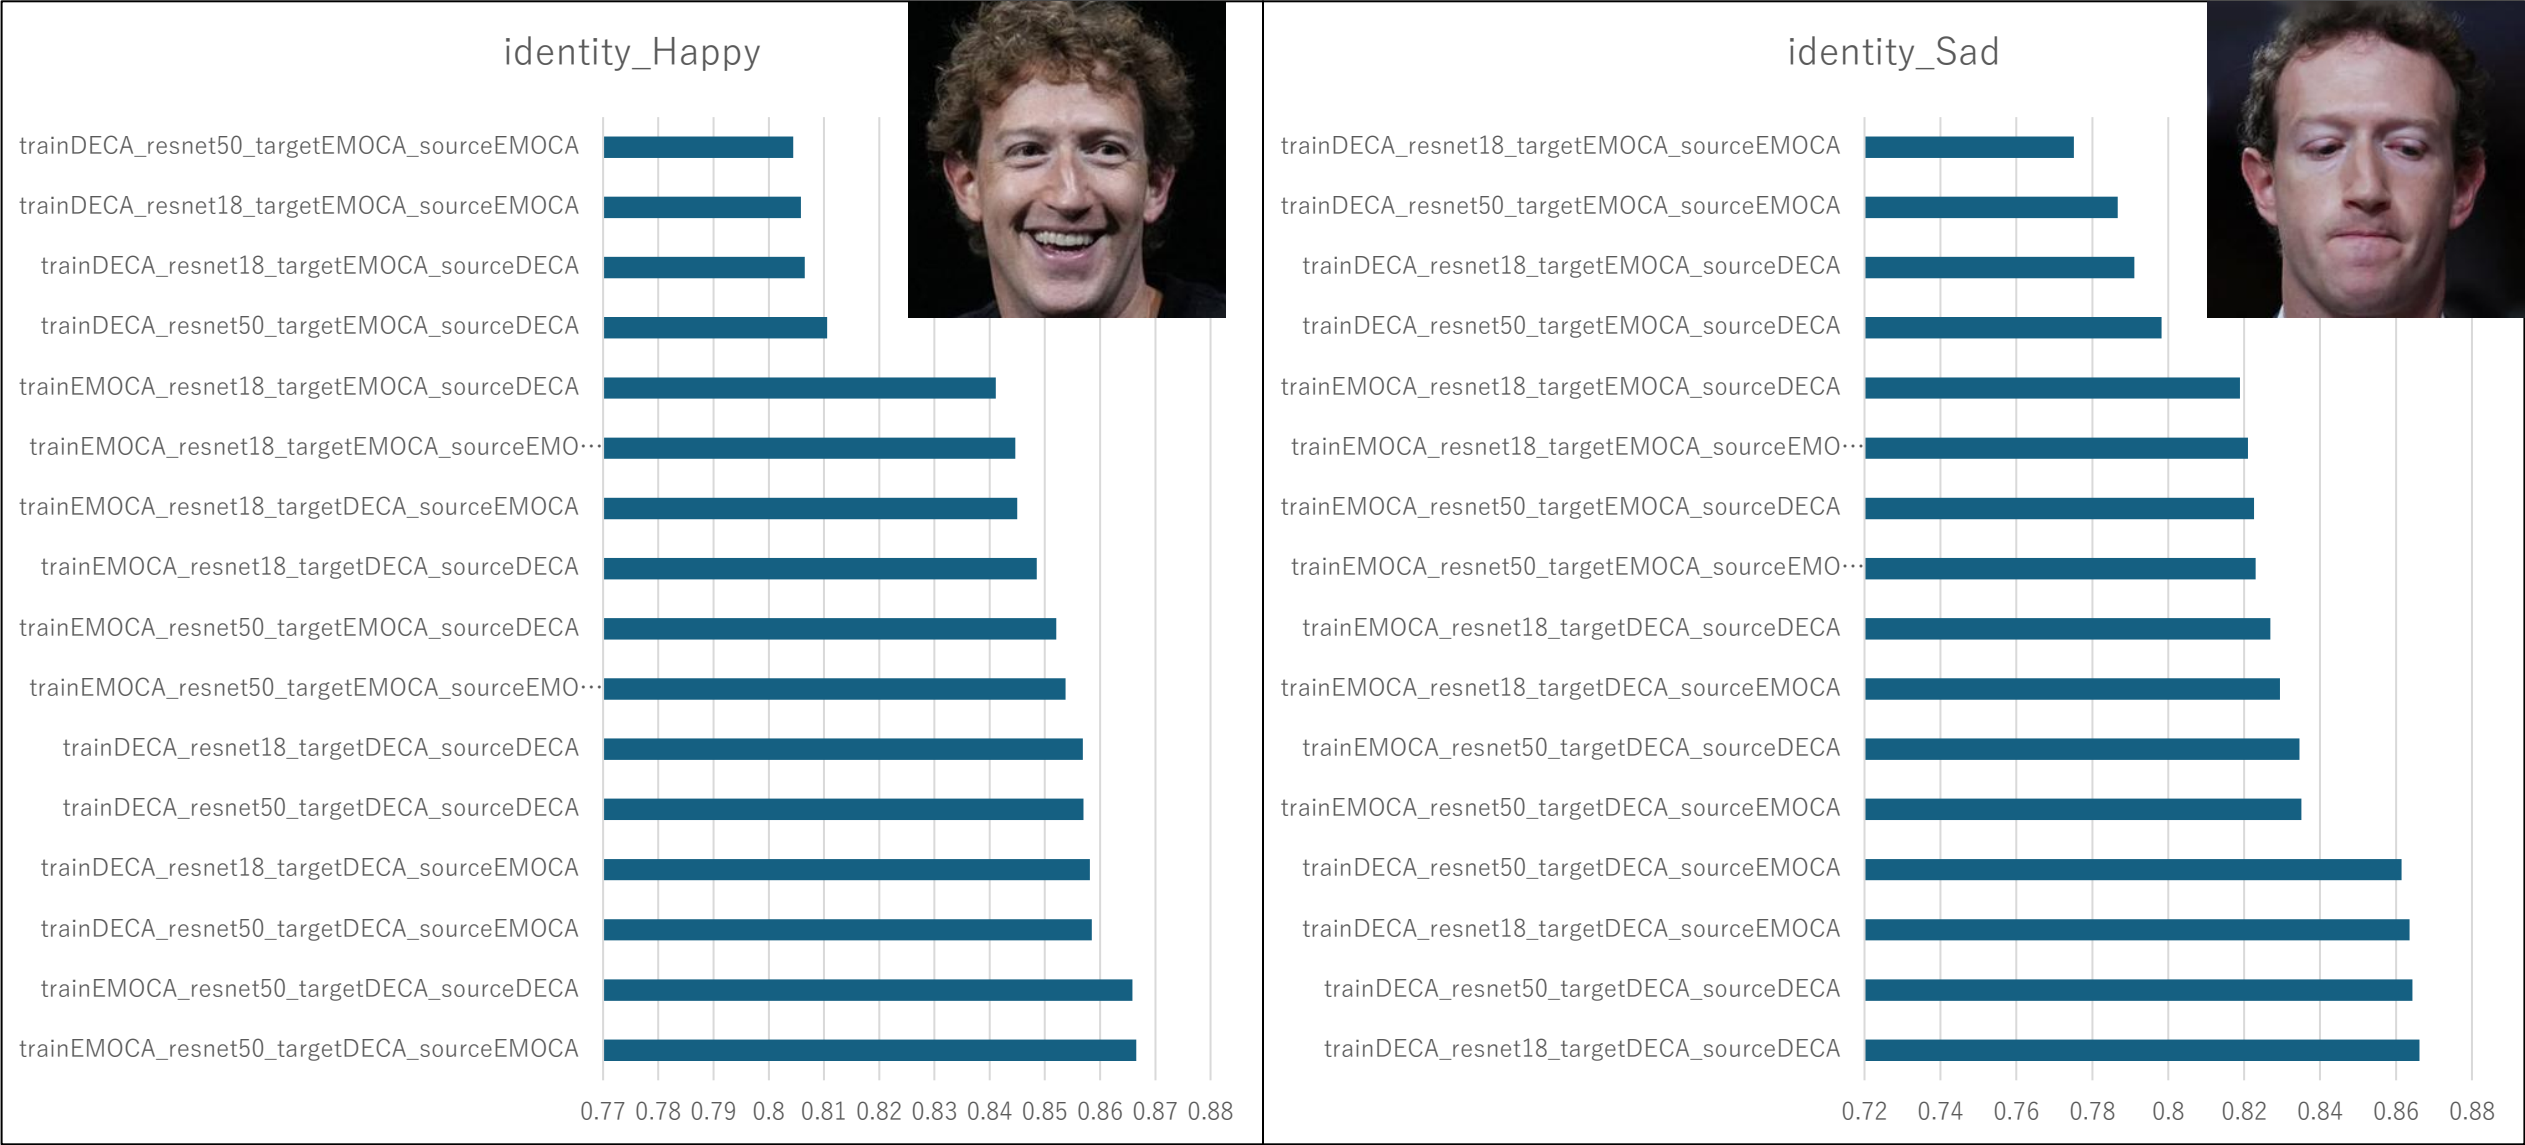
👉 Neutralと真逆の結果

- 学習モデルの選択がアイデンティティ損失に与える影響が大きい
- グローバルエンコーダはResNet50を用いたほうが損失が少ない
- 転送する表情ごとに、DECAとEMOCAのアイデンティティに関する優位性が異なる

identity_affectnet



アイデンティティ類似度(Happy Vs Sad)




アニメ画像・アバター画像の編集


Target



Source



DECA



EMOCA



アニメ画像・アバター画像の編集


Target




Source



DECA



EMOCA





今後の研究計画

