


# 第17回定期ミーティング

2025/05/23

早稲田大学 基幹理工学研究科  
電子物理システム学専攻 史研究室  
石黒将太郎・野口颯汰

表情変換顔生成モデル(Diffsion)と2Dto3D顔形状を生成するモデルを組み合わせることで、3Dの表情変換を軽量化かつ自然に行う



1 性能の良い**分類機**に変更


2 2Dアイデンティティ損失を追加

3 3Dアイデンティティ損失を追加

図. DECA[1]とDiffusionAutoencoders[2]を元にした提案モデル

[1] YAO FENG et al. Learning an Animatable Detailed 3D Face Model from In-The-Wild Images

[2] Konpat Preechakul et al. Diffusion Autoencoders: Toward a Meaningful and Decodable Representation



## 画像生成の流れ

1. 入力画像を **Semantic encoder** と **Stochastic encoder** に入力
2. **Semantic encoder** で意味的情報  $z_{sem}$  を抽出
3. **Stochastic encoder** で画像の詳細情報  $x_T$  を抽出
4. **線形分類器** から属性の方向を示す重みベクトルを取得
5. 抽出された  $z_{sem}$  に対して、重みベクトルを加算
6. 操作後の  $z_{sem}$  と  $x_T$  を **Decoder** に入力し、属性変更した画像を生成

## Manipulationにおける訓練

1. Diffusion Autoencoderの訓練

$$L_{\text{simple}} = \sum_{t=1}^T \mathbb{E}_{x_0, \epsilon_t} \left[ \|\epsilon_\theta(x_t, t, z_{sem}) - \epsilon_t\|_2^2 \right]$$

2. 線形分類器の訓練

入力された  $z_{sem}$  に対して、以下の重みベクトルを推定

$$z_{sem\_new} = w^T z_{sem} + b$$

今回発見した新しい改善余地：

線形分類器の改善、AffectNetを用いたDiffusionAutoencoderの訓練

|      | 線形分類器                                                                                                                                                                                                      | 非線形分類器                                                                                                                                                                                                                                                                                                                                                                                                                                        |
|------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 訓練   | <ul style="list-style-type: none"> <li>• <code>nn.Linear(conf.style_ch, num_cls)</code> のみで構成</li> <li>• 入力特徴ベクトルをそのまま分類出力にマッピング</li> <li>• 非線形性がなく、学習できる関係は線形に限定</li> <li>• シンプルで軽量だが、表現力に制限あり</li> </ul> | <ul style="list-style-type: none"> <li>• <code>nn.Sequential</code> により複数の層を構成               <ul style="list-style-type: none"> <li>• <code>nn.Linear(conf.style_ch, 512)</code>: 隠れ層を追加</li> <li>• <code>nn.LeakyReLU(negative_slope=0.01)</code>: 非線形性を導入</li> <li>• <code>nn.Dropout(0.5)</code>: 過学習を防止</li> <li>• <code>nn.Linear(512, num_cls)</code>: 最終出力層</li> </ul> </li> <li>• より複雑なデータ分布に対応可能</li> <li>• 汎化性能の向上が期待できる</li> </ul> |
| 条件付け | <ul style="list-style-type: none"> <li>• 条件ベクトルに対して、分類器の重みベクトル (<code>cls_id</code> に対応) を直接加算することで強調を行う</li> <li>• 分類器の出力に勾配を用いず、固定的な方向の操作</li> </ul>                                                     | <ul style="list-style-type: none"> <li>• 条件ベクトルを分類器に通して、目的クラス (<code>cls_id</code>) のスコアに対する勾配を取得</li> <li>• その勾配方向に沿って特徴量を強調 (勾配 × 強度 <math>\alpha</math> × スケール)</li> <li>• より柔軟でタスク適応的な条件操作が可能 (勾配ベースの強調)</li> </ul>                                                                                                                                                                                                                       |

▶ 非線形分類器では分類器全体の挙動を活かして**意味方向**を導き出すことが可能

表. InceptionResnetV1を用いたアイデンティティ評価

| alpha         | Neutral | Happiness | Sadness | Surprise | Fear   | Disgust | Anger  | Contempt | 平均        | 減少比率       |
|---------------|---------|-----------|---------|----------|--------|---------|--------|----------|-----------|------------|
| $\alpha=0.05$ | 0.9755  | 0.9848    | 0.9922  | 0.9795   | 0.9834 | 0.9492  | 0.9548 | 0.959    | 0.9723    | 3.73213    |
| $\alpha=0.10$ | 0.9392  | 0.9509    | 0.9785  | 0.885    | 0.935  | 0.9326  | 0.9188 | 0.9481   | 0.9360125 | 4.40565698 |
| $\alpha=0.15$ | 0.8842  | 0.9243    | 0.96    | 0.8448   | 0.8992 | 0.8635  | 0.8773 | 0.9049   | 0.894775  | 4.4354726  |
| $\alpha=0.20$ | 0.8304  | 0.902     | 0.9437  | 0.7799   | 0.8736 | 0.8199  | 0.8213 | 0.8699   | 0.8550875 | 5.28747058 |
| $\alpha=0.25$ | 0.7098  | 0.8897    | 0.9211  | 0.7335   | 0.8355 | 0.7817  | 0.7745 | 0.8332   | 0.809875  | 5.28476617 |
| $\alpha=0.30$ | 0.689   | 0.8572    | 0.8948  | 0.6764   | 0.7834 | 0.7525  | 0.7107 | 0.7726   | 0.767075  | 4.87077535 |
| $\alpha=0.35$ | 0.6892  | 0.8389    | 0.8596  | 0.5973   | 0.7777 | 0.6808  | 0.6617 | 0.7325   | 0.7297125 | 5.21266937 |
| $\alpha=0.40$ | 0.6396  | 0.8119    | 0.8125  | 0.5307   | 0.7614 | 0.6461  | 0.6361 | 0.6951   | 0.691675  | -          |

- ✓  $\alpha$  の増加に伴い、アイデンティティ保持精度は減少
- ✓ 感情による差異：Neutral, Surprise, Disgust, Anger, Contempt が特に影響を受けやすい  
→これらの表情は顔の幾何的特徴を大きく歪ませるため
- ✓ 減少比率が最大になるのは  $\alpha=0.20\sim0.25$  付近  
→FaceNetの認識限界を超え始める閾値がある

表. HSEMtionを用いた顔認識結果

| alpha         | Neutral | Happiness | Sadness | Surprise | Fear    | Disgust | Anger   | Contempt | Accuracy |
|---------------|---------|-----------|---------|----------|---------|---------|---------|----------|----------|
| $\alpha=0.05$ | Sadness | Contempt  | Sadness | Sadness  | Sadness | Sadness | Sadness | Sadness  | 0.125    |
| $\alpha=0.10$ | Sadness | Happiness | Sadness | Sadness  | Sadness | Sadness | Sadness | Sadness  | 0.25     |
| $\alpha=0.15$ | Sadness | Happiness | Sadness | Fear     | Sadness | Sadness | Sadness | Sadness  | 0.25     |
| $\alpha=0.20$ | Neutral | Happiness | Sadness | Fear     | Sadness | Sadness | Sadness | Disgust  | 0.375    |
| $\alpha=0.25$ | Neutral | Happiness | Sadness | Fear     | Fear    | Disgust | Sadness | Disgust  | 0.625    |
| $\alpha=0.30$ | Neutral | Happiness | Sadness | Fear     | Fear    | Disgust | Sadness | Disgust  | 0.625    |
| $\alpha=0.35$ | Neutral | Happiness | Sadness | Fear     | Fear    | Disgust | Sadness | Disgust  | 0.625    |
| $\alpha=0.40$ | Neutral | Happiness | Sadness | Fear     | Fear    | Disgust | Sadness | Disgust  | 0.625    |

— 一致  
— 不一致

- ✓ 感情の生成に必要な「 $\alpha$ の閾値」が存在する
- ✓ Sadness, Surprise, Fear, Disgust, Anger, Contemptの明確な生成&認識が困難  
→ データセットの枚数の問題、ラベリングの問題等 多数原因が考えられる
- ✓ DisgustとFearは $\alpha$ が強まると安定して識別される
- ✓ Sadnessの誤判定が多い → 元々の画像がSadnessと判定されるため

# 定性評価

$\alpha$  値によって、表情の強さの調整が可能


|                 | Neutral                                                                             | Happiness                                                                           | Sadness                                                                             | Surprise                                                                              | Fear                                                                                  | Disgust                                                                               | Anger                                                                                 | Contempt                                                                              |
|-----------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|
| $\alpha = 0.05$ |    |    |    |    |    |    |    |    |
| $\alpha = 0.10$ |    |    |    |    |    |    |    |    |
| $\alpha = 0.15$ |    |    |    |    |    |    |    |    |
| $\alpha = 0.20$ |    |    |    |    |    |    |    |    |
| $\alpha = 0.25$ |    |    |    |    |    |    |    |    |
| $\alpha = 0.30$ |   |   |   |   |   |   |   |   |
| $\alpha = 0.35$ |  |  |  |  |  |  |  |  |
| $\alpha = 0.40$ |  |  |  |  |  |  |  |  |




### Neutralのidentityが低い理由

モデルは個別の顔のアイデンティティよりも、「**中立的な表情**」や「**平均的な顔**」の**プロトタイプ表現**に強く引き寄せられる可能性がある

個人の特徴が抑制され、より汎用的な顔が生成される結果、identityが薄れると考えらる



Neutral ( $\alpha=0.05$ )



Neutral ( $\alpha=0.40$ )


### アーティファクト

データセットが少ないため、**モデルが学習したデータ分布の境界領域や疎な部分**に生成が押しやられる可能性がある

これらの領域では、モデルが安定した画像を生成するための十分な情報を持っていないので、ピクセル化されたノイズや不自然なテクスチャといったアーティファクトが発生すると考えられる



Sadness ( $\alpha=0.40$ )



Fear ( $\alpha=0.40$ )


### DisgustとAngerの類似性

#### 1. 人間における表情の共通性:


嫌悪と怒りの表情は、眉をひそめる、口角を下げる、鼻にしわを寄せるなど、共通の部分が多く持つため、モデルは学習データからこれらの共通点を捉え、結果として視覚的に類似した出力を生成する可能性がある

#### 2. 学習データセットの課題:

DisgustとAngerの表情間の**視覚的な区別が曖昧であったり、アノテーションが一貫していない**可能性がある



Disgust ( $\alpha=0.40$ )



Anger ( $\alpha=0.40$ )



# Classifier-Free Diffusion Guidance

(NeurIPS 2021 Workshop) Jonathan Ho, Tim Salimans

<https://arxiv.org/abs/2207.12598>



## 概要

classifier-free guidanceという**分類器なし**での条件付けを行うことで  
拡散モデルにおけるサンプル品質と多様性のトレードオフを制御する新しい手法を提案

## 分類機を用いず、純粋な生成モデルの能力で高品質なサンプル生成を目指す

背景：

- **分類器ガイダンス**という手法が提案され、訓練済みの追加の分類器を利用することで、拡散モデルのサンプル品質を向上させることが示された
- **分類器ガイダンス**が、拡散モデルの訓練プロセスを複雑化させること。  
追加の分類器を訓練する必要があり、その分類器はノイズが加えられたデータで訓練しなければならないため、既存の事前学習済み分類器を容易に利用できないこと
- **拡散モデルが推定したスコアと、別途訓練された画像分類器の勾配**を組み合わせるプロセスが、画像分類器に対する**勾配ベースの敵対的攻撃**と見なせる可能性がある  
→分類器が高評価してしまうような画像」が生成された可能性がある
- **分類器ベースの評価指標に対して最適化されるようなメカニズム**が働いている可能性があり、必ずしも真の意味での生成モデルの能力向上を反映しているとは限らない

取り組んだ問題：

分類器を使用せず、分類器ガイダンスと同様のサンプル品質と多様性のトレードオフを実現すること

- 分類機を使わずに画像品質を向上させたい

### Classifier Guidanceとは

#### Classifier

- ノイズ画像で訓練した分類器

#### Guidance

- サンプリングの際に, ノイズ画像に対する分類器の勾配を使う

### Classifier Guidanceの問題点

#### アーキテクチャが複雑

- 事前にノイズ画像を分類器で学習する必要があり, 使いにくい

#### 評価指標が良くない

- 分類器の勾配を使ってサンプリングするので, 分類器を使う評価指標される値よりも良くなってしまう

---

**Algorithm 1** Classifier guided diffusion sampling, given a diffusion model  $(\mu_\theta(x_t), \Sigma_\theta(x_t))$ , classifier  $p_\phi(y|x_t)$ , and gradient scale  $s$ .

---

Input: class label  $y$ , gradient scale  $s$

$x_T \leftarrow \text{sample from } \mathcal{N}(0, \mathbf{I})$

**for all**  $t$  from  $T$  to 1 **do**

$\mu, \Sigma \leftarrow \mu_\theta(x_t), \Sigma_\theta(x_t)$

$x_{t-1} \leftarrow \text{sample from } \mathcal{N}(\mu + s\Sigma \nabla_{x_t} \log p_\phi(y|x_t), \Sigma)$

**end for**

**return**  $x_0$

---

→ Classifierを使わないGuidanceが欲しい


# • 無条件と条件付けを組み合わせることで達成

- conditionalなモデルとunconditionalなモデルを考えてノイズを予測

- unconditionalなモデル  $p_{\theta}(\mathbf{z})$  の出力  $\epsilon_{\theta}(\mathbf{z}_{\lambda}) = \epsilon_{\theta}(\mathbf{z}_{\lambda}, \mathbf{c} = \emptyset)$
- conditionalなモデル  $p_{\theta}(\mathbf{z}|\mathbf{c})$  の出力  $\epsilon_{\theta}(\mathbf{z}_{\lambda}, \mathbf{c})$

1つのモデルで  
2つのモデルを表す

$$\begin{aligned}\tilde{\epsilon}_{\theta}(\mathbf{z}_{\lambda}, \mathbf{c}) &= (1 + w)\epsilon_{\theta}(\mathbf{z}_{\lambda}, \mathbf{c}) - w\epsilon_{\theta}(\mathbf{z}_{\lambda}) \\ &= \epsilon_{\theta}(\mathbf{z}_{\lambda}, \mathbf{c}) + w(\epsilon_{\theta}(\mathbf{z}_{\lambda}, \mathbf{c}) - \epsilon_{\theta}(\mathbf{z}_{\lambda}))\end{aligned}$$



- 条件付け拡散モデルを少しの変更するだけで実装可能

### 学習時

```
if np.random.random() < 0.1:  
    labels = None  
predicted_noise = model(x_t, t, labels)
```

### 条件付

```
if y is not None:  
    t += self.label_emb(y)
```

### サンプリング時

```
if cfg_scale > 0:  
    uncond_predicted_noise = model(x, t, None)  
    predicted_noise = torch.lerp(uncond_predicted_noise, predicted_noise, cfg_scale)
```




- Inceptionスコア (IS) とFIDの間のトレードオフを実現できる

| Model                         | FID (↓)                           | IS (↑)                        |
|-------------------------------|-----------------------------------|-------------------------------|
| ADM (Dhariwal & Nichol, 2021) | 2.07                              | -                             |
| CDM (Ho et al., 2021)         | <b>1.48</b>                       | 67.95                         |
| Ours                          | $p_{\text{uncond}} = 0.1/0.2/0.5$ |                               |
| $w = 0.0$                     | 1.8 / 1.8 / 2.21                  | 53.71 / 52.9 / 47.61          |
| $w = 0.1$                     | 1.55 / 1.62 / 1.91                | 66.11 / 64.58 / 56.1          |
| $w = 0.2$                     | 2.04 / 2.1 / 2.08                 | 78.91 / 76.99 / 65.6          |
| $w = 0.3$                     | 3.03 / 2.93 / 2.65                | 92.8 / 88.64 / 74.92          |
| $w = 0.4$                     | 4.3 / 4 / 3.44                    | 106.2 / 101.11 / 84.27        |
| $w = 0.5$                     | 5.74 / 5.19 / 4.34                | 119.3 / 112.15 / 92.95        |
| $w = 0.6$                     | 7.19 / 6.48 / 5.27                | 131.1 / 122.13 / 102          |
| $w = 0.7$                     | 8.62 / 7.73 / 6.23                | 141.8 / 131.6 / 109.8         |
| $w = 0.8$                     | 10.08 / 8.9 / 7.25                | 151.6 / 140.82 / 116.9        |
| $w = 0.9$                     | 11.41 / 10.09 / 8.21              | 161 / 150.26 / 124.6          |
| $w = 1.0$                     | 12.6 / 11.21 / 9.13               | 170.1 / 158.29 / 131.1        |
| $w = 2.0$                     | 21.03 / 18.79 / 16.16             | 225.5 / 212.98 / 183          |
| $w = 3.0$                     | 24.83 / 22.36 / 19.75             | 250.4 / 237.65 / 208.9        |
| $w = 4.0$                     | 26.22 / 23.84 / 21.48             | <b>260.2</b> / 248.97 / 225.1 |

ガイダンス強度を上げるほど  
多様性は下がり、忠実度は向上する

表. 分類機なしガイダンスによるFIDとISのトレードオフ

今回発表した改善点を随時実装





## 1. 論文紹介

---

## 2. リファクタリング結果、NPHMの現状報告

---

## 3. 研究計画

---

# InstantID: Zero-shot Identity-Preserving Generation in Seconds

Qixun Wang<sup>12</sup>, Xu Bai<sup>12</sup>, Haofan Wang<sup>12\*</sup>, Zekui Qin<sup>12</sup>, Anthony Chen<sup>123</sup>,  
Huaxia Li<sup>2</sup>, Xu Tang<sup>2</sup>, and Yao Hu<sup>2</sup>

InstantX Team<sup>1</sup>, Xiaohongshu Inc<sup>2</sup>, Peking University<sup>3</sup>

{haofanwang.ai@gmail.com}

<https://instantid.github.io>



## 取り組んだ問題と背景

- ✓ Stable DiffusionにおけるLoRAなどの手法により、IDをembeddingすることで、特定の個人を生成・編集できるようになった
- ✓ 従来の手法やDiffusionRigでは、事前のファインチューニングに多数の顔画像が必要な点や、アイデンティティ保持度が弱いという欠点が存在

## このモデルの特徴

- ✓ InstantIDは拡散モデルに基づく手法で、1枚の顔画像のみを用いて、多様なスタイルの画像をパーソナライズ化(アイデンティティに基づく編集)を実現
- ✓ テキストプロンプトによる自由度が高い編集と、顔画像に基づく画像生成を両立
- ✓ ControlNetと同様に、事前学習済みのStable Diffusionにアーキテクチャを結合可能
- ✓ 画像生成を制御する手法として、強いsemantic(=identity) conditionsと弱いspatial conditionsを課したIdentityNetを用いる

# InstantIDの構成要素

## 1. ID Embedding

- 顔のsemanticな特徴を捉え、ベクトル化するためのモジュール
- 事前学習済みの顔モデルantelopev2.1 を活用

## 2. Image Adapter

- 画像をプロンプトとして使用できるようにする分離型クロスアテンション
- テキストによる制御とID情報を明確に区別

## 3. IdentityNet

- OpenPoseによるlandmarks(目・鼻・口のみ)とFace embeddingsをクロスアテンション条件として使用
- ControlNetのように、IdentityNetの各層の出力をDiffusionのUNetに残差接続

## 4. Diffusion model

- 従来の潜在変数を用いたUNetベースのStable Diffusion model
- InstantID由来のアーキテクチャをプラグインとして後付け可能(ファインチューニング不要)

## アーキテクチャ




図1. InstantIDのアーキテクチャ.[1]

| 特徴注入経路                | 目的               | 技術             |
|-----------------------|------------------|----------------|
| Image Cross Attention | 顔IDを保持           | 分離型クロスアテンション   |
| Identity Net          | 姿勢・ランドマーク局所特徴の保持 | 中間層に特徴マップとして加算 |



## 定性評価



図1. プロンプトやその他条件による生成画像の違い.[1]



## Ablation Study



図2.参照画像の増減による生成画像の違い.[1]

- LoRAとの比較



図3.InstantID vs LoRA.[1]

## 拡散モデルソルバーの追加




図. laplacian filterによる画質評価




図. waveletによる画質評価

## Stage2での学習回数による画質差




図. laplacian filterによる画質評価




図. waveletによる画質評価



## NPHMの現状報告



図. monoNPHMの出力結果

## NPHMの現状報告





図. monoNPHMの出力結果



今後の研究計画

