


第18回定期ミーティング

2025/06/26

早稲田大学 基幹理工学研究科
電子物理システム学専攻 史研究室
石黒将太郎・野口颯汰

表情変換顔生成モデル(Diffsion)と2Dto3D顔形状を生成するモデルを組み合わせることで、3Dの表情変換を軽量化かつ自然に行う



1 性能の良い**分類機**に変更

2 2Dアイデンティティ損失を追加

3 3Dアイデンティティ損失を追加

図. DECA[1]とDiffusionAutoencoders[2]を元にした提案モデル

[1] YAO FENG et al. Learning an Animatable Detailed 3D Face Model from In-The-Wild Images

[2] Konpat Preechakul et al. Diffusion Autoencoders: Toward a Meaningful and Decodable Representation

Agenda

CVPR2025の紹介

1. DIfLocks : Generating 3D Hair from a Single Image using Diffusion Models
2. Learning Person-Specific Animatable Face Models from In-the-Wild Images via a Shared Base Model


Agenda

CVPR2025の紹介

1. DlffLocks : Generating 3D Hair from a Single Image using Diffusion Models
2. Learning Person-Specific Animatable Face Models from In-the-Wild Images via a Shared Base Model

DiffLocks: Generating 3D Hair from a Single Image using Diffusion Models

Radu Alexandru Rosu, Keyu Wu, Yao Feng, Youyi Zheng, Michael J. Black



単一画像からの詳細な3Dヘア形状生成は、髪型の高い多様性に対応する3Dデータの不足が課題

課題： 単一の画像から3Dの髪の形状を生成することは非常に困難なタスク


理由：

1. ヘアスタイルの多様性が極めて大きいこと
2. 画像と対応する3Dヘアデータが不足していること

従来手法の限界：

1. **データ量不足への対処:** 主に合成データで学習されていましたが、データ量が限られていたため、ガイドストランドやスカルプレベルの埋め込みといった低次元の中間表現に依存
2. **後処理の必要性:** これらの低次元表現は、3Dモデルとしてデコード、アップサンプリング、リアリズムの付加といった**後処理が必要**
3. **詳細な髪の再構築の困難さ:** その結果、**詳細な髪の再構築が困難**
4. **特定のヘアスタイルへの対応不足:**
 - 特に**巻き毛の再構築に苦戦**したり、扱えるヘアスタイルの種類が限定的
 - 既存手法は、画像全体の形状には一致するものの、**細かいディテールやカールが不足**し、ストランドが平行に並ぶ傾向
 - **薄毛やアフロのような非常に巻き毛のヘアスタイルは、正確に再構築できない**
 - **画像条件付けの制約:** 従来の画像条件付けは、髪の成長方向を推測できず、隠れた部分が多いヘアスタイルではノイズが発生しやすいという問題がある

DiffLocks : 単一画像から多様なヘアスタイルを詳細に再構築する



DiffLocksは、三つの段階で構成されている

1. データ生成パイプラインの構築
2. 髪のスレッドとヘアスタイルを正規スカルプ空間にパラメータ化
3. 条件付き拡散モデル「DiffLocks」の学習

1. データ生成パイプラインの構築

目的: 3Dヘアデータの不足という課題に対処するため、DiffLocksは**大規模で多様な合成ヘアデータセット**を自動生成

使用ツール: Blenderのジオメトリノードを活用

生成規模: 40,000種類もの異なるヘアスタイル

開始点: 約75種類の粗いガイドストランドからプロセスが開始



生成プロセス:

- 58のジオメトリノードと349の補助ノードからなるネットワークを使用
 - 髪の毛の補間、塊化、カール、ノイズ付加、物理シミュレーションなど、多様な変換を適用
- **3Dの髪の毛のストランド**と、それに対応するBlenderでレンダリングされた**リアルなRGB画像**
薄毛やアフロのような非常に巻き毛のヘアスタイルを含め、**幅広い髪型**を生成
768×768の解像度の画像と、約10万本の3Dストランドジオメトリを含む

2. 髪のスランドとヘアスタイルを正規スカalp空間にパラメータ化

目的: 従来の手法が、ガイドスランドのような低次元の中間表現に依存し、詳細な髪の再構築や巻き毛の処理に課題を抱えていたのに対し、DiffLocksは**個々の髪のスランドを直接表現する**

3Dスランドの形式的表現: 256個の3D点の集合 × 約10万本


① **Strand VAE** : 64次元の潜在コードに圧縮

構成:

- エンコーダ: 1D畳み込み
- デコーダ: 潜在コードを256個の3D点の系列へとマッピング

学習:

- **位置損失:** 予測された点と真の点の間の距離
- **方向損失:** スランドのセグメントの方向
- **曲率損失:** スランドの曲がり具合



$$\mathcal{L}_{\text{data}} = \sum_0^L |\mathbf{p}_i - \tilde{\mathbf{p}}_i| + \lambda_1 |\mathbf{d}_i - \tilde{\mathbf{d}}_i| + \lambda_2 |\boldsymbol{\kappa}_i - \tilde{\boldsymbol{\kappa}}_i|$$
$$\mathcal{L}_{\text{VAE}} = \mathcal{L}_{\text{data}} + \lambda_{\text{KL}} \mathcal{L}_{\text{KL}}$$

3. 条件付き拡散モデル「DiffLocks」の学習

学習データセット：作成した40,000種類のヘアスタイルを含むデータセット

拡散アーキテクチャ：Hourglass Diffusion Transformers (HDiT)

単一RGB画像からの条件付け：

従来の2D方向マップに頼るのではなく、**事前学習済みのDINOv2 モデルから抽出された特徴**を使用
DINOv2-largeモデル：

特徴マップ F_{map} ($55 \times 55 \times 1024$) とグローバルなCLSトークン F_{cls} (1024) にエンコード
メリット：

短髪や暗い髪の毛で方向マップがノイズを含む場合に、より堅牢な条件付けが可能


F_{map} は、髪の毛を正確に再構築するために非常に重要

F_{cls} は、より高レベルで全体的なコンテキストを提供

出力：**頭皮テクスチャ T と密度マップ D**

頭皮テクスチャ：マップ上の任意の点が個々のヘアストランドの潜在コードを含む256x256サイズ

密度マップ：頭皮上の各位置でストランドが生成される確率を表す



▶ **個々のヘアストランドの潜在コードを直接回帰することで、頭皮全体にわたるストランド間の詳細な空間的関係を学習でき、後処理なしに3Dストランドに直接デコード**

幅広い種類の画像に対して高品質でリアルなヘアストランドを生成



従来のNeuralHDHair2やHairStep1といった手法：

画像全体の形状にはある程度合致するものの、**微細なディテールやカール（巻き毛）の再現性に欠け**、ストランドが互いに平行に走るような結果
特に**薄毛（balding）やアフロヘアのような髪型を正しく再構築**

DiffLocks：

巻き毛のアフロスタイルや薄毛のヘアスタイルを含む、**多様なヘアスタイルを高精度で再構築**

堅牢性とDINO v2を用いてVAEを使用しない方法で高精細な再構築を実現



Classifier-Free Guidance を用いて学習されているため、特定の
入力画像に条件付けされない状態でもヘアスタイルを生成可能
→新しいヘアスタイルを生成する能力向上



RGB Input

Model:

Condition: Global+Local



VAE



Diffusion
Global



Diffusion
Global+Local

左 : VAEモデルを使用して頭皮テクスチャを生成
中央 : ローカルな特徴マップ (F_{map}) を削除
右 : 最も詳細な髪の構造を捉える構造


Agenda

CVPR2025の紹介

1. DlffLocks : Generating 3D Hair from a Single Image using Diffusion Models
2. Learning Person-Specific Animatable Face Models from In-the-Wild Images via a Shared Base Model

Learning Person-Specific Animatable Face Models from In-the-Wild Images via a Shared Base Model

Yuxiang Mao , Zhenfeng Fan , ZhiJie Zhang , Zhiheng Zhang , Shihong Xia



In-the-wild環境での3D顔再構築には、個人差表現・ランドマーク誤差・再構築精度に関する課題が残されている


取り組んだ背景

- **In the wild画像からの学習の進展と限界**
 - In the wild画像を用いて、2D顔画像データセットを用いて、自己教師あり学習で汎用的な3D顔再構築モデルを訓練したものは、個々の被写体の独特な特徴を正確に捉える点で限界
- **ViT-MAEアーキテクチャの潜在能力**
 - 大規模データセットでの事前学習を通じて、限られた訓練データでも堅牢な性能と高い汎化能力を発揮

取り組んだ問題


- **特定の個人の特徴表現の不十分さ**
 - 既存の3D顔再構築モデルは、異なる個人の画像に対して**統一されたモデル重み**を使用している影響で、特定の個人のユニークな顔の形状や詳細な特徴を十分に表現不可
- **ランドマークマーチング問題**
 - 2D画像から3D顔を再構築する際、特に非正面の視点や顔が部分的に隠れている場合、顔の輪郭を示す2Dランドマークと3Dモデルの対応がずれる「ランドマークマーチング」と呼ばれる現象が発生
- **アニメーション可能な詳細の再構築における課題と堅牢性の不足**
 - UNetでは、スキップ接続が不必要な低レベルのしわを伝播させたり、非正面の姿勢やオクルージョンによって入力テクスチャが不完全になり、詳細が欠落したりする問題が発生
 - 3D顔の詳細と2Dシェーディング（影のつき方）の間には**1対1の対応がない**ため、自己教師あり学習におけるシェーディングのアプローチでは、詳細生成の最適化方向が曖昧になるという課題

2段階構成で、表情と個人の特徴を分離して操作することが可能



エンドツーエンド学習フレームワーク

入力された2D画像から最終的な3D顔モデルを再構築するまでのプロセス



アニメーション可能ディテール学習パイプライン

アニメーション可能な顔のディテール（シワなど）を学習するための詳細なプロセス

3.1 基礎的な前提条件

➤ 3D ジオメトリモデル

- FLAMEを使用

- **アイデンティティ形状パラメータ (β)**: 個人の固有の顔の形状

- **表情パラメータ (ψ)**: さまざまな顔の表情 (笑顔、怒りなど)

- **ポーズパラメータ (θ)**: 首、顎、眼球の関節周りの回転、およびグローバルな回転

→ 5023個の頂点と9976個の面から構成される3Dメッシュ ($S(\beta, \theta, \psi)$) を出力

➤ 外観モデル

- 顔の肌の表面の色や質感を表現するためのモデル

- テクスチャパラメータ (α) を与えると、**FLAMEテクスチャマップ ($A(\alpha)$)** を出力

➤ カメラモデル

- 3D顔モデルを2D画像に投影するためのモデル


➤ 照明モデル

- 入力画像における**照明条件を推定**するためのモデル

- 顔に光が当たってどのように影ができるか (シェーディング) を計算するために使用


▶ 2D画像から3D顔モデルを再構築し、それを再び2D画像としてレンダリングするために必要な仕組み

2段階構成で、表情と個人の特徴を分離して操作することが可能



エンドツーエンド学習フレームワーク

入力された2D画像から最終的な3D顔モデルを再構築するまでのプロセス



アニメーション可能ディテール学習パイプライン

アニメーション可能な顔のディテール（シワなど）を学習するための詳細なプロセス

3.2. 顔の粗い3D形状を再構築するステップ


主要なポイント：

ViTエンコーダの利用

2Dの顔画像を16x16のパッチに分割し、それぞれのパッチを埋め込み表現に変換し、位置情報も加えてトークンのシーケンスを形成

メリット：

- ① 局所적および大局的な依存関係の把握
- ② 大規模データセットでの事前学習による堅牢な性能と汎化能力
- ③ 自己教師あり学習との親和性
- ④ 軽量アダプターによる個人特化モデルへの転移




シルエット頂点再投影の導入

従来の方法：3Dランドマークと2Dランドマークの間の誤差を最小化することで3D顔を制約
→ (非正面からの視点) **隠れた境界のランドマーク**において、正確なアノテーションが困難
(**ランドマークマーチング問題**)

アノテーションされた2Dランドマークと、3Dモデルの**外縁にある頂点**を


$$\mathcal{L}_{sil} = \sum_{i, N_{z,i} > 0} d(\mathbf{k}_i, \tilde{\mathbf{k}}_i) + \sum_{i, N_{z,i} < 0} \min_{\mathbf{v}_e \in \tilde{V}_e} d(\mathbf{k}_i, \mathbf{v}_e)$$

2段階構成で、表情と個人の特徴を分離して操作することが可能



エンドツーエンド学習フレームワーク

入力された2D画像から最終的な3D顔モデルを再構築するまでのプロセス



アニメーション可能ディテール学習パイプライン

アニメーション可能な顔のディテール（シワなど）を学習するための詳細なプロセス

3.3. 粗い再構築をさらに洗練し、詳細な表情に関連するしわを生成

①ディテール再構築の目的と主要モデル

目的: FLAMEジオメトリを**変位マップ D** を用いて精緻化

(この変位マップは、顔の表面の微細な凹凸やしわなどの「ディテール」を表現)

主要モデル: 顔のディテールを捉えるために、**マスク付きオートエンコーダ (MAE)** を利用

(顔の細部を正確に再構築するためにマスキング比率をゼロにする)

②顔のテンションの利用

顔のテンションの定義: 中立的な表情 (口を閉じた状態) から現在の表情への変形によって生じる、3Dメッシュ上の頂点ごとの**圧縮または拡張の度合いを数値化したもの**

今回はMAEの入力として、UV空間でのテンションマップ T_{UV} を用いる

3.3. 粗い再構築をさらに洗練し、詳細な表情に関連するしわを生成

③Teacher-Student戦略

- 背景：UNetの利点と限界
 1. UNetのスキップ接続は、顔の動きで消えるべき不要なしわを伝播させてしまう可能性がある
 2. 非正面の姿勢やオクルージョンが再構築におけるディテールの欠損につながる可能性がある
- オートエンコーダ（MAE）の選択
 - オートエンコーダは、アニメーションとオクルージョンに対するロバスト性において、強み
- 解決方法：教師としてのUNetの利用
 - 浅いUNetの詳細再構築ネットワークを教師モデルとして訓練
 - 教師モデルの推定値を「擬似真値」として用いられ、**オートエンコーダ（MAE）のディテール再構築を導く**


④教師-生徒損失 (Teacher-Student Loss)

L_{Tchr} は、事前学習済みの教師ネットワークUNetが与える変位と、生徒ネットワークMAE A が与える変位の類似性を測る

$$\mathcal{L}_{Tchr} = \mathcal{L}_{phoD}(D, D_{UNet}) + \mathcal{L}_{ssim}(D, D_{UNet})$$


ViTエンコーダによって生成された粗い形状の上に、動的な表情変化に応じた**リアルな顔のしわや微細な特徴を追加することを可能**にする

2段階構成で、表情と個人の特徴を分離して操作することが可能



エンドツーエンド学習フレームワーク

入力された2D画像から最終的な3D顔モデルを再構築するまでのプロセス



アニメーション可能ディテール学習パイプライン

アニメーション可能な顔のディテール（シワなど）を学習するための詳細なプロセス

3.4. 個人特化モデルへの転移

目的：汎用ベースモデルが既に学習した「in-the-wild」画像における堅牢性や多様な表情に関する事前知識を維持しつつ、特定の個人の顔の**固有の形状や詳細な特徴**をより忠実に捉える

転移の方法：

軽量アダプターの利用：

ViT-MAEベースモデルのトランスフォーマー層内に**軽量なモジュール「アダプター」**を組み込むことで実現

詳細：

ベースモデルの**パラメータは固定し**、アダプターのパラメータのみを訓練
アダプターはトランスフォーマーブロック内のフィードフォワード層の後、層正規化の前に配置

訓練方法：


データ: 特定の個人の複数の画像や動画フレームを利用

損失関数:

粗い再構築段階: 汎用ベースモデルの粗い再構築に使用された損失を利用


詳細再構築段階: 教師-生徒損失 L_{Tchr} を利用

2段階構成で、表情と個人の特徴を分離して操作することが可能



エンドツーエンド学習フレームワーク

入力された2D画像から最終的な3D顔モデルを再構築するまでのプロセス



アニメーション可能ディテール学習パイプライン

アニメーション可能な顔のディテール（シワなど）を学習するための詳細なプロセス

大容量のベースモデルを軽量アダプターで個人特化モデルに転移する本手法が、特定の個人の顔の形状と詳細な特徴を非常に高い忠実度で再構築できる

表. 異なるデータセット間の再構成誤差

Method	300-W [57]			300-VW [63]			FaceScape [80]	
	boundary↓	inner↓	overall↓	boundary↓	inner↓	overall↓	inner error↓	overall error↓
DECA [19]	0.0576	0.0402	0.0446	0.0563	0.0426	0.0460	0.0477 (± 0.0097)	0.0496 (± 0.0103)
EMOCA [13]	0.0579	0.0467	0.0495	-	-	-	-	-
EMOCA-v2 [13, 20]	0.0590	0.0377	0.0430	0.0553	0.0507	0.0519	0.0585 (± 0.0111)	0.0600 (± 0.0109)
SynergyNet [78]	-	0.0545	0.0545	-	0.0651	0.0651	0.0589 (± 0.0117)	0.0785 (± 0.0230)
3DDFA-v2 [22]	-	0.0470	0.0470	-	0.0524	0.0524	0.0514 (± 0.0104)	0.0700 (± 0.0218)
Ours-base (w/o $\mathcal{L}_{sil}$) [†]	0.0616	0.0401	0.0455	0.0660	0.0554	0.0580	0.0526 (± 0.0169)	0.0539 (± 0.0181)
Ours-base	0.0559	0.0348	0.0401	0.0585	0.0456	0.0488	0.0404 (± 0.0126)	0.0429 (± 0.0128)
Ours-base w/ δ_{PS}	-	-	-	0.0359	0.0217	0.0252	0.0253 (± 0.0045)	0.0305 (± 0.0060)

様々なデータセットにおける顔のアライメントおよび再構築誤差で優れた性能を発揮

300-Wデータセット（単一画像再構築）：

シルエット頂点再投影損失 ($\mathcal{L}_{sil}$) の有効性を示している

$\mathcal{L}_{sil}$ を使用しない場合と比較して、境界誤差で9.1%、内部ランドマーク誤差で13.2%の改善


300-VWデータセット（単眼動画再構築）：

個人特化モデルは、ベースモデルおよび既存手法を大幅に凌駕する性能を示している

FaceScapeデータセット（多視点画像再構築）：

個人特化モデルは、各個人の異なる視点からの誤差をさらに大幅に削減

提案手法が定性的にも最もface alignment精度が高い



顔の外側の輪郭と内部の特徴点において、既存の手法と比較してより高い精度を示している

既存の全ての手法よりも低いRMSE誤差を達成していることの裏付け

精度向上の要因：
シルエット頂点再投影損失

図. Face alignment on 300-W

従来手法の課題であるロバスト性と精細な個人表現の限界を克服し、提案手法は特に“しわ”の再現において優れた精度を実現



図. ディテール形状再構成に関する比較

既存手法の課題：

FaceScape3・FaceVerse

現在の画像に特化して最適化を行うため、**推論速度が遅く、姿勢やオクルージョン（遮蔽）に対するロバスト性（堅牢性）に限界**

DECA・EMOCA-v2

個人に特化した顔の詳細の忠実性において課題

提案手法


顔のしわなどの詳細表現において高い精度

個人特化モデルは特にしわの詳細においてさらに改善された精度を示す

精度向上の要因：

教師-生徒アーキテクチャ
軽量アダプターを統合


今回発表した改善点を随時実装




1. NPHM実験結果


2. 論文紹介

3. 研究計画









1. アジア人に弱い

- 白人に対して、黒人やアジア人の髪再現度・顔の輪郭の自然さが劣る
- NPHM専用のデータセットは高品質だが、実験対象者の人数・多様性が少なかったのではないかな？

2. mesh生成の速度が遅すぎる

- 1枚の2D画像からNPHMパラメータの推定及びメッシュ生成を行うのに22分以上かかる(RTX 4070)
- 前処理として、以下の4つがあるためさらに時間がかかる
 - *facenet*による顔領域検出
 - *Pipnet*による顔ランドマーク検出
 - NPHMの基盤となる *MICA* モデル

3. DiffusionRigとmonoNPHMで使用しているpytorch3dライブラリのバージョンが異なる

- 同じ環境で動作させることはできない
- monoNPHMを新しいpytorch3dで動作できるようにコードを改変する必要あり



やっぱり3DMMは偉大
潜在コードの条件付けや新たな2D_to_3Dモデル、SMIRKの使用・比較

SMIRK: 3D Facial Expressions through Analysis-by-Neural-Synthesis

George Retsinas^{1†} Panagiotis P. Filntisis^{1†} Radek Daněček³ Victoria F. Abrevaya³
Anastasios Roussos⁴ Timo Bolkart^{3*} Petros Maragos^{1,2}

¹Institute of Robotics, Athena Research Center, 15125 Maroussi, Greece

²School of Electrical & Computer Engineering, National Technical University of Athens, Greece

³MPI for Intelligent Systems, Tübingen, Germany

⁴Institute of Computer Science (ICS), Foundation for Research & Technology - Hellas (FORTH), Greece



取り組んだ問題と背景

- ✓ 3D再構成に関する既存手法は、顔全体の形状復元には優れているものの、極端な表情や非対称な表情に関しては不得意である
- ✓ 微分可能レンダリングの結果を損失関数に用いていることによる、ドメインギャップが学習に悪影響を与えているのではないか？

このモデルの特徴

- ✓ DECAやEMOCAにおける微分可能レンダリングをニューラルレンダリング(U-Net)に置き換える
- ✓ 予測メッシュのジオメトリと、入力画像からまばらにサンプリングされた顔領域のピクセルから顔画像を生成し、損失関数に用いる
→SMIRKはジオメトリの復元に集中
- ✓ ニューラルレンダリングにより、学習中に様々な表情の画像を生成することが可能（擬似的）であり、多様な表情に対する汎化性能が向上

モデルアーキテクチャ




図1. SMIRKのアーキテクチャ[1].

3つのエンコーダ(MobileNetV3)で

- 表情パラメータ ψ を予測
- 形状パラメータ β を予測
- ポーズ変換パラメータ θ を予測 (pose & c)

※ NNレンダリングを用いるためアルベドやSH関数は
不必要




図2. 顔領域のマスキ化[1].

表情の多様性向上

1. 予測済みのパラメータの内、表情パラ ψ を ψ_{aug} に変更
2. Image2image変換器により新しい出力画像 I'_{aug} を得る
3. I'_{aug} をEに入力すると $E_{\psi}(I'_{aug}) = \psi_{aug}$ になるべきことから、新しいcycle lossを定義

$$L_{exp} = ||E_{\psi}(T(R(\theta, \beta, \psi_{aug}) \oplus M(I))) - \psi_{aug}||_2$$




図3. 表情の摂動を考慮した学習アーキテクチャ[1].

定量評価

表1. 感情認識精度の比較[1].

Model	V-CCC ↑	V-RMSE ↓	A-CCC ↑	A-RMSE ↓	E-ACC ↑
MGCNet	0.69	0.35	0.58	0.34	0.60
3DDFA-v2	0.62	0.39	0.50	0.34	0.52
Deep3DFace	0.73	0.33	0.65	0.31	0.65
DECA	0.69	0.36	0.58	0.33	0.59
FOCUS-CelebA	0.69	0.35	0.54	0.33	0.58
EMOCA v1	0.77	0.31	0.68	0.30	0.68
EMOCA v2	0.76	0.33	0.66	0.30	0.66
SMIRK	0.72	0.35	0.61	0.31	0.64
SMIRK w/o emo	0.71	0.35	0.60	0.32	0.62

表2. User study[1].

	DECA	EMOCAv2	Deep3D	FOCUS
SMIRK	603/77	461/219	510/170	534/146

表3. 3Dモデルからの再構成結果[1].

	DECA	EMOCAv2	FOCUS	Deep3DFace	SMIRK
L1 Loss ↓	0.10	0.11	0.09	0.09	0.09
VGG Loss ↓	0.80	0.84	0.78	0.78	0.76

定性評価



図4. 各モデルのジオメトリ再構成結果の比較[1].

Cycle lossの導入に関するablation study




図5. 再構成性能[1].



図6. アーティファクト生成防止. [1].

今後の研究計画

