

第20回定期ミーティング

2025/08/29

早稲田大学 基幹理工学研究科
電子物理システム学専攻 史研究室
石黒将太郎・野口颯汰

Agenda

1. 自身の研究の進捗

2. 今後の研究計画

表情変換顔生成モデル(Diffsion)と2Dto3D顔形状を生成するモデルを組み合わせることで、3Dの表情変換を軽量化かつ自然に行う

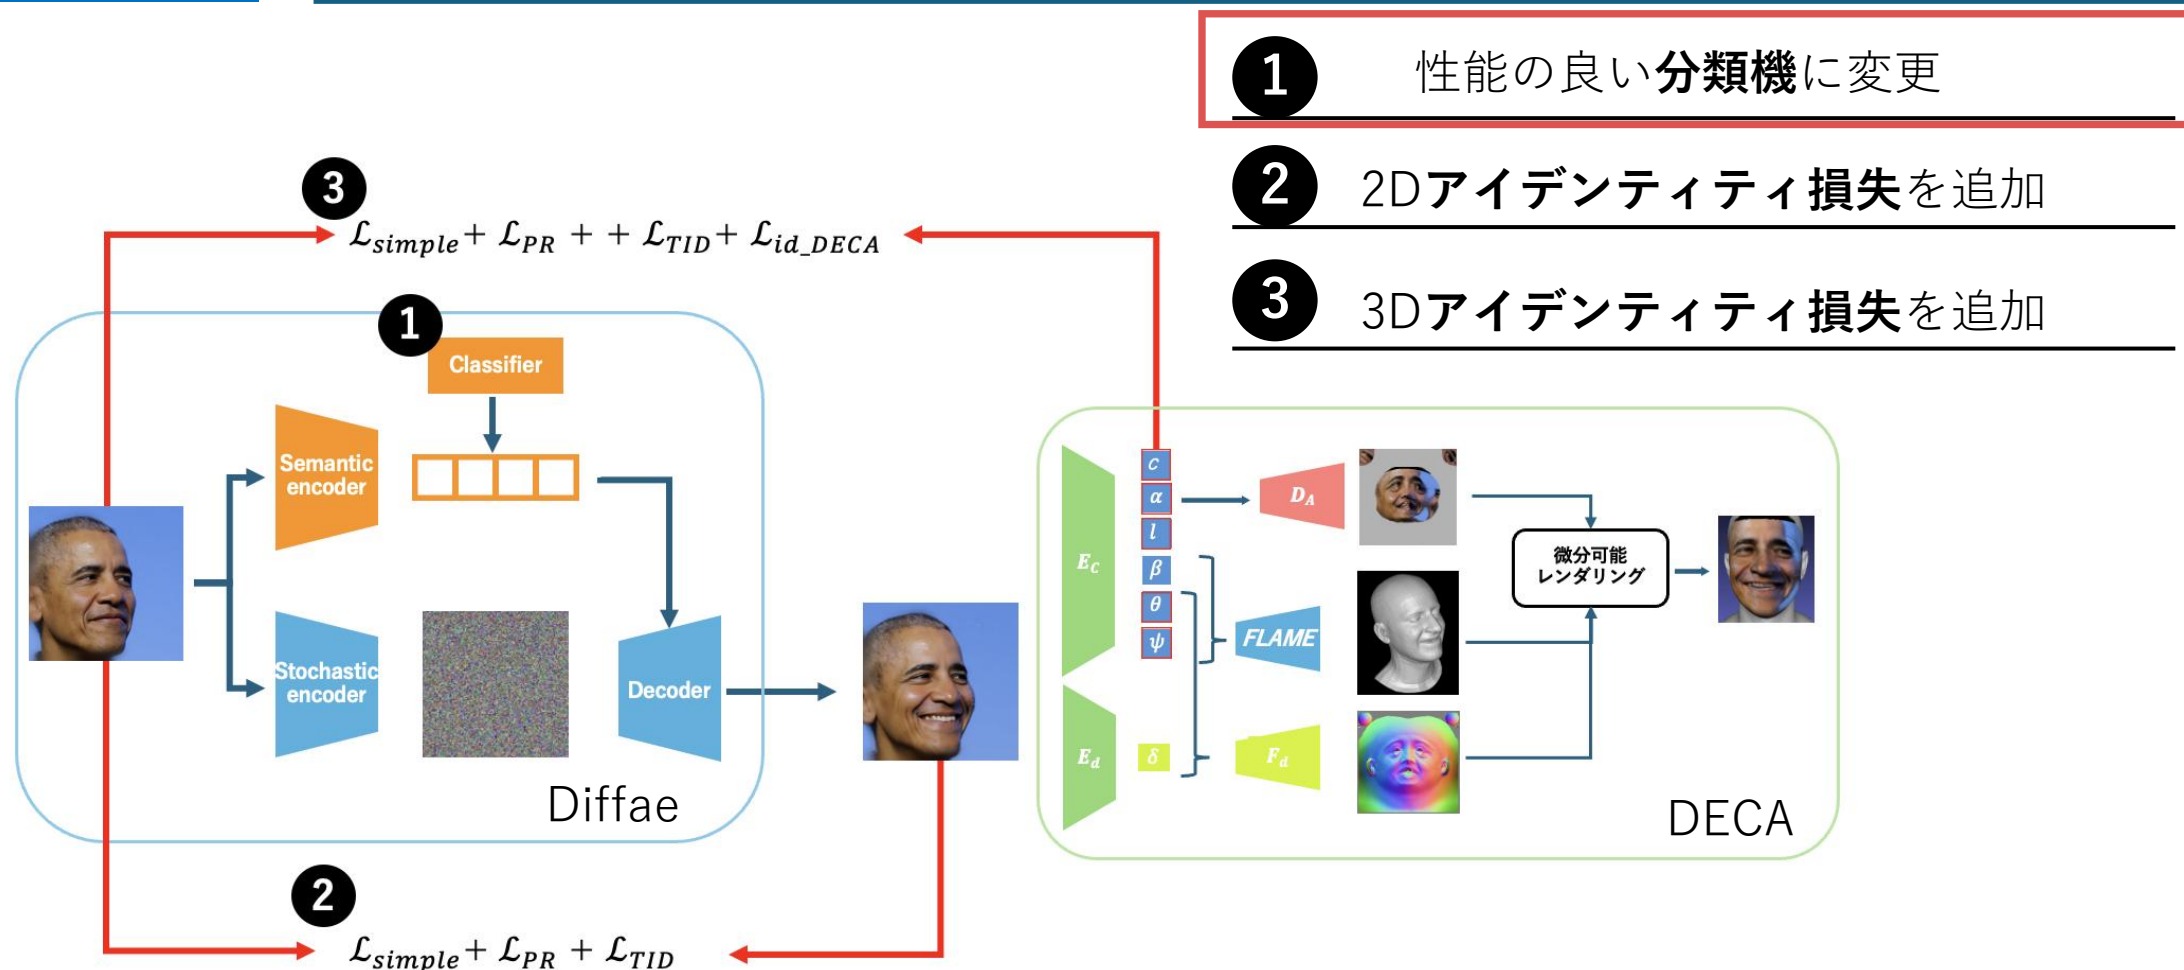



図. DECA[1]とDiffusionAutoencoders[2]を元にした提案モデル

[1] YAO FENG et al. Learning an Animatable Detailed 3D Face Model from In-The-Wild Images

[2] Konpat Preechakul et al. Diffusion Autoencoders: Toward a Meaningful and Decodable Representation



画像生成の流れ

1. 入力画像を**Semantic encoder**と**Stochastic encoder**に入力
2. **Semantic encoder**で意味的情報 z_{sem} を抽出
3. **Stochastic encoder**で画像の詳細情報 x_T を抽出
4. **線形分類器**から属性の方向を示す重みベクトルを取得
5. 抽出された z_{sem} に対して、重みベクトルを加算
6. 操作後の z_{sem} と x_T を**Decoder**に入力し、属性変更した画像を生成

Manipulationにおける訓練

1. Diffusion Autoencoderの訓練

$$L_{\text{simple}} = \sum_{t=1}^T \mathbb{E}_{x_0, \epsilon_t} \left[\|\epsilon_\theta(x_t, t, z_{sem}) - \epsilon_t\|_2^2 \right]$$

2. 線形分類器の訓練

入力された z_{sem} に対して、以下の重みベクトルを推定

$$z_{sem_new} = w^T z_{sem} + b$$

今回発見した新しい改善余地：

線形分類器の改善、AffectNetを用いたDiffusionAutoencoderの訓練

	線形分類器	非線形分類器
訓練	• <code>nn.Linear(conf.style_ch, num_cls)</code> のみで構成 • 入力特徴ベクトルをそのまま分類出力にマッピング • 非線形性がなく、学習できる関係は線形に限定 • シンプルで軽量だが、表現力に制限あり	• <code>nn.Sequential</code> により複数の層を構成 • <code>nn.Linear(conf.style_ch, 512)</code>: 隠れ層を追加 • <code>nn.LeakyReLU(negative_slope=0.01)</code>: 非線形性を導入 • <code>nn.Dropout(0.5)</code>: 過学習を防止 • <code>nn.Linear(512, num_cls)</code>: 最終出力層 • より複雑なデータ分布に対応可能 • 汎化性能の向上が期待できる
条件付け	• 条件ベクトルに対して、分類器の重みベクトル (<code>cls_id</code> に対応) を直接加算することで強調を行う • 分類器の出力に勾配を用いず、固定的な方向の操作	• 条件ベクトルを分類器に通して、目的クラス (<code>cls_id</code>) のスコアに対する勾配を取得 • その勾配方向に沿って特徴量を強調 (勾配 $\times$ 強度 $\alpha \times$ スケール) • より柔軟でタスク適応的な条件操作が可能 (勾配ベースの強調)

▶ 非線形分類器では分類器全体の挙動を活かして**意味方向**を導き出すことが可能

非線形よりも線形の方が正確度が高い

入力画像






図. 8種類の表情に対するAccuracy

当初の仮説：分類器を非線形にすることで、表現力が向上し、精度が向上する
前回の結果：線形分類器の方が精度が高い

原因：

1. データに関する要因
 - a. 問題が本質的に線形分離可能である
 - b. データセットが小規模である
 - c. 特徴量の質が高い
2. モデル構造に関する要因
 - a. 過学習
 - i. 隠れ層の次元数が大きすぎる
 - ii. Dropout率が不適切
 - b. 不適切な活性化関
3. 学習プロセスに関する要因
 - a. 最適化の難しさ
 - b. ハイパーパラメータのチューニング不足
 - c. 学習エポック数が不適切

原因を一つずつ検証

ステップ1：過学習の抑制
隠れ層のユニット数を減らす
Dropout率を調整する
L2正則化を追加する

ステップ2：学習プロセスの最適化
学習率を調整する
Early Stoppingを導入する

ステップ3：データと問題設定の再評価
データ拡張をする
データの可視化

ステップ1：過学習の抑制

表.過学習抑制のためのハイパーパラメータ検証値

変更点	検証値
隠れ層のユニット数	[32, 64, 128, 256, 512]
Dropout率	[0.1, 0.2, 0.3, 0.4, 0.5]
L2正則化	[1e-5, 1e-4, 1e-3, 1e-2]

①「隠れ層のユニット数」を決める:

まずは正則化を無効（Dropout=0, weight_decay=0）にするか、非常に弱い状態（weight_decay=1e-5など）にして、最適なユニット数のあたりをつけます。これにより、モデルに必要な最低限の表現力が分かります。

②「正則化の強さ」を決める:

ステップ1で決めた最適なユニット数でモデルを固定します。その上で、Dropout率→Weight Decayの順で値を変更し、過学習を最も効果的に抑制できる値を探します。

隠れ層ごとの比較

表. 隠れ層ごとの分類精度

Accuracy	h32	h64	h128	h256	h512	liner
$\alpha=0.05$	0.125	0.25	0.375	0.25	0.375	0.375
$\alpha=0.10$	0.125	0.375	0.375	0.25	0.75	0.625
$\alpha=0.15$	0.125	0.5	0.625	0.5	0.75	0.625
$\alpha=0.20$	0.375	0.625	0.625	0.625	0.875	0.625
$\alpha=0.25$	0.375	0.75	0.75	0.625	0.875	0.75
$\alpha=0.30$	0.375	0.75	0.75	0.75	0.875	0.875
$\alpha=0.35$	0.375	0.75	0.75	0.75	0.875	0.875
$\alpha=0.40$	0.375	0.75	0.75	0.75	0.875	0.875

h512とLinerが最高精度を達成
隠れ層は多いほど、精度が向上する

h512とlinerの比較①

表. アイデンティティ比較

CSIM	h512	liner
$\alpha=0.05$	0.94835	0.94888
$\alpha=0.10$	0.931013	0.933013
$\alpha=0.15$	0.89705	0.9046
$\alpha=0.20$	0.8589	0.88005
$\alpha=0.25$	0.81465	0.846138
$\alpha=0.30$	0.772125	0.808488
$\alpha=0.35$	0.722738	0.771063
$\alpha=0.40$	0.675075	0.748825

α を軸に比較すると、linerの方がアイデンティティを保持できている
一方で、Accuracy : 0.875を達成した α で比較すると、h512の方が優れている

h512とlinerの比較②

表. h512の表情分類

h512	正解の表情								正解の表情の確率							
	Neutral	Happiness	Sadness	Surprise	Fear	Disgust	Anger	Contempt	Neutral	Happiness	Sadness	Surprise	Fear	Disgust	Anger	Contempt
$\alpha=0.05$	Contempt	Happiness	Contempt	Contempt	Disgust	Disgust	Disgust	Contempt	0.1503	0.3076	0.1315	0.0579	0.1017	0.2346	0.136	0.2236
$\alpha=0.10$	Neutral	Happiness	Sadness	Disgust	Disgust	Disgust	Anger	Contempt	0.2002	0.3672	0.1963	0.0647	0.1192	0.276	0.2127	0.2434
$\alpha=0.15$	Neutral	Happiness	Sadness	Disgust	Disgust	Disgust	Anger	Contempt	0.2306	0.3613	0.287	0.0765	0.1577	0.3264	0.2811	0.2639
$\alpha=0.20$	Neutral	Happiness	Sadness	Disgust	Fear	Disgust	Anger	Contempt	0.2505	0.3625	0.4087	0.0824	0.2272	0.3858	0.3411	0.2868
$\alpha=0.25$	Neutral	Happiness	Sadness	Disgust	Fear	Disgust	Anger	Contempt	0.2625	0.3586	0.5359	0.0832	0.3168	0.4589	0.3987	0.3207
$\alpha=0.30$	Neutral	Happiness	Sadness	Fear	Fear	Disgust	Anger	Contempt	0.2702	0.351	0.6214	0.0826	0.4212	0.5492	0.4645	0.3475
$\alpha=0.35$	Neutral	Happiness	Sadness	Fear	Fear	Disgust	Anger	Contempt	0.2719	0.3557	0.6766	0.0812	0.5341	0.6325	0.5212	0.3738
$\alpha=0.40$	Neutral	Happiness	Sadness	Fear	Fear	Disgust	Anger	Contempt	0.2693	0.3807	0.7076	0.0817	0.6335	0.7017	0.5647	0.3833

表. linerの表情分類

h512	正解の表情								正解の表情の確率							
	Neutral	Happiness	Sadness	Surprise	Fear	Disgust	Anger	Contempt	Neutral	Happiness	Sadness	Surprise	Fear	Disgust	Anger	Contempt
$\alpha=0.05$	Contempt	Happiness	Contempt	Contempt	Contempt	Disgust	Disgust	Contempt	0.1564	0.2925	0.1289	0.0585	0.1019	0.226	0.1089	0.2275
$\alpha=0.10$	Neutral	Happiness	Sadness	Disgust	Contempt	Disgust	Disgust	Contempt	0.2108	0.3571	0.1938	0.0643	0.1112	0.2563	0.1469	0.2494
$\alpha=0.15$	Neutral	Happiness	Sadness	Disgust	Contempt	Disgust	Disgust	Contempt	0.2508	0.3603	0.2912	0.0731	0.1287	0.2907	0.1813	0.2727
$\alpha=0.20$	Neutral	Happiness	Sadness	Disgust	Disgust	Disgust	Disgust	Contempt	0.2796	0.356	0.4042	0.0868	0.1612	0.331	0.2107	0.2804
$\alpha=0.25$	Neutral	Happiness	Sadness	Fear	Fear	Disgust	Disgust	Contempt	0.297	0.3593	0.5268	0.1043	0.2154	0.3865	0.2371	0.2883
$\alpha=0.30$	Neutral	Happiness	Sadness	Fear	Fear	Disgust	Anger	Contempt	0.3004	0.3586	0.6204	0.1187	0.2732	0.4503	0.2572	0.298
$\alpha=0.35$	Neutral	Happiness	Sadness	Fear	Fear	Disgust	Anger	Contempt	0.3038	0.3613	0.6841	0.1253	0.3208	0.5229	0.2725	0.3071
$\alpha=0.40$	Neutral	Happiness	Sadness	Fear	Fear	Disgust	Anger	Contempt	0.3047	0.3687	0.7164	0.1286	0.3625	0.5992	0.2802	0.3177

Accuracy : 0.875を達成した α と比較すると、h512の方が低い確率の絶対値で分類できている
表情分類は、Surpriseがどちらも失敗・Fear/Angerに関して**h512の方が低い α で分類できている**

ドロップアウト率がモデルの性能を低下させていた

表. Dropout率ごとの分類精度比較

Accuracy	dr=0.0	dr=0.1	dr=0.2	dr=0.3	dr=0.4	dr=0.5
$\alpha=0.05$	0.375	0.25	0.375	0.375	0.375	0.375
$\alpha=0.10$	0.75	0.375	0.375	0.25	0.25	0.25
$\alpha=0.15$	0.75	0.5	0.5	0.25	0.5	0.5
$\alpha=0.20$	0.875	0.625	0.5	0.625	0.5	0.5
$\alpha=0.25$	0.875	0.75	0.625	0.625	0.5	0.5
$\alpha=0.30$	0.875	0.75	0.75	0.625	0.625	0.625
$\alpha=0.35$	0.875	0.75	0.75	0.625	0.625	0.625
$\alpha=0.40$	0.875	0.75	0.75	0.625	0.625	0.625



過学習が発生していない

モデルが過学習を起こしていないため、ドロップアウトによる正則化が不要だった

ドロップアウトが学習を阻害した

ドロップアウト率が高すぎたため、重要な特徴量の学習を妨げ、性能が低下した

タスクの特性に起因する

タスクが単純なため、ドロップアウトがノイズとなり、モデルの性能を下げてしまった

Weight Decayは小さいほど、分類精度は高い

表. Weight Decayごとの分類精度比較

Accuracy	wd=0.00001	wd=0.0001	wd=0.001	wd=0.01
$\alpha=0.05$	0.375	0.125	0.25	0.25
$\alpha=0.10$	0.75	0.125	0.25	0.125
$\alpha=0.15$	0.75	0.25	0.125	0.125
$\alpha=0.20$	0.875	0.375	0.375	0.125
$\alpha=0.25$	0.875	0.375	0.375	0.125
$\alpha=0.30$	0.875	0.5	0.5	0.25
$\alpha=0.35$	0.875	0.75	0.5	0.25
$\alpha=0.40$	0.875	0.75	0.5	0.25



Weight Decayが0.00001のときが最も精度が高かった

→この値が**モデルの複雑さを抑えつつ、データの特徴を学習するのに最適なバランス**であった

Weight Decayを大きくすると、モデルの重みが過度にペナルティを受け、小さくなりすぎたと考えられる

→モデルが**データ内の重要なパターンや特徴を十分に学習できなくなり**、結果として分類精度が低下した

Summary

- **隠れ層のユニット数:**
 - 隠れ層の数が多いほど精度は向上した.
 - h512 モデルが線形分類器 (liner) と同等の最高精度 (0.875) を達成した.
- **アイデンティティ保持:**
 - アイデンティティ保持の面では、h512 が線形分類器 (liner) よりも優れていることがわかった.
 - 特定の α 値 (0.875 の精度を達成した α) で比較すると、h512 がより優れたアイデンティティ保持を示した.
- **表情分類の信頼性:**
 - h512 モデルは、特定の表情 (Fear/Anger) において線形モデルよりも低い確率で分類でき、より高い信頼性を示した.
 - 一方で、Surprise の分類は両モデルともに失敗した.
- **正則化の影響:**
 - **Dropout:** モデルが過学習を起こしていないため、Dropoutによる正則化は不要で、むしろ学習を阻害し、性能を低下させていた.
 - **Weight Decay:** Weight Decayの値が小さいほど分類精度が高かった.

最終的な結論


非線形分類器 (h512) は、適切なハイパーパラメータ設定（特に正則化を弱める）により、線形分類器を上回る分類精度とアイデンティティ保持を達成できる。

Agenda

1. 自身の研究の進捗

2. 今後の研究計画

今回発表した改善点を随時実装



1. SMIRK実験結果

2. 作成予定モデル


3. 論文紹介

実施事項：

- DECA・EMOCA・SMIRKから抽出したExpression Latent CodeをDDMに直接条件付け

期待されるメリット

- 3DMM由来の感情をより直接的に表現可能




実施事項：

- DECA・EMOCA・SMIRKから抽出したIdentity Latent CodeをDDMに直接条件付け

期待されるメリット

- より少ない個人アルバム枚数でアイデンティティを保った画像を生成可能
- DDMが背景と顔の区分けより明確に意識するようになる



shape・expパラ追加
なし あり

target



DECA



source



EMOCA



target



source



DECA


shape・expパラ追加
なし あり



EMOCA



OFER: Occluded Face Expression Reconstruction



取り組んだ問題と背景

- ✓ 顔の上に遮蔽物が存在する場合の再構成問題は、観測可能な情報が減少するだけでなく、複数の再構成結果がいずれも妥当となり得るという曖昧性が新たに生じる
- ✓ 現状のFLAMEやNPHMをベースとした2D to 3Dモデルは単一の再構成結果しか出力できない

このモデルの特徴

- ✓ 強い遮蔽条件下においても、現実的で多様性に富み、かつ表情豊かな3D顔モデルを生成可能
- ✓ 入力画像に基づいてFLAMEのshape・expパラメータを別々に生成する2つの拡散モデルを訓練することで、出力として複数の解の分布を生成する
- ✓ 多様な表情表現を実現かつ表情間で一貫性を保つために、最適なshapeパラメータの選択が重要
→ shape用拡散モデルの出力を、予測された形状精度スコアに基づいて順位付けする新規のランキング機構を導入

OFERの概要




図1. モデルの生成過程[1]

IdGen・ExpGen（アイデンティティ・表情生成ネットワーク）

- 二つの拡散モデルを用いてFLAMEパラメータを出力




図2. IdGenとExpGenのアーキテクチャ[1]

IdRank (アイデンティティランキングネットワーク)

- 表情パラメータが異なるN個のサンプルにおいて、一貫したアイデンティティを保持したい
- 様々な遮蔽物で入力画像を覆った場合のFLAMEパラメータを比較すると、形状係数は表情係数に比べて変動性がはるかに小さい




図3. IdRankのアーキテクチャ[1]

定性比較




図4. 各モデルの比較[1]

IdRankの導入結果




図5. 無表情の場合の再構成結果[1]

アイデンティティ保持度の比較




図6. 様々な条件で同一人物を撮影した画像を入力した結果[1]

定量評価

表1. IdRankに関するablation study[1]

Samples	Ideal Lowest Error Sample			Ranked Sample			Average of All Samples		
	Med ↓	Mean ↓	std ↓	Med ↓	Mean ↓	std ↓	Med ↓	Mean ↓	std ↓
(a)FLAME(200 - 1k)	(1.00 - 0.90)	(1.31 - 1.20)	(1.18 - 1.11)	NA	NA	NA	1.75	2.19	1.86
(b)FLAME(50)+OFER(50)	0.84	1.09	0.95	1.08	1.44	1.32	1.33	1.79	1.62
(c)FLAME(80)+OFER(20)	0.86	1.10	0.97	1.34	1.81	1.65	1.60	2.06	1.84
(d)OFER(100)	0.81	1.05	0.92	0.98	1.21	1.01	1.02	1.25	1.04

表2. 定量評価[1]

Method	Unoccluded			Occluded			Both		
	Med	Mean	std	Med	Mean	std	Med	Mean	std
FLAME	1.79	2.24	1.89	1.80	2.26	1.91	1.79	2.25	1.90
Deep3D [11]	1.33	1.67	1.41	1.40	1.73	1.41	1.36	1.70	1.41
DECA [21]	1.18	1.47	1.24	1.29	1.56	1.29	1.17	1.46	1.25
MICA (4DS) [61]	n/a	n/a	n/a	n/a	n/a	n/a	1.02	1.25	1.05
MICA (8DS) [61]	n/a	n/a	n/a	n/a	n/a	n/a	0.90	1.11	0.92
TokenFace [58]	n/a	n/a	n/a	n/a	n/a	n/a	0.79	0.99	0.85
FOCUS [32]	1.03	1.25	1.03	1.07	1.34	1.19	1.05	1.31	1.14
FOCUS (MP) [32]	1.02	1.24	1.02	1.08	1.34	1.20	1.03	1.29	1.12
Diverse3D [12]	n/a	n/a	n/a	n/a	n/a	n/a	1.41	1.78	1.52
OFER-rank (ours)	0.97	1.20	1.00	1.01	1.26	1.05	0.98	1.21	1.01
OFER-min	0.81	1.04	0.91	0.84	1.10	0.96	0.81	1.05	0.92
OFER-avg	1.01	1.25	1.03	1.04	1.29	1.08	1.01	1.25	1.04

今後の研究計画

