

第22回定期ミーティング

2025/10/24

早稲田大学 基幹理工学研究科
電子物理システム学専攻 史研究室
石黒将太郎・野口颯汰

1. DiffusionRig-EmoV2の結論

2. 今年中の目標

3. 研究計画

3DMM推論モデルのid・expパラメータをDiffusionRig内の拡散モデルに直接条件付けすることによる効果は？

Valence・Arousalの値が悪化しているため、生成画像における感情の再現度が落ちている。

Identityの維持度と肌の質感に関しては改善したが微差であるため直接条件付けする必要はない

DiffusionRig内のDECAをEMOCAに置き換えたV1と、V1内の拡散モデルに直接条件付けを加えたV2の差

指標 タイプ	評価指標	V1内のSOTAモデルの値	V2内のSOTAモデルの値	V1との差
定量的	Valence(↓)	21.186	23.483	15.6%悪化(オバマは10.8%)
	Arousal (↓)	9.529	10.313	0.9%悪化(オバマは8.2%)
	Identity(↑)	0.9115	0.9278	1.5%改善(オバマは2.7%)
定性的	肌の質感	-	-	イラスト感が減少
	3DMMで扱わない部分の表現	-	-	髪や歯が崩れた画像の増加

今後やること

1. AWS上でDiffusionRig-Emoを使用できるようにする。






図. DiffusionRigのアーキテクチャ

今後の研究計画



Agenda

1. 関連研究の紹介
2. 自身の研究の進捗
3. 今後の研究計画

OmniPart: Part-Aware 3D Generation with Semantic Decoupling and Structural Cohesion

YUNHAN YANG, YUFAN ZHOU, YUAN-CHEN GUO, ZI-XIN ZOU, YUKUN HUANG, YING-TIAN LIU, HAO XU, DING LIANG, YAN-PEI CAO, XIHUI LIU



参考サイト：

- ✓ <https://www.youtube.com/watch?v=FRrtlz3u4B8>
- ✓ <https://omnipart.github.io/>
- ✓ <https://github.com/HKU-MMLab/OmniPart>
- ✓ <https://huggingface.co/spaces/omnipart/OmniPart>

- 従来の3D生成モデルはパーツ構造を欠くモノリシックな形状の生成にとどまり、実用的な編集タスクに限界がある

背景・課題

モノリシックな形状の生成：

多くの3Dオブジェクト生成モデルが単一の塊の形状のオブジェクトを生成をするモデルであり、実世界のオブジェクトに固有のパーツベースの構造を欠いている

実用性の限定：

パーツ構造が欠けていると、構造的な編集、プロシージャルアニメーション、マテリアル割り当て、意味的理解といった、アーティストや開発者にとって不可欠なタスクが困難になる

取り組んだ問題

パーツを意識した3D生成を行うことで上記の課題を解決するため以下の要素を両立することを目指す

1. 高い意味的な分離：


各コンポーネントが明確に区別され、独立してアドレス可能であること

2. 強固な構造的な凝集性：

パーツ全体が一貫性のある、もっともらしい統合された全体を形成すること

- パーツを意識した3D生成において、高い意味的分離と強固な構造的凝集性の両立を目指し、構造計画とパーツ合成の2段階プロセスを提案

第1段階




オブジェクトのパーツレベルの空間レイアウトの定義

自己回帰モデルによる可変長の3Dパーツバウンディングボックス (BBox) シーケンスの生成

柔軟な2Dパーツマスクによる直感的な制御：直接的な対応付けや意味的ラベルは不要

パーツカバレッジ損失の導入による、BBoxのボクセル包含の保証

第2段階




計画されたレイアウト内でのすべての3Dパーツの同時かつ一貫した合成

全オブジェクトコンテキストを考慮したデノイズ処理
クリーンなパーツ境界の実現を目的としたボクセル破棄メカニズムの導入
パーツ位置埋め込みによるTransformer内でのパーツ識別

- OmniPartは、アクティブボクセル（粗い構造）と潜在特徴（詳細）の2段階で3D形状を生成する大規模事前学習済みモデル「TRELLIS」を基盤としている

OmniPartの基盤：TRELLIS


- 大規模な事前学習済み3Dジェネレーター（整流フローモデル）を活用
- 構造化された潜在表現を導入
表面と交差するアクティブなボクセル（粗い構造）と、ローカルな潜在特徴（幾何学的・外観の詳細）のセットで構成される
- 2段階のアプローチを採用:
 - 全体のアクティブボクセル $\mathbf{v}$ を生成し、
 - 整流フローモデルで潜在特徴 $\mathbf{f}$ を生成する



- 2Dパーツマスクによる「制御性」とカバレッジ損失による「網羅性」を確保した自己回帰モデルで、3Dバウンディングボックスを生成する


自己回帰的バウンディングボックス生成

- 制御性:**
柔軟な2Dパーツマスクを入力として使用し、パーツの粒度や分解を制御
- 条件付け:**
入力画像の特徴 (DINOv2) と、2Dマスクに基づくパーツ埋め込み $\mathbf{E}$ を結合し、条件付けトークン $\mathbf{f}$ を生成
- 新しい損失:**
パーツカバレッジ損失 L_{coverage} を導入し、BBBoxがパーツのボクセルを完全に囲むことを保証する (小さすぎる場合にペナルティ)



- 第1段階で計画したBBBoxを用いて潜在コードを初期化し、事前学習済みTRELLISモデルをファインチューニングすることで高忠実なパーツを生成

空間条件付きパーツ合成: 一貫性と高忠実度の実現



基盤モデルの適応:


事前学習済みのTRELLISモデルを、**限られたパーツ教師データ**で効率的にファインチューニング

パーツ潜在コードの初期化:

BBBoxがTRELLISのボクセル空間を定義し、パーツごとの潜在コードを初期化する

- 全体コンテキストの利用、パーツ位置埋め込み、ボクセル破棄メカニズムの3つの技術により、パーツ間の構造的ー貫性とクリーンな境界を両立


空間条件付きパーツ合成: ー貫性と高忠実度の実現



構造的ー貫性の確保:

- 全オブジェクトコンテキストの利用: ノイズ除去 (デノイズ) プロセスで、各パーツのボクセル表現が全体形状のコンテキストと並行して考慮され、全体的なコヒーレンスを強化
- パーツ位置埋め込み: Transformer内でパーツを識別するため、全体形状トークンにインデックス0、各パーツに一意的インデックスを割り当てる
- クリーンなインターフェース: ボクセル破棄メカニズムを導入。パーツの潜在表現に有効性を示す次元を追加し、境界でのノイズボクセルや重複をフィルタリングし、クリーンな分離を実現

- 180K/15Kのデータセットを使い分け、特に**Voxel recall**を重要指標とする評価において、カバレッジ損失がBBBox生成精度の向上に決定的な役割を果たす



全体データセット:

180K個のパーツ注釈付きオブジェクトを収集し、そのうち**15K個**を高品質な注釈を持つオブジェクトとして特定

1. 自己回帰的BBBox生成（第1段階）用データ:

学習データ:

事前学習済みの知識がないため、全180Kの注釈付き形状を使用してゼロから学習

データ処理:

各パーツのBBBoxを抽出し、z-y-x順でソートし、トークン化してシーケンス学習に使用

2. 構造化パーツ潜在生成（第2段階）用データ:

学習データ:

15Kの高品質な注釈付き形状のみを使用し、事前学習済みのTRELLIS（第2段階）をファインチューニング

データ処理:

各パーツについて150ビューをランダムにレンダリングし、特徴を抽出、3Dボクセルに投影して融合

- バウンディングボックス生成の評価（第1段階）では、提案手法(OmniPart)がVoxel recallで85.96%を達成
特にカバレッジ損失と2Dマスクが性能向上に不可欠であることを示した

表. バウンディングボックス生成に関する定量結果

Method	Voxel recall ↑	Voxel IoU ↑	Bbox IoU ↑
PartField [Liu et al. 2025a]	79.12	39.02	27.30
OmniPart (w/o 2D mask)	66.98	31.44	25.90
OmniPart (w/o coverage loss)	64.50	50.56	41.24
OmniPart (Ours)	85.96	61.02	38.37

重要指標: Voxel recall (↑) :

欠損ボクセルを生成しないために、予測されたBBox内に有効なボクセルがどれだけ含まれるかを測る指標

結果 :

OmniPart (Ours) はベースライン (PartField) を大幅に上回り、Voxel recallで85.96%を達成し、高いカバレッジを保証

アブレーション分析:

- カバレッジ損失がないモデルは、BBox IoUは高いものの、**Voxel recallが大幅に低下** (85.96% → 64.50%)
- **制御性の検証:** 2Dマスクがない場合、BBoxのサイズと配置の制御に失敗し、性能が低下

- パーツレベルのF1スコアでSOTAを達成しつつ、生成時間も約0.75分と既存手法(Part123, PartGen)より大幅に高速化した

表. パーツレベルおよび全体オブジェクト生成の定量的結果

Method	Part-level			Overall-object		
	CD ↓	F1-0.1 ↑	F1-0.5 ↑	CD ↓	F1-0.1 ↑	F1-0.5 ↑
TRELLIS+SAM3D	0.49	0.38	0.28	0.08	0.92	0.77
TRELLIS+PartField	0.19	0.69	0.52	0.08	0.92	0.77
TRELLIS+PartField+HoloPart	0.19	0.68	0.51	0.08	0.91	0.77
Part123	0.43	0.31	0.16	0.47	0.33	0.19
PartGen	0.44	0.43	0.30	0.11	0.86	0.69
OmniPart (Ours)	0.18	0.74	0.59	0.07	0.93	0.80


表. 生成時間比較

Method	Part123 [Liu et al. 2024a]	PartGen [Chen et al. 2024b]	Ours
Time (minute)	~ 15	~ 5	~ 0.75

OmniPartは、**パーツレベル**および**全体オブジェクトレベル**の両方で一貫して上回る

- **パーツレベル F1-0.1:** OmniPart (Ours) は **0.74** を達成し、SOTAを達成
- **全体オブジェクトのコヒーレンス:** 全体形状のみを生成するTRELLIS単体の結果よりも、OmniPartで統合された結果の方が性能が高い
- **効率性:** エンドツーエンドの生成時間は、Part123（約15分）やPartGen（約5分）と比較して、OmniPartは**約0.75分**と大幅な効率改善を実現





- 提案手法(Ours)は他の手法に見られる幾何学的な不整合を克服し、正解(GT)に最も近い高品質なパーツ生成を達成



OmniPart :
低セマンティック結合と高構造的凝集性を両立したテクスチャ付きパーツを生成

他の手法 :
表面セグメンテーションの限界や、幾何学的整合性の低さに悩まされる





- (a) 2Dマスクでパーツ構造を正確にガイドできる制御性と、(b) マスクの粒度を調整するだけで多様な分解能の3Dオブジェクトを生成できる柔軟性を両立している



(a) マスク制御型生成:
ユーザーが2Dマスクを指定することで、生成されるパーツの構造を正確にガイド可能

(b) マルチグラニューラリティ生成:
2Dセグメンテーションマスクの粒度を調整するだけで、異なるレベルのパーツ分解能を持つ3Dオブジェクトを生成可能

- (c) パーツ単位での自由なマテリアル編集や、(d) リメッシュ等の処理でも境界のアーティファクトを防ぐジオメトリ処理が可能になる



(c) マテリアル編集:

生成されたパーツ構造を利用し、帽子のテクスチャや服の色など、パーツレベルでの自由な外観カスタマイズが容易に実現

(d) ジオメトリ処理:

パーツ認識型表現は、リメッシュなどの高度な処理においてもパーツ間の境界でアーティファクトが発生せず、**構造的コヒーレンス**を維持

Agenda

1. 関連研究の紹介
- 2. 自身の研究の進捗**
3. 今後の研究計画




図. DECA[1]とDiffusionAutoencoders[2]を元にした提案モデル

[1] YAO FENG et al. Learning an Animatable Detailed 3D Face Model from In-The-Wild Images

[2] Konpat Preechakul et al. Diffusion Autoencoders: Toward a Meaningful and Decodable Representation

Summary

- **隠れ層のユニット数:**
 - 隠れ層の数が多いほど精度は向上した.
 - h512 モデルが線形分類器 (liner) と同等の最高精度 (0.875) を達成した.
- **アイデンティティ保持:**
 - アイデンティティ保持の面では、h512 が線形分類器 (liner) よりも優れていることがわかった.
 - 特定の α 値 (0.875 の精度を達成した α) で比較すると、h512 がより優れたアイデンティティ保持を示した.
- **表情分類の信頼性:**
 - h512 モデルは、特定の表情 (Fear/Anger) において線形モデルよりも低い確率で分類でき、より高い信頼性を示した.
 - 一方で、Surprise の分類は両モデルともに失敗した.
- **正則化の影響:**
 - **Dropout:** モデルが過学習を起こしていないため、Dropoutによる正則化は不要で、むしろ学習を阻害し、性能を低下させていた.
 - **Weight Decay:** Weight Decayの値が小さいほど分類精度が高かった.

最終的な結論

非線形分類器 (h512) は、適切なハイパーパラメータ設定（特に正則化を弱める）により、線形分類器を上回る分類精度とアイデンティティ保持を達成できる。

Summary

非線形分類器の性能向上を目的とした、「活性化関数」と「ネットワークの深さ」の2つの観点からの最適なモデル構成の検討

1. 活性化関数の比較検証:

- ReLUをはじめとする6種類の活性化関数における分類精度の比較
- パラメータ α が高い領域 ($\alpha \geq 0.25$) において、ReLUが継続的に最も高い精度を達成し、 $\alpha = 0.40$ で最高値 (0.53125) を記録

2. 隠れ層の深さの比較検証:

- 隠れ層を1～3層で変化させた場合の、分類精度、処理速度、アイデンティティ維持の3指標における性能比較
- 分類精度、処理速度、アイデンティティ維持の性能を総合的に評価した結果、最もバランスの取れた2層 (depth=2) のモデル

結論

以下の構成の採用による、分類器の精度と安定性の両立、および総合的な性能向上の実現することが可能

活性化関数：ReLU

隠れ層の深さ：2層 (depth=2)

元画像

Happiness($\alpha = 0.2$) & Anger

Happiness($\alpha = 0.2$) & Sadness

入力画像

$\alpha = 0.1$

$\alpha = 0.2$

$\alpha = 0.3$

$\alpha = 0.1$

$\alpha = 0.2$

$\alpha = 0.3$



HSEMtionによる
表情認識評価

prob_Anger

prob_Happiness

prob_Sadness

prob_Happiness

0.0297

0.3423

0.029

0.3451

0.033

0.3139

0.0282

0.3284

0.0474

0.2751

0.0368

0.299

考察

- 定量的な評価だと、 α を加えるにあたって、認識確率が向上しているが、かなりHappiness側によっている
- Angerは目力がつよく、Sadnessは口角が下がっているような印象を受けるが、微々たる違いである
- ▶ 引き続き改善を行う

Agenda

1. 関連研究の紹介
2. 自身の研究の進捗
- 3. 今後の研究計画**

今回発表した改善点を随時実装

