

第23回定期ミーティング

2025/10/28

早稲田大学 基幹理工学研究科
電子物理システム学専攻 史研究室
石黒将太郎・野口颯汰

Agenda

1. 自身の研究の進捗

2. 今後の研究計画

「量子化」は、Diffaeに対し、低コストで（PTQの場合）、課題である「メモリ」と「計算速度」の両方を同時に改善できる、最も実用的なアプローチ

1. Diffusion Autoencoder (Diffae) の構造とボトルネック

	デコーダ (Conditional DDIM)	セマンティック・エンコーダ
役割	2種類の潜在コードを受け取り、画像を再構成するために「反復実行（例: 20-100ステップ）」される - 内部ではU-Netベースのモデルが動作する	入力画像から意味情報を抽出するために「1回」実行される
ボトルネック	- 反復実行が推論時間の大部分を占める - 巨大なU-Netモデルが「メモリ使用量」と「メモリ帯域幅」を圧迫	CNNベース（デコーダのU-Net前半部と類似）であり、一定のメモリと計算コストを要す
メモリ容量	98.73 MB	514.38 MB

2. 各軽量化手法のターゲットと特性

	ステップ削減	蒸留	量子化
ターゲット	デコーダ (Conditional DDIM)	デコーダ (U-Net) / エンコーダ	デコーダ (U-Net) / エンコーダ
主な効果	反復回数を削減し、計算時間（推論速度）を短縮	モデルサイズ（パラメータ数）を削減	メモリ使用量（と帯域幅）を大幅に削減
コスト/課題	Diff-AEは条件付けにより、ベースのDDIMより少ないステップで既に高速化されてる。 しかし、デコーダ (U-Net) 自体の「メモリ」問題は解決していない	高品質なモデルの実現には、大規模な「再学習」が必須であり、導入コストが非常に高いです	PTQ（後述）ならば再学習が不要で、導入コストが低い

PTQは、DAEに対して「再学習コスト」を回避し、「メモリ削減」と「高速化」の恩恵を最もバランス良く受けるための、現実的かつ強力な手法

	PTQ	QAT	Dynamic Quantization
タイミング	トレーニング後	トレーニング中	推論中
追加データの必要性	不要	必要	不要
実装の容易さ	容易	難 (学習コスト高)	容易
精度	低ビット（特に4bit以下） は低下の可能性あり	高い精度を保ちやすい	モデルサイズと精度の バランスを取りやすい
特徴	実装が簡単で、 元の学習データが不要	学習段階から量子化をシミュ レートし、重みを最適化	推論時に入力データを見て、 動的にスケールを決定

PyTorch静的量子化（fbgemmバックエンド）によるINT8化を実行

表. 量子化による削減効果

	量子化前 [MB]	量子化後 [MB]	削減割合 [%]
Encoder	98.73	25.04	74.4
Denoiser	514.38	130.73	74.8
Classifier	2.12	0.56	73.6

概要

GroupNorm がINT8非対応

問題

実行結果

torch.quantization.convert 時、またはモデル実行時に RuntimeError: unsupported module type for fbgemm: GroupNorm32 が発生

対策

仮に convert を回避しても、GroupNorm が返すFP32テンソルと、他のINT8テンソルとの演算（特に ResBlock 内の加算）で RuntimeError: promoteTypes with quantized numbers... (QUInt8 Float) が発生する

検討中の解決策

混合精度 量子化

fbgemm がサポートする層（Conv2d, Linear）はINT8で計算し、非対応の層（GroupNorm）はFP32のまま計算

元画像

Happiness($\alpha = 0.2$) & Anger

Happiness ($\alpha = 0.2$) & Sadness

$\alpha = 0.1$

$\alpha = 0.2$

$\alpha = 0.3$

$\alpha = 0.1$

$\alpha = 0.2$

$\alpha = 0.3$

入力画像



HSEMtionによる
表情認識評価

α	prob_Anger	prob_Happiness	prob_Sadness	prob_Happiness
0.1	0.0297	0.3423	0.029	0.3451
0.2	0.033	0.3139	0.0282	0.3284
0.3	0.0474	0.2751	0.0368	0.299

考察


- 定量的な評価だと、 α を加えるにあたって、認識確率が向上しているが、かなりHappiness側によっている
- Angerは目力がつよく、Sadnessは口角が下がっているような印象を受けるが、微々たる違いである

Agenda

1. 自身の研究の進捗

2. 今後の研究計画

今回発表した残論点を随時実装



1. DiffusionRig-Emoの実用化

2. 開発環境の選定

3. 実装状況

4. 研究計画

今後やること

1. AWS上でDiffusionRig-Emoを使用できるようにする。





図. DiffusionRigのアーキテクチャ

サービス名	概要
AWS	Amazonが運営するクラウドコンピューティング。クラウドサービスの中で市場シェア一位。基本何でもできる。
Google Cloud	Googleが運営するクラウドコンピューティング。自社開発のTensorflow・TPUを合わせたAI開発プラットフォームがある。
Azure	Microsoftが運営するクラウドコンピューティング。Microsoft製品との親和性が高く、オンプレミスでWindows ServerやSQL Serverを既に利用している企業向き。
Lambda Labs	個人向けのクラウドGPU。自社で豊富な種類のGPUを保有していて、信頼性の高い環境で最新のGPUを使用できる可能性が高い。
Vast.AI	個人向けのクラウドGPU。個人や企業が余っているGPUを貸し出しているプラットフォーム。最も価格が安い、貸し手（ホスト）側で接続を切られたり、ネット接続が不安定な場合がある。
Paperspace	クラウドGPU。データの管理からモデル学習、推論用APIのデプロイまで同じプラットフォームで可能であり、サービス自体はブラウザ上でJupyter Notebookを通して利用できる。
SOROBAN	経産省認定のクラウドGPUサービス。AI開発やCAD、シミュレーションをするためのGPUを利用でき、CUDAやPytorchがプリインストールされているため使いやすい。国内サービスで最も個人向け。
さくらインターネット	経産省認定のクラウドGPUサービス。ハイエンドのGPUをメインに利用でき、最新のGPU(H100~)が豊富。また、同社の「さくらのクラウド」との連携が強み。
GMO	経産省認定の法人向けクラウドGPUサービス。ハイエンドのGPUをメインに利用でき、NVIDIA推奨の高速ネットワークを採用しているため、複数GPU間の通信ボトルネックに対する柔軟性が強み。
NTTPC	法人向けのクラウドGPUサービス。最新世代のNVIDIA製GPUであるBlackwellシリーズを利用でき、インフラの設計から運用・保守までNTTPCのエンジニアによるサポートを受けられる。

開発を行うクラウドサービスの選定（料金）

サービス名	T4	L4	A10	V100	A100
AWS	80	120	150	450	620
Google Cloud	53	105	120	375	-
Azure	60	105	125	450	558
Lambda Labs	-	-	110	-	200
Vast.AI	23	60	24	270	-
Paperspace	-	-	-	345	450
SOROBAN	-	-	-	-	361
さくらインターネット	-	-	-	481	-
GMO	-	-	-	-	-
NTTPC	-	-	-	-	341

※1ドル=150円として計算し、1時間あたりの料金を記載。
※Vast.AIは11/1時点の料金。変動性のため、時間によって大幅な使用可能なGPUや使用料金の変更がある。

開発を行うクラウドサービスの選定（使いやすさ）

サービス名	推論向けGPUの有無	開発環境の操作性	プリインストール	GPUの借りやすさ（主観）
AWS	有	SageMaker	CUDAやPytorchなど全て	○
Google Cloud	有	Vertex AI	CUDAやPytorchなど全て	×（GPU1個から申請が必要）
Azure	有	Azure ML	CUDAやPytorchなど全て	▲（多くのGPUには申請が必要）
Lambda Labs	有	SSH接続	CUDAやPytorchなど全て	▲
Vast.AI	有	SSH接続 or Jupyter Notebook	ホスト次第	○
Paperspace	無	Jupyter Notebook(ブラウザ操作)	CUDAやPytorchなど全て	○
SOROBAN	無	利用しやすいクラウドコンソールが提供	CUDAやPytorchなど全て	○
さくらインターネット	無	利用しやすいクラウドコンソールが提供	標準OSのみ	×（申請が必要）
GMO	無	専任エンジニアが必要	CUDAやPytorchなど全て	×（申請が必要）
NTTPC	無	専任エンジニアが必要	CUDAやPytorchなど全て	×（申請が必要）

- ✓ AWS上でDiffusionRig用のAPIサーバーを立てる
- ✓ g4dnインスタンス（NVIDIA T4搭載）上でDiffusionRig-Emoの推論を実行
- ✓ ローカル環境でstreamlitを用いたアプリとして、推論の実行と結果表示まで行う

🚀 推論実行トリガー

📡 接続設定

推論API エンドポイント URL

`https://iu6oaxao69.execute-api.ap-northeast-1-`

📁 パス設定

Source ディレクトリ (S3パス)

`s3://diffusionrig-demo-tokyo/source02/`

S3バケット名

`diffusionrig-demo-tokyo`

Target ファイル (S3パス)

`s3://diffusionrig-demo-tokyo/target/obama05.p`

Output ディレクトリ (S3パス)

`s3://diffusionrig-demo-tokyo/outputs/my-first-r`

完了監視設定

S3チェック間隔 (秒)

`15`

監視上限時間 (分)

`15`

ECS推論タスクを実行 (Start Task)

my-ecs-cluster

ARN: arn:aws:ecs:ap-northeast-1:20749297321:cluster/my-ecs-cluster

ステータス: アクティブ

CloudWatch モニタリング: デフォルト

登録済みコンテナインスタンス: 1

サービス: ドレイン中

タスク: 1

タスク (3)

タスク	前のステータス	必要なステータス	タスク
29a60863cd7d40f79bdbbd1e8bf52e3f	停止済み Essential container in task exited	停止済み	diffus
61a8ce894a8c4a1f9ba15aa9560ad816	停止済み Essential container in task exited	停止済み	diffus
d6101ebc0006467295ff6f5590a7d690	停止済み Essential container in task exited	停止済み	diffus

今後の研究計画

- DiffusionRig-Emoの推論をAWS上の様々なインスタンスで実行してみる
- 各インスタンスでの推論実行時間を比較し、どのインスタンス(GPU)がDiffusionRig-Emoの実行に適しているかについて考察

